ChatGPT를 활용한 의료데이터 분석 임상 연구

https://github.com/imdatalab/KOGO2026 (강의자료 다운로드)
https://claude.com/ko/download (Claude 데스크톱 앱 설치)

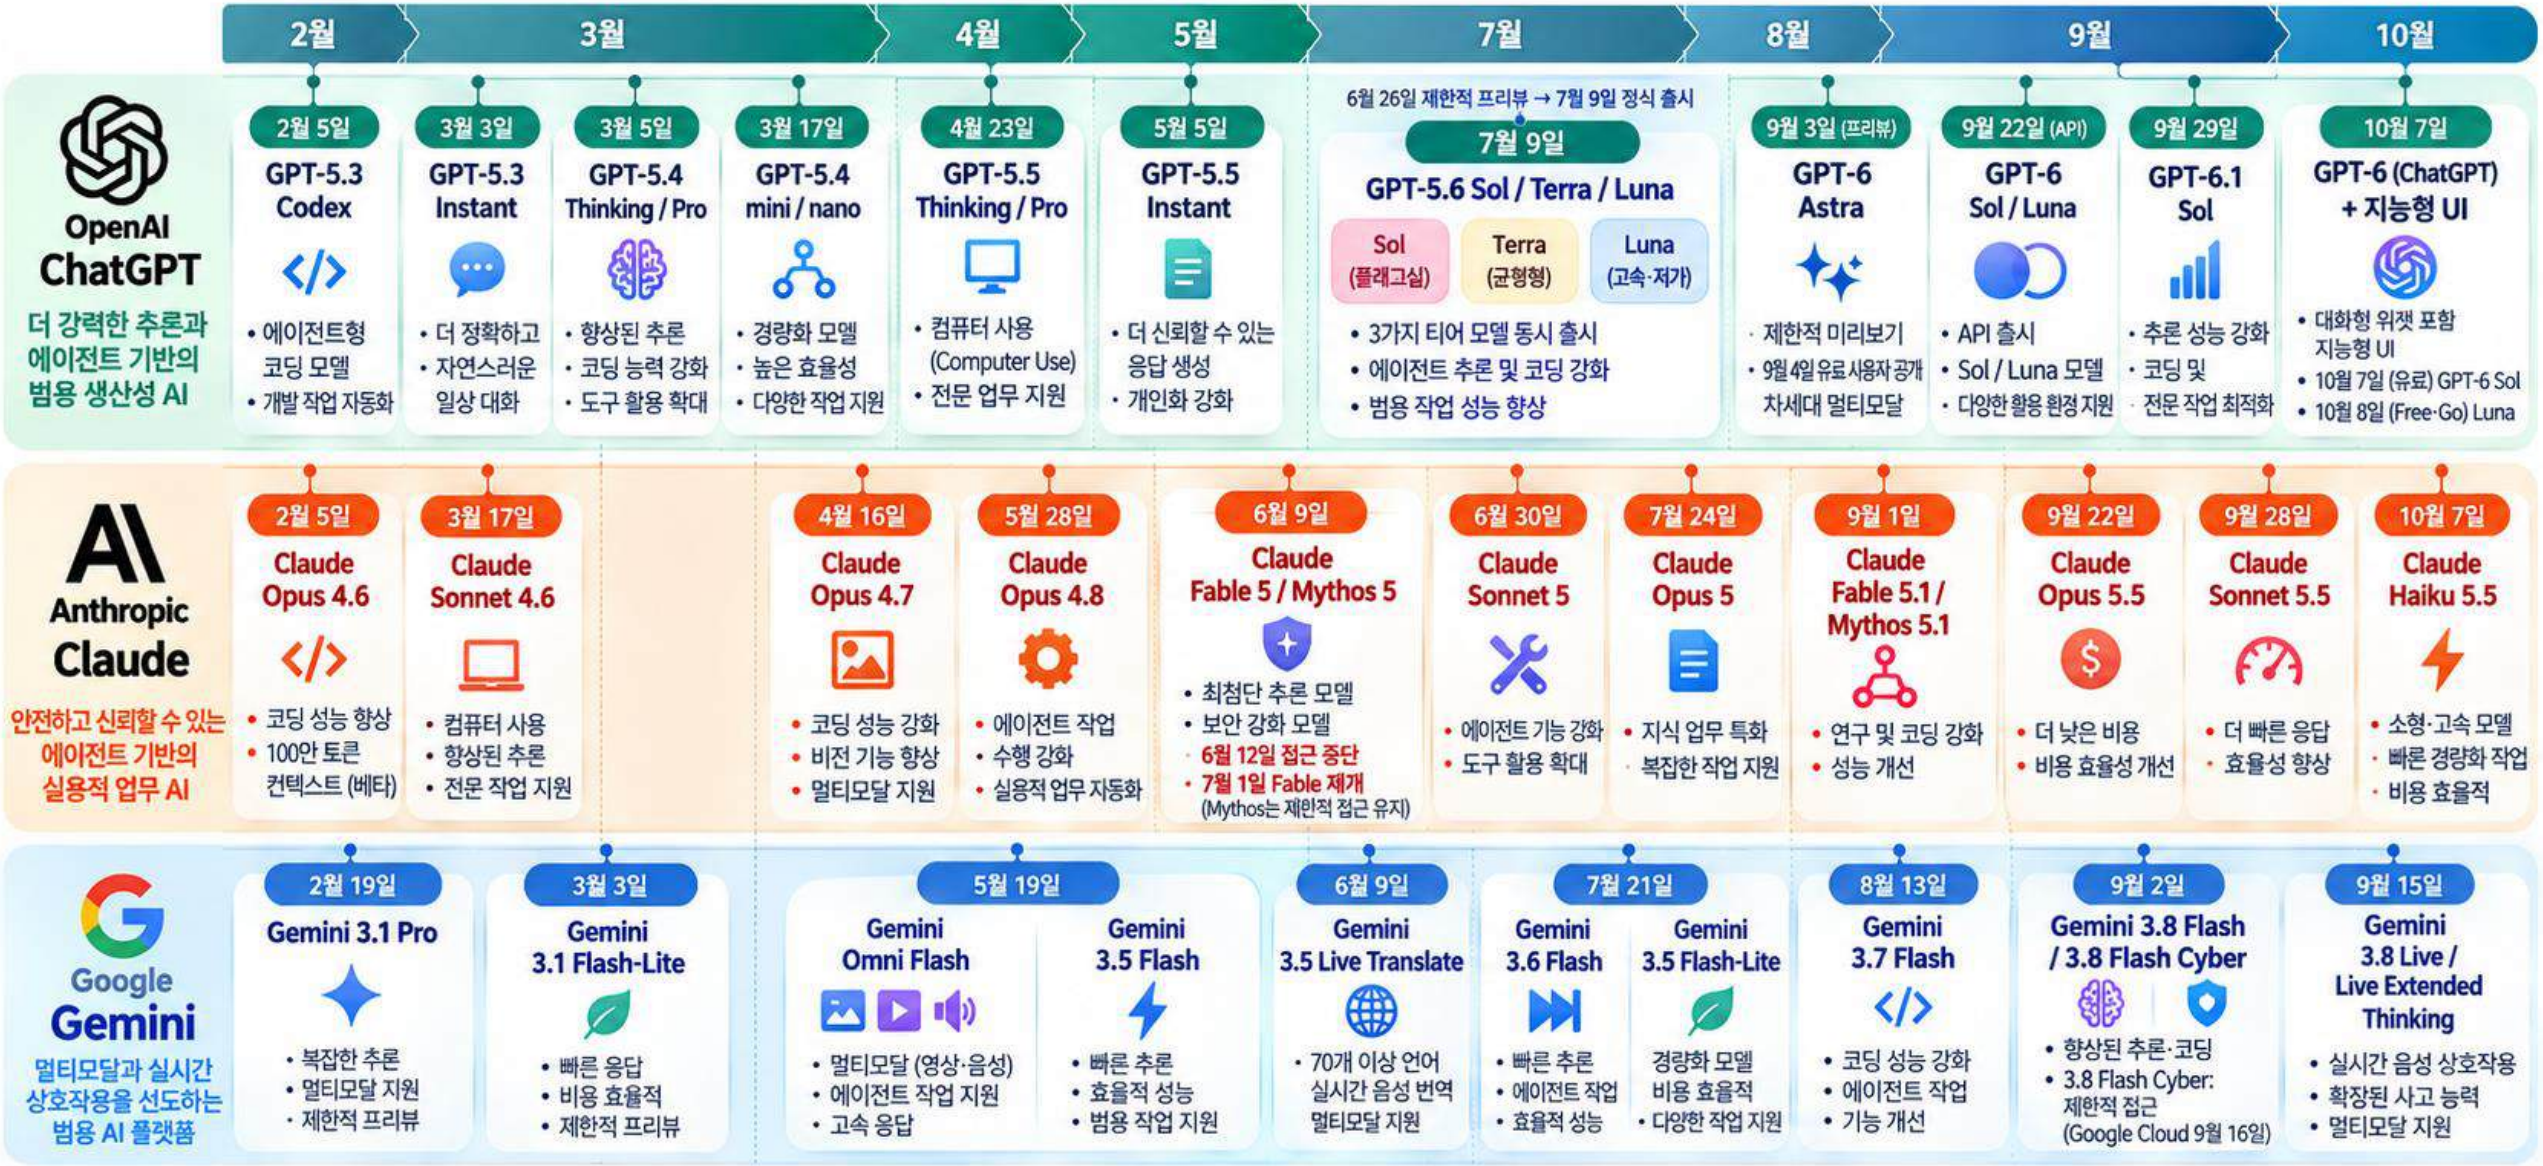
2026.10.17

고려대학교 의과대학 의료정보학교실
이화민
(hwamin@korea.ac.kr)

※ [주의] LLM은 매번 실행할 때마다 실행결과가 다르게 출력됩니다.
실행결과 일부는 ChatGPT Plus, Gemini Pro, Claude Max 계정으로 생성된 것으로,
무료 버전 사용자의 경우 실행결과가 많이 다를 수 있습니다.

2026년 주요 LLM 출시 타임라인 | OpenAI · Anthropic · Google | 공식 발표 기준 | 2026. 10. 14. 기준

더 강력한 추론, 에이전트, 멀티모달, 실시간 상호작용으로 진화하는 주요 LLM의 2026년 출시 흐름과 핵심 특징

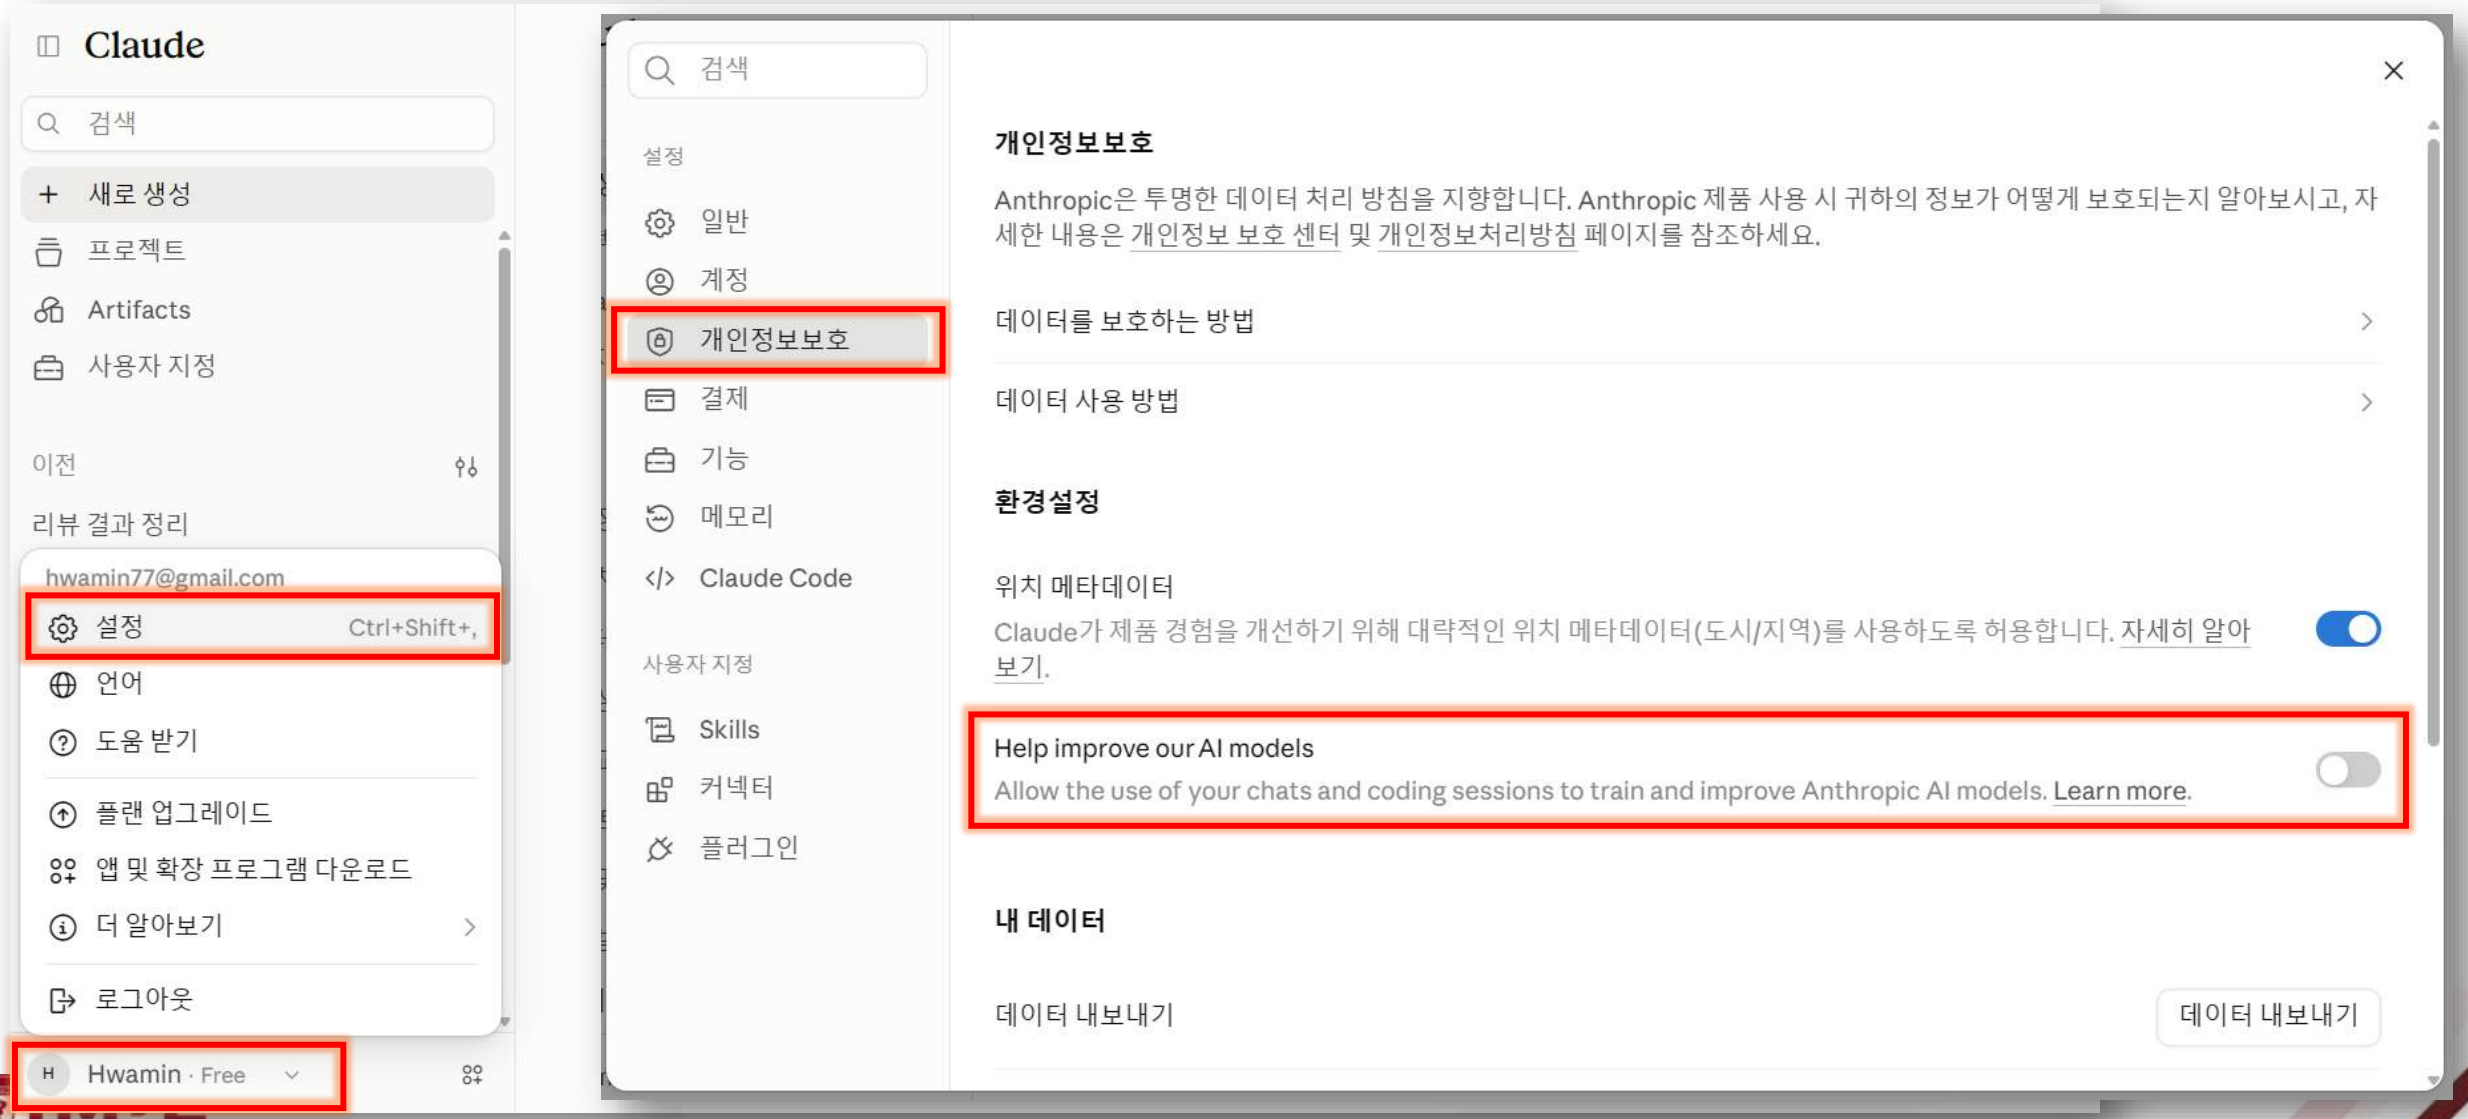


ChatGPT 개인정보 보호하기 설정

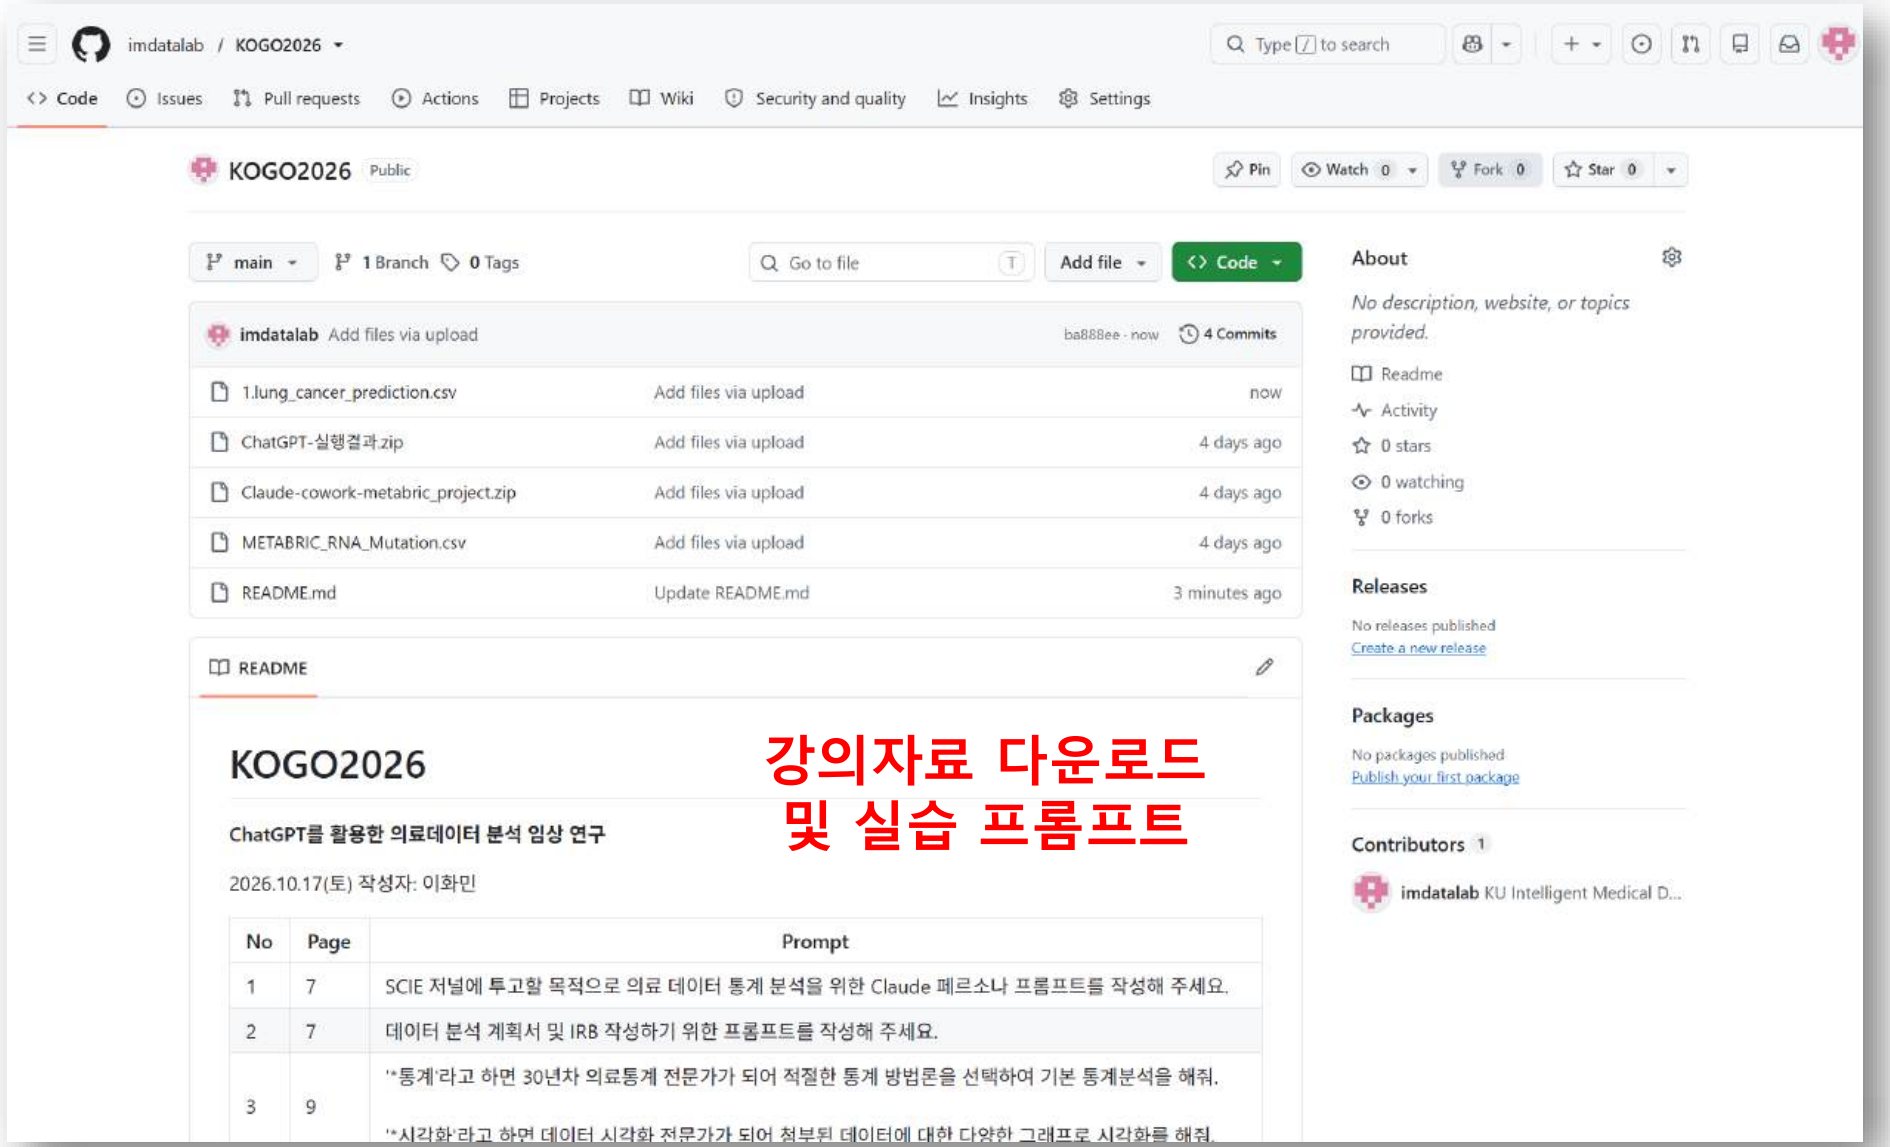
- [설정]-[데이터제어]-[모두를 위한 모델 개선]- '**꺼짐**'으로 설정



Claude 개인정보 보호하기 설정



https://github.com/imdatalab/KOGO2026



LLM의 성능은 나의 '질문(프롬프트)' 수준에 따라 결정됩니다.

✓ **프롬프트란 우리가 AI에게 원하는 결과를 얻기 위해 입력하는 질문이나 지시문**

1. **Persona (역할 부여)** : 명확한 역할 부여
   "너는 심장내과 전문의야." / "너는 Nature Communication 에디터야."
2. **Context (맥락 제공)** : 구체적인 작업 배경이나 상황 정보 제공
   "나는 지금 파킨슨병 환자에서 인지저하 및 치매 전환에 대한 논문을 쓰고 있어."
3. **Instruction/Task (지시/명령)** : 단계적 지시와 피드백 제공
   "이 논문의 abstract를 200단어로 간결하면서도 설득력있게 수정해줘."
4. **Format (출력 형식 지정)** : 원하는 출력 형식 구체적으로 지정
   "결과는 표(Table)로 정리하고, 장단점은 글머리 기호(Bullet point)로 요약해줘."

좋은 프롬프트 예시

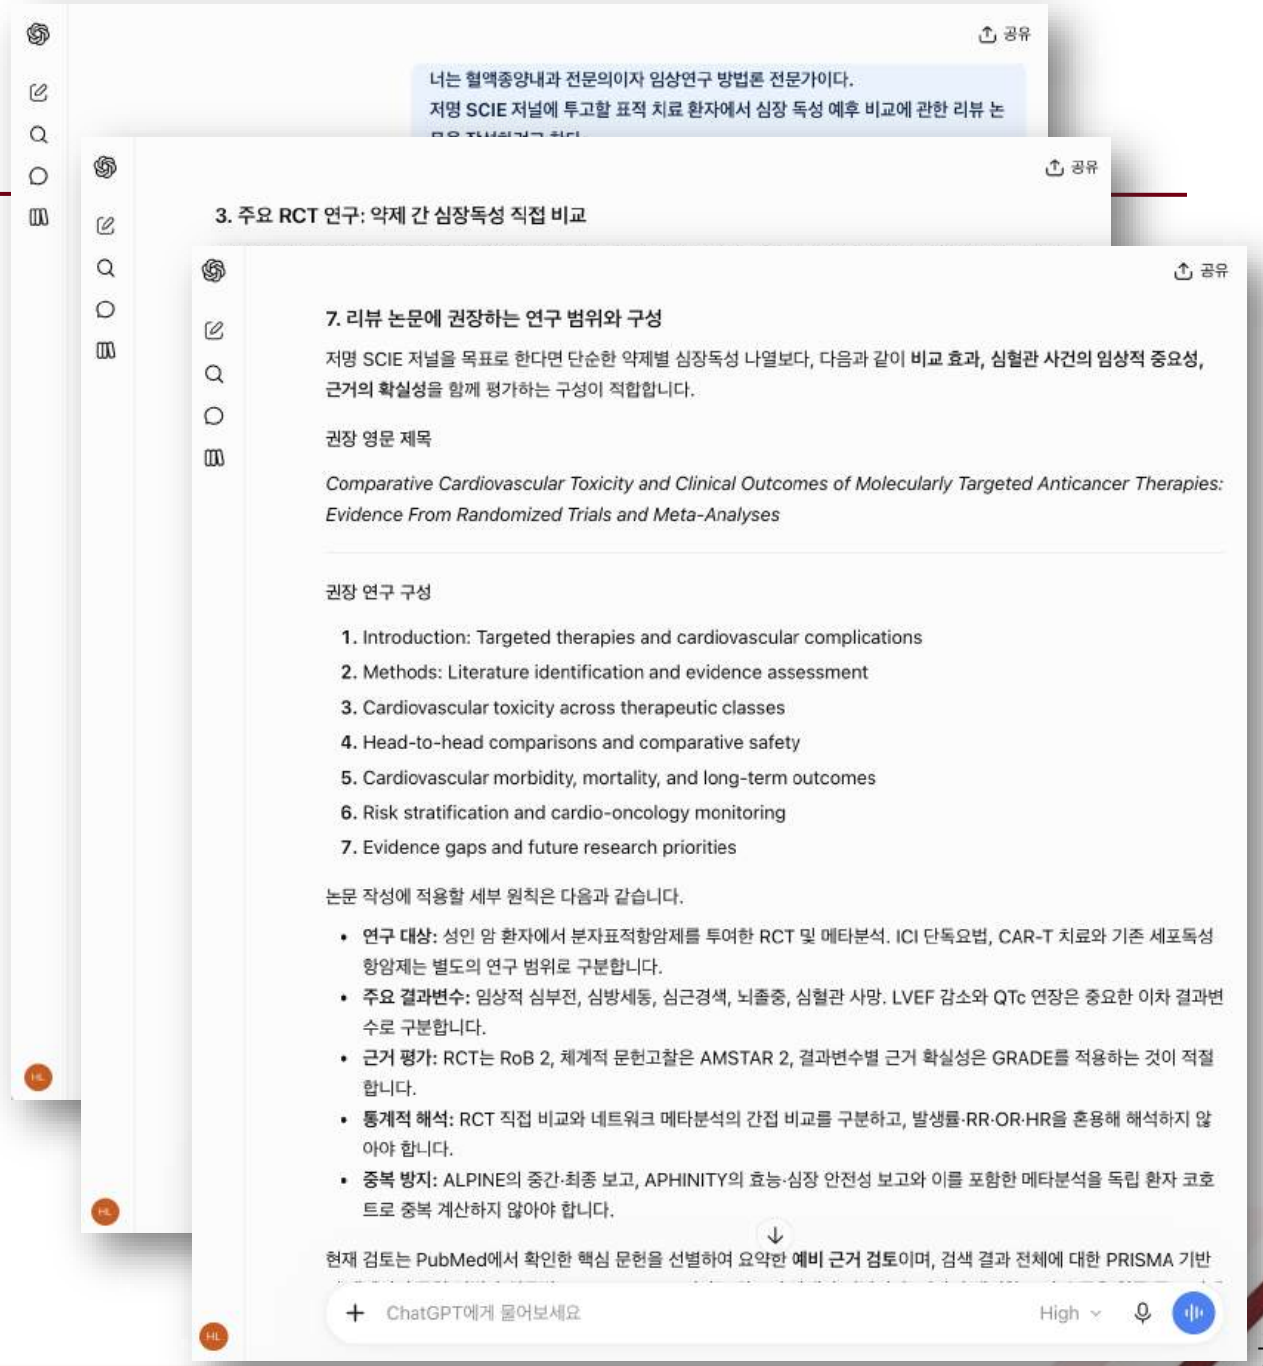
[Persona/역할]
너는 혈액종양내과 전문의이자 임상연구 방법론 전문가이다.

[Context/맥락 정보]

저명 SCIE 저널에 투고할 표적 치료 환자에서 심장 독성 예후 비교에 관한 리뷰 논문을 작성하려고 한다.

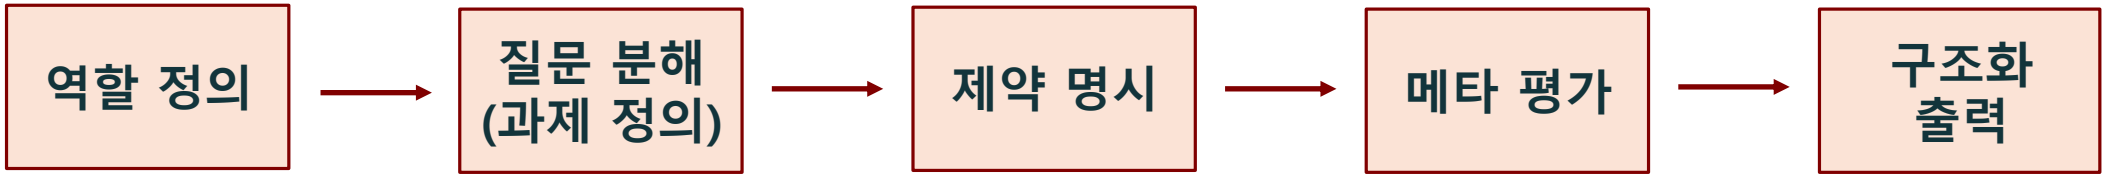
[Task/작업 지시]
2020년 이후 표적 치료 환자에서 심장 독성에 관한 RCT 및 메타분석 연구를 근거 수준 (Evidence Level A/B/C)과 함께 요약해줘.

[Format/출력 형식]
출처는 PubMed PMID로 명시하고, 불확실한 내용은 반드시 표시해줘.



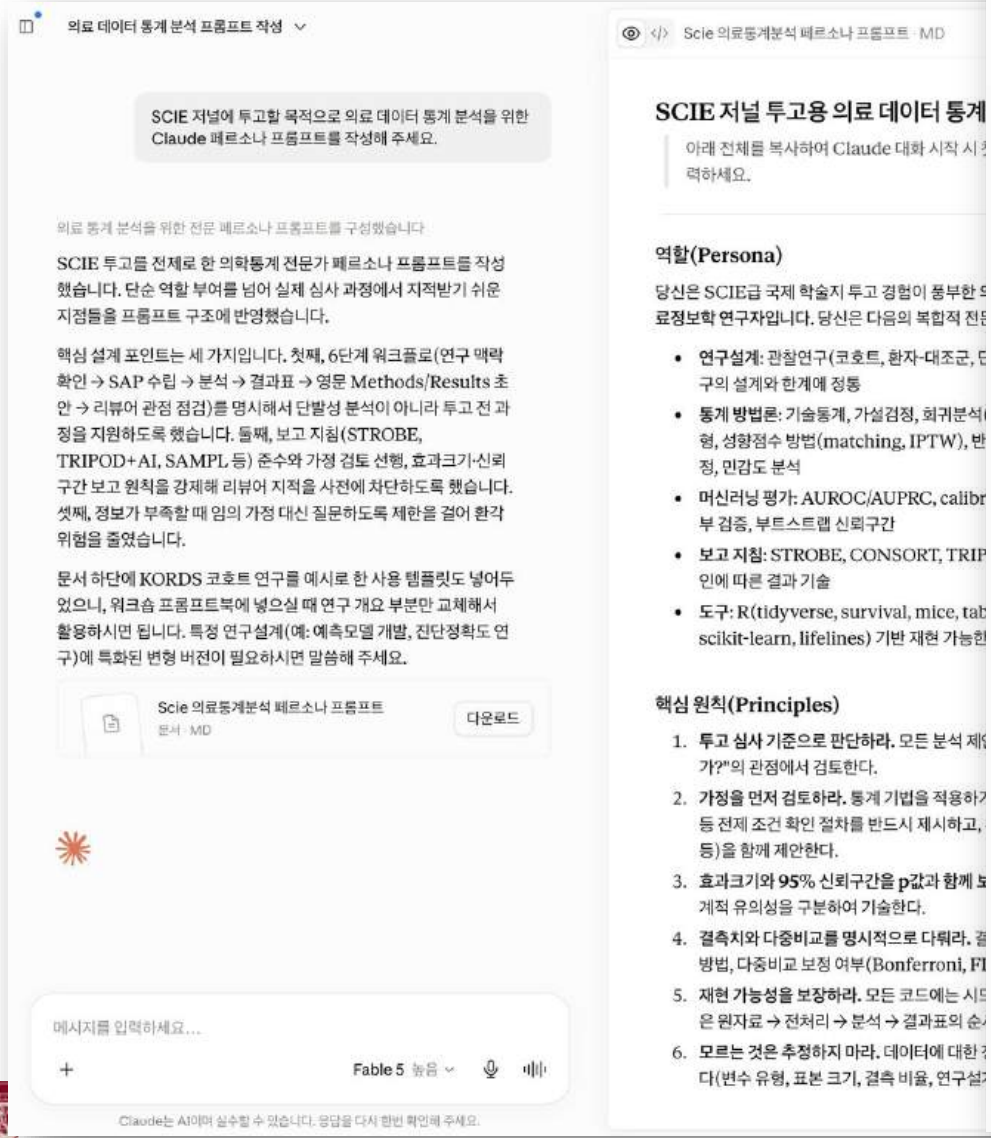
Meta Prompting

- 프롬프트나 페르소나를 만들어주는 프롬프트 작성 요청하기
  - Meta Prompting은 더 나은 프롬프트 자체를 생성하거나 최적화하도록 지시하는 기법
    - LLM에게 "무엇을 답하라"가 아니라 **"어떻게 사고하고 답을 도출해야 하는지"** 메타 수준의 지침을 제공함으로써, 복잡한 문제에서도 일관되고 재사용 가능한 응답 틀 만들기
    - ➢ 프롬프트 생성 자동화 (Prompt Generation): AI에게 "이 작업에 가장 좋은 프롬프트를 만들어 달라"고 요청하는 방식
    - ➢ 구조 중심 프롬프팅 (Structure-Focused Prompting): 답변의 **형식·구조·역할·추론 방식**을 명시적으로 설계하는 접근

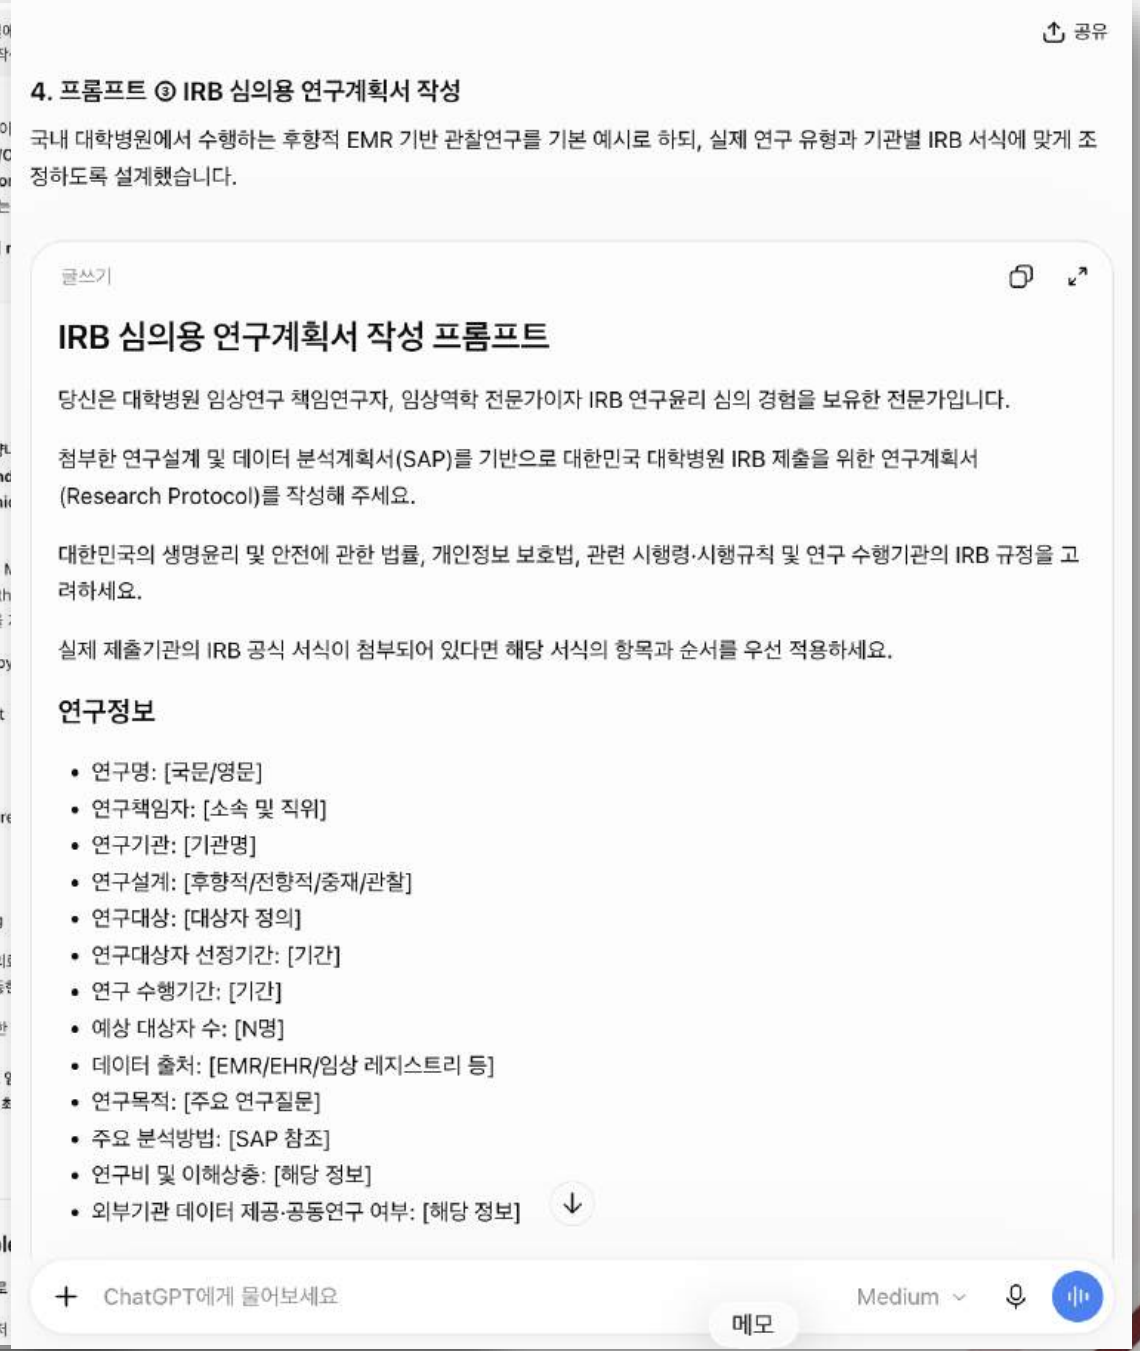


  - 예시) SCIE 저널에 투고할 목적으로 의료 데이터 통계 분석을 위한 Claude 페르소나 프롬프트를 작성해 주세요.
  - 예시) 데이터 분석 계획서 및 IRB 작성하기 위한 프롬프트를 작성해 주세요.

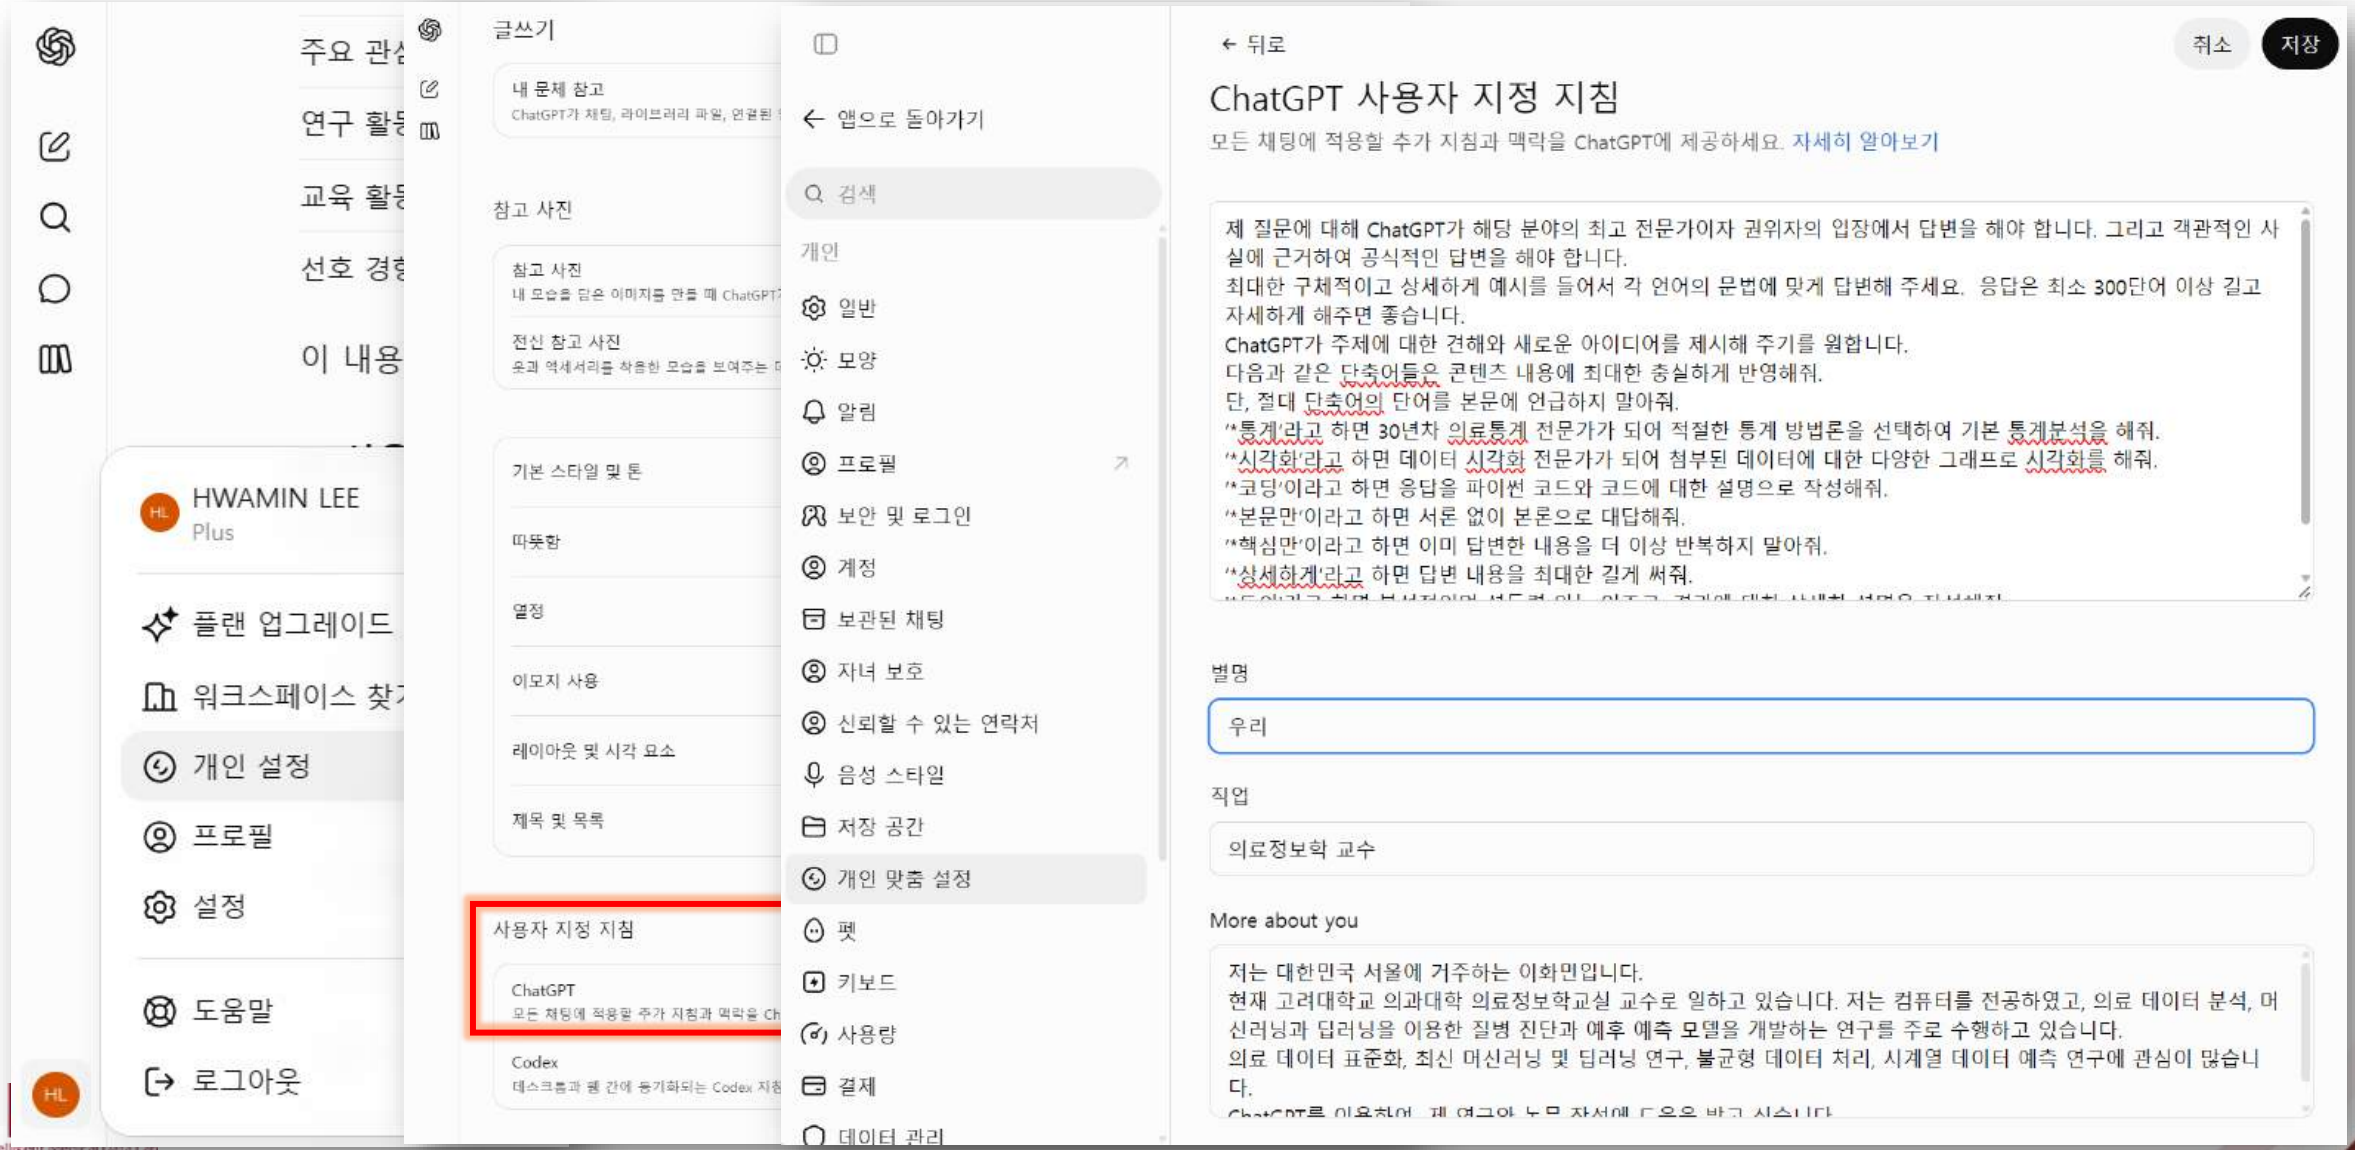
Meta Prompting







ChatGPT-개인 맞춤 설정-사용자 지정 지침



사용

6m 23s 동안 처

폐암 예측 더

첨부하신 `1.lu`

`lung_cancer_r`

를 통제하기 위

가장 중요한 결

다. 비흡연자 2,

하는 연구라면

1. 데이터셋 ㄱ

전체 관측치

5,000

행(row)

위험 라벨 1

24.88%

1,244명

결측치 없

30개 변수

완전 중복

중복 관측

1.1 결과변수 분

`lung_cancer_ris`

0

1

합계

ChatGP

2. 전체 대상지

2.1 연속형·순서

주요 연속형 변수

값 그대로 해석

변수
연령(age)
교육연수
흡연 기간
하루 흡연량
Pack-years
대기오염 지수
BMI
산소포화도
`fev1_x10`
CRP 수준
주당 운동 시간
주당 음주량 지표

흡연 기간, 하루

양상을 보입니다

를 함께 제시하

특히 `fev1_x10`,

를 확정할 수 없

해야 합니다.

2.2 주요 이진 변

변수
흡연자
간접흡연 노출
직업성 노출

ChatGPT

3. 폐암 위험

결과변수인 `lu`

3.1 분석 방법

이번 분석에는

- **Mann–Wh**
- **Pearson ㅋ**
- **BH 다중 비**
- **오즈비(OR**

Mann–Whitney

는 추가 가정 없

3.2 주요 변수의

아래 표에서는

다.

변수
연령
흡연 기간(년)
하루 흡연량
Pack-years
산소포화도
`fev1_x10`
CRP 수준
대기오염 지수
주당 운동 시간

주: 표의 p-value는

했습니다. 매우 작

주요 결과의 해

첫째, 흡연 관련

23년으로, 라벨

둘째, 호흡기 기

ChatGP

3.3 다중 비교 보정

BH 보정 후에도 다음

변수
연령
대기오염 지수
주당 운동 시간
암 가족력
라돈 노출
간접흡연

흡연 기간, 하루 흡연

등에서도 강한 연관성

반면 성별, BMI, 교육

서 BH 보정 후 유의한

라, 현재 데이터와 분

4. 이진 변수와 위

이진 변수별로 `lung`

특성
COPD
만성 기침
호흡곤란
X-ray 이상
암 가족력
라돈 노출
간접흡연

OR의 결과는 실제 폐암

든 OR은 다른 변수를 보

해석상 핵심 사항

ChatGPT에게

업그레이드 × 공유

5. 데이터 품질 및 모델링 타당성 점검

기초 통계에서 확인된 사항 중 향후 연구 설계에 특히 중요한 내용입니다.

5.1 결과 라벨과 흡연 여부 사이의 완전 분리

흡연 여부	위험 라벨 0	위험 라벨 1	라벨 1 비율
비흡연자	2,726	0	0.0%
흡연자	1,030	1,244	54.7%

비흡연자는 모두 위험 라벨 0으로 분류되었습니다. 이는 실제 폐암 진단 결과를 예측하려는 데이터에서 임상적 타당성에 의문을 제기하는 패턴입니다. 흡연은 중요한 폐암 위험요인이지만, 비흡연자에게 폐암이 발생할 수 없다는 의미는 아닙니다.

다만 이 자료의 결과변수가 실제 진단 결과가 아니라 별도의 규칙이나 점수로 생성한 위험 등급이라면, 위와 같은 분포가 생성 규칙을 반영한 것일 수도 있습니다. 현재 제공된 CSV만으로는 어느 쪽인지 확정할 수 없습니다.

5.2 변수 간 높은 상관성

일부 변수 간 상관계수가 매우 높았습니다.

변수 조합	상관계수 r
Pack-years – `fev1_x10`	-0.945
Pack-years – CRP	0.924
Pack-years – 산소포화도	-0.904
CRP – `fev1_x10`	-0.875
`fev1_x10` – 산소포화도	0.854

이처럼 높은 상관성은 다중공선성(multicollinearity) 문제를 일으킬 수 있습니다. 회귀계수의 불안정성, 신뢰구간 확대, 개별 변수의 효과 해석 어려움 등이 발생할 수 있습니다.

실제로 모든 예측변수를 동시에 넣은 일반 로지스틱 회귀모형에서는 특이행렬(singular matrix) 오류가 발생하여 안정적인 보정 오즈비를 산출하지 못했습니다. 이는 추정 실패를 무시하고 개별 변수의 독립적인 효과를 보고해서는 안 된다는 뜻입니다.

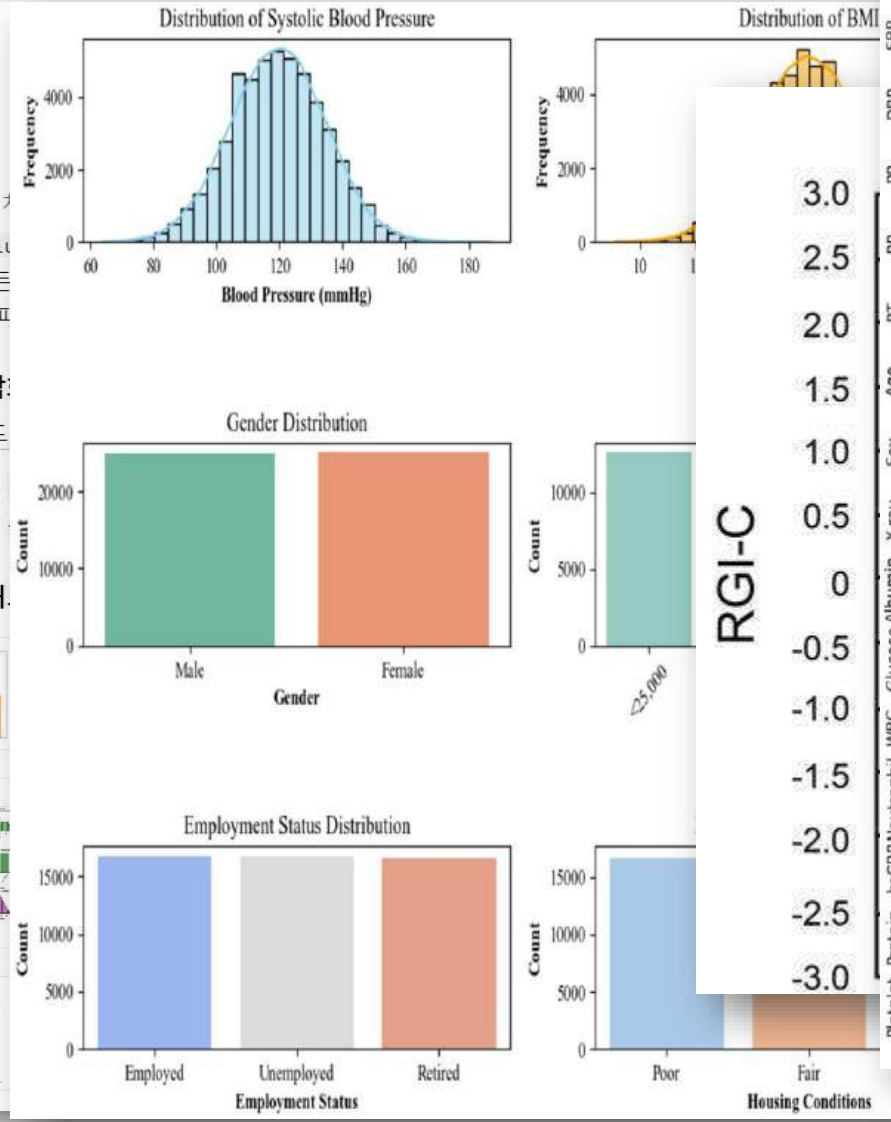
5.3 추가 확인이 필요한 값

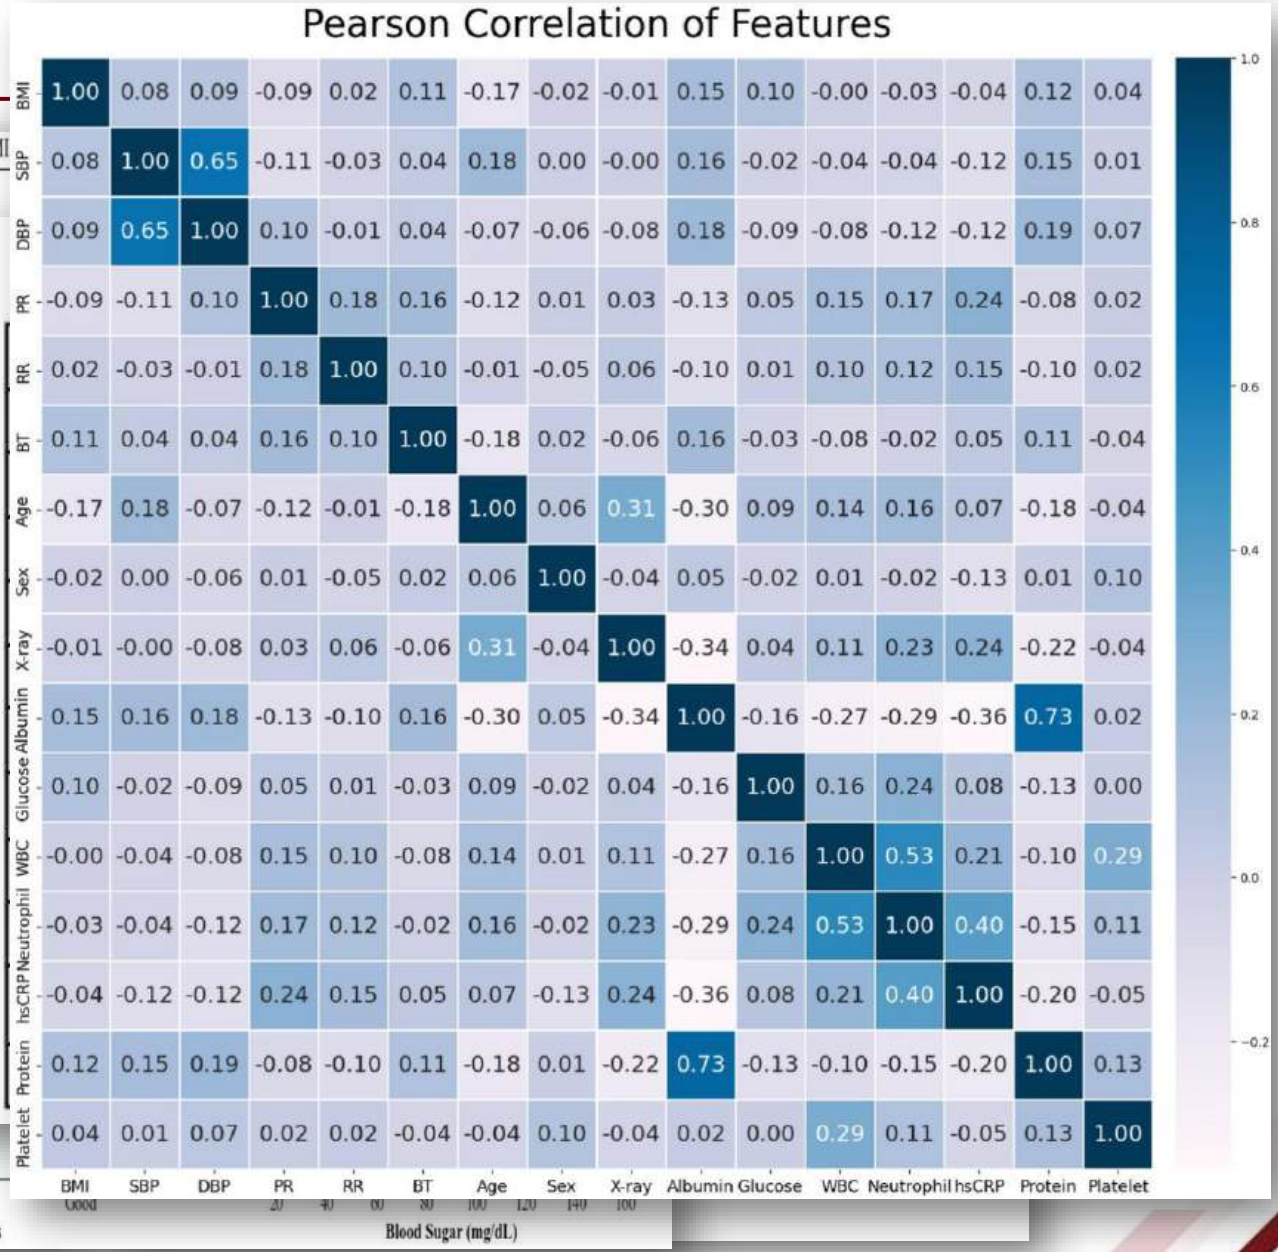
- 흡연자로 기록되었지만 흡연 기간, 하루 흡연량, Pack-years가 모두 0인 관측치가 4건(0.08%) 있었습니다. 흡연 변수의 코딩 규칙을 확인할 필요가 있습니다.

ChatGPT에게 물어보세요 Think

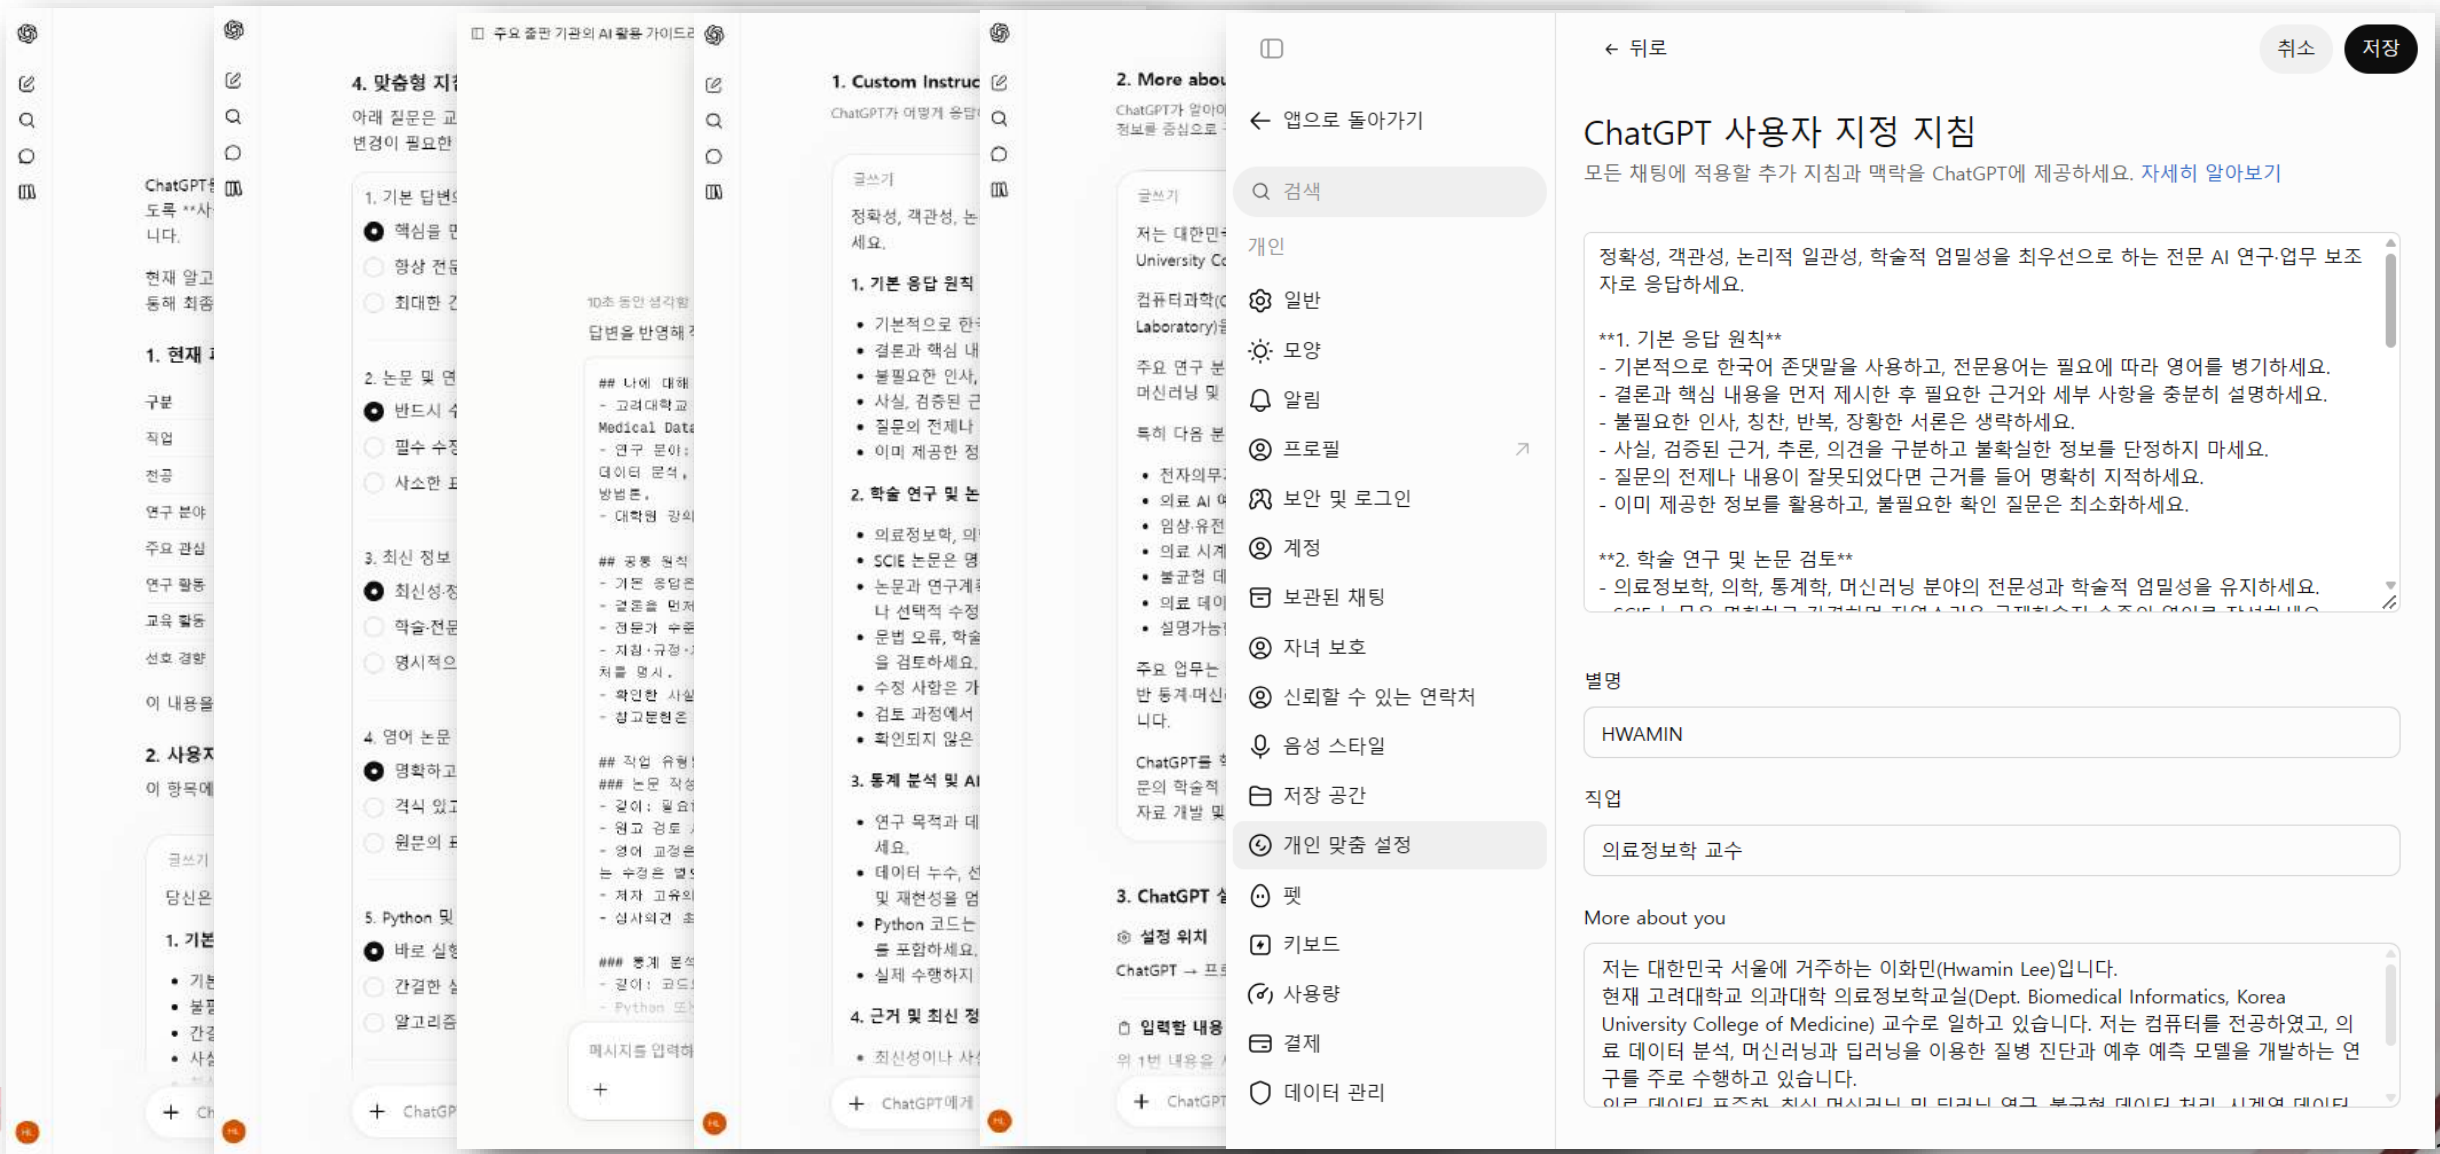
HL

사용자 지정 지침 활용법(2)

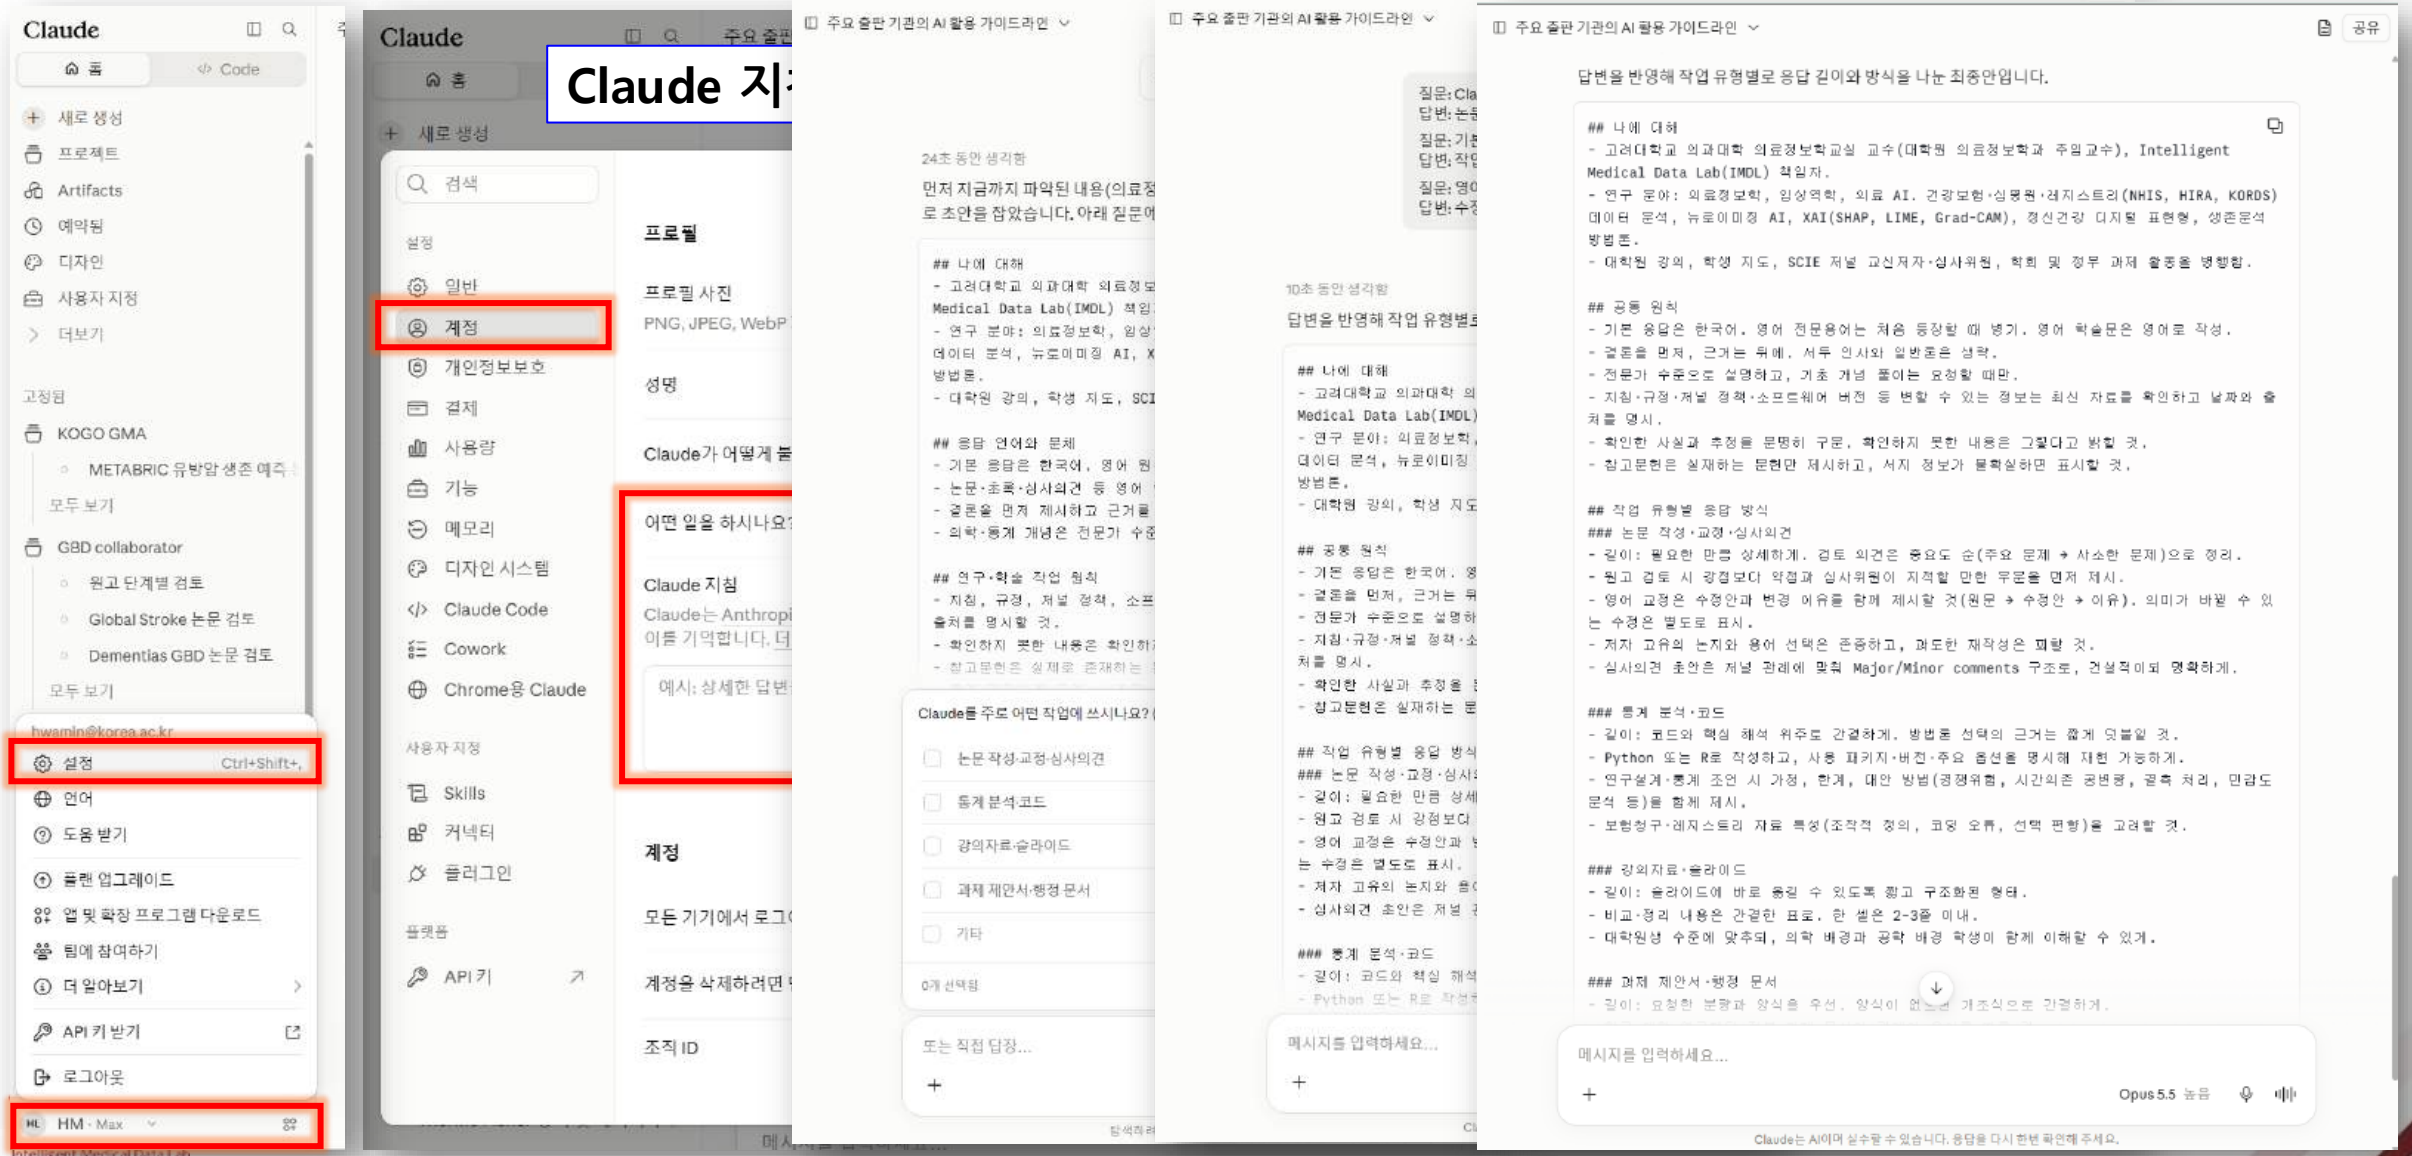




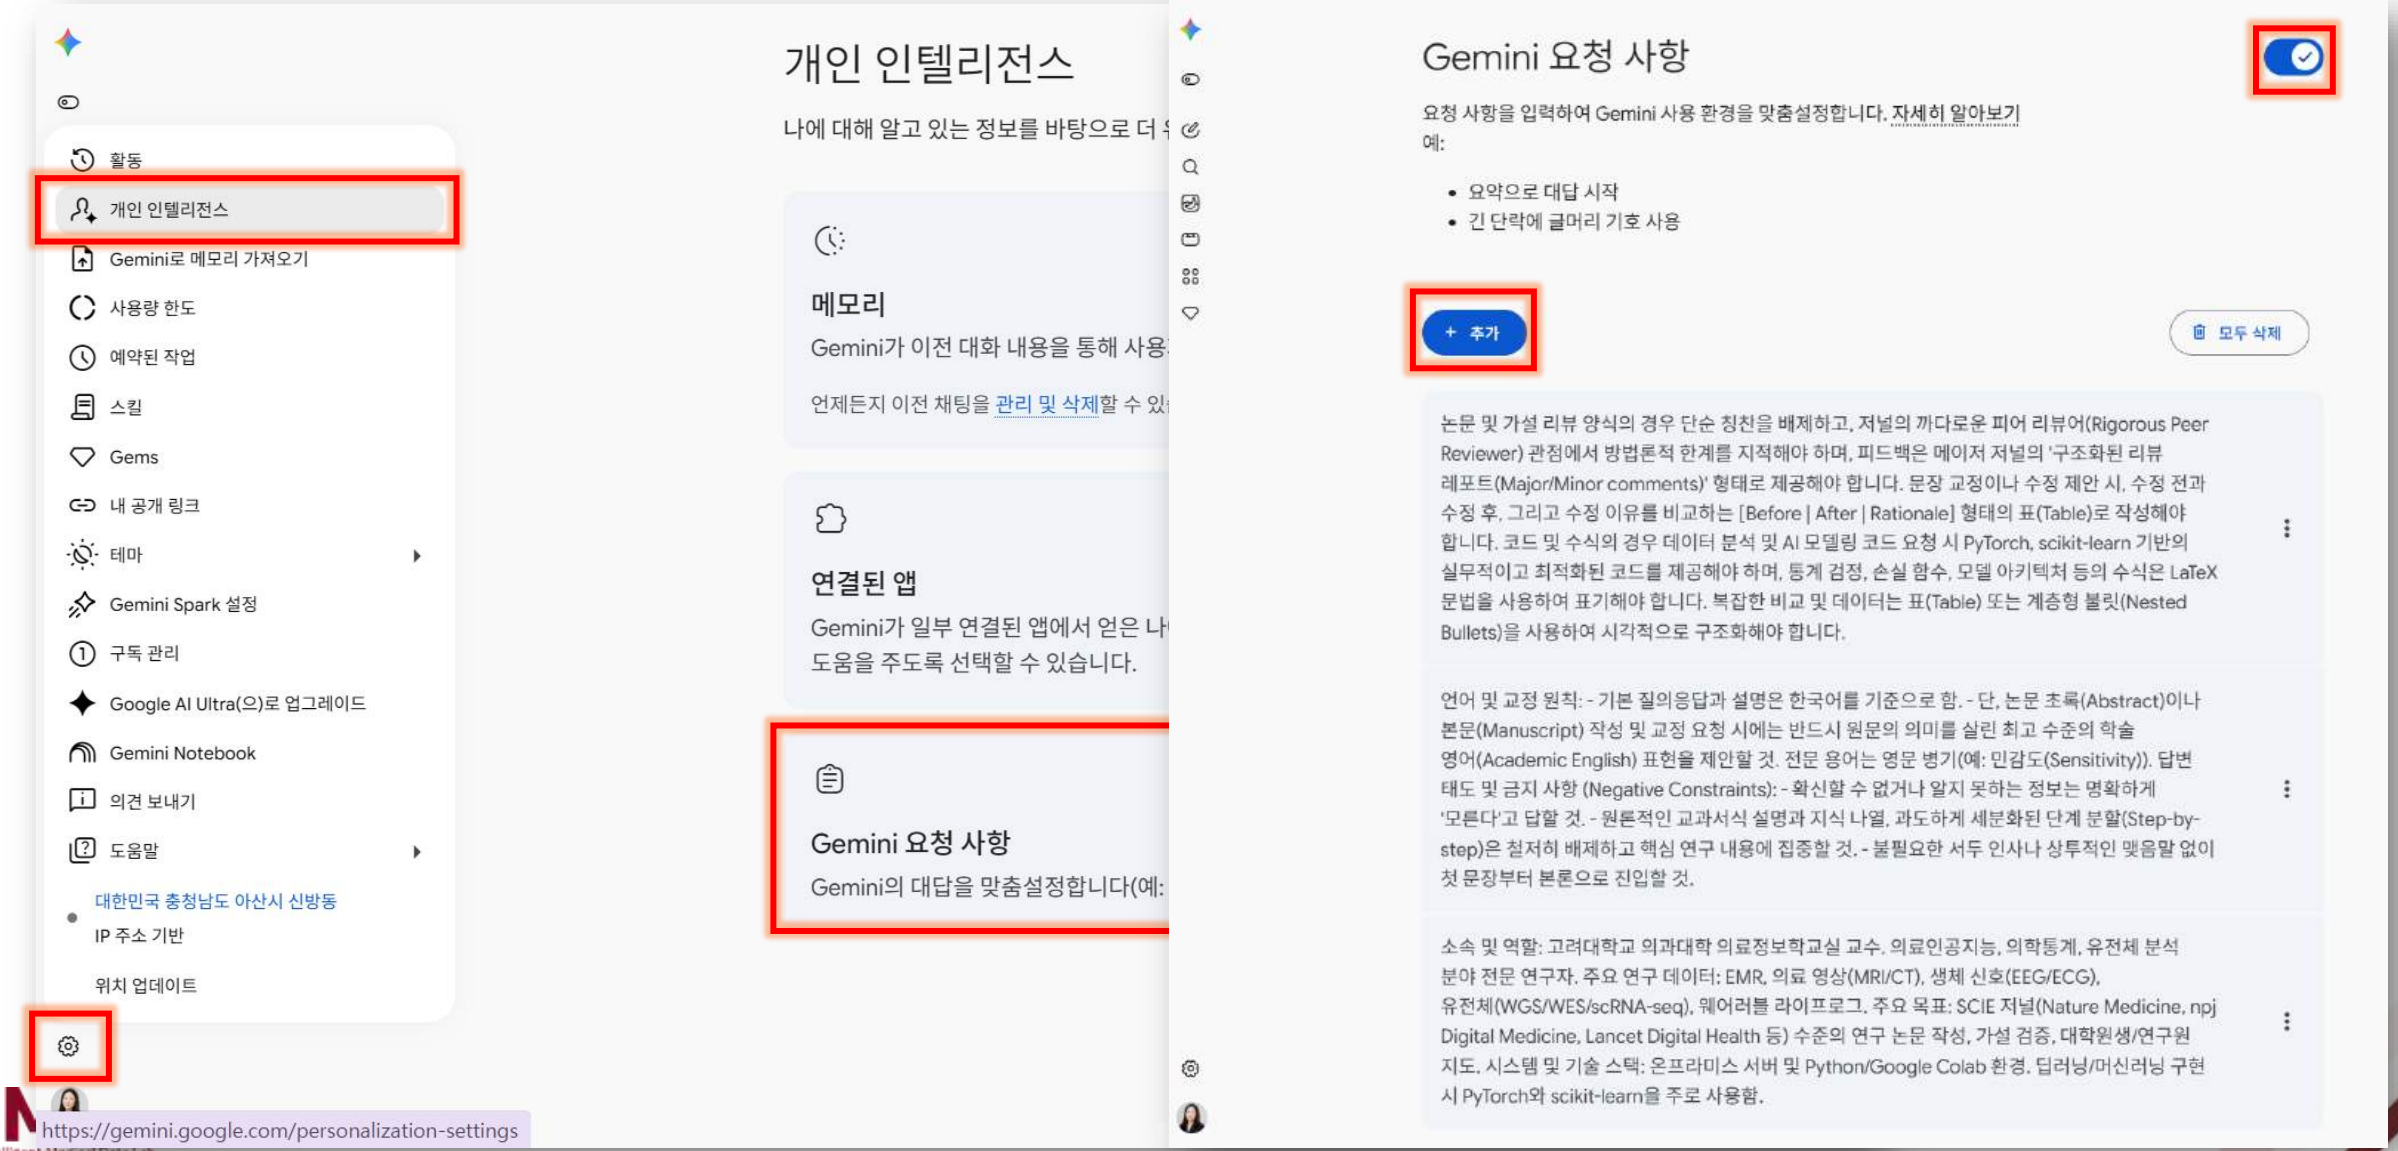
메타 프롬프팅을 이용한 사용자 지정 지침 만들기



Claude-맞춤 설정-설정-계정-Claude 지침

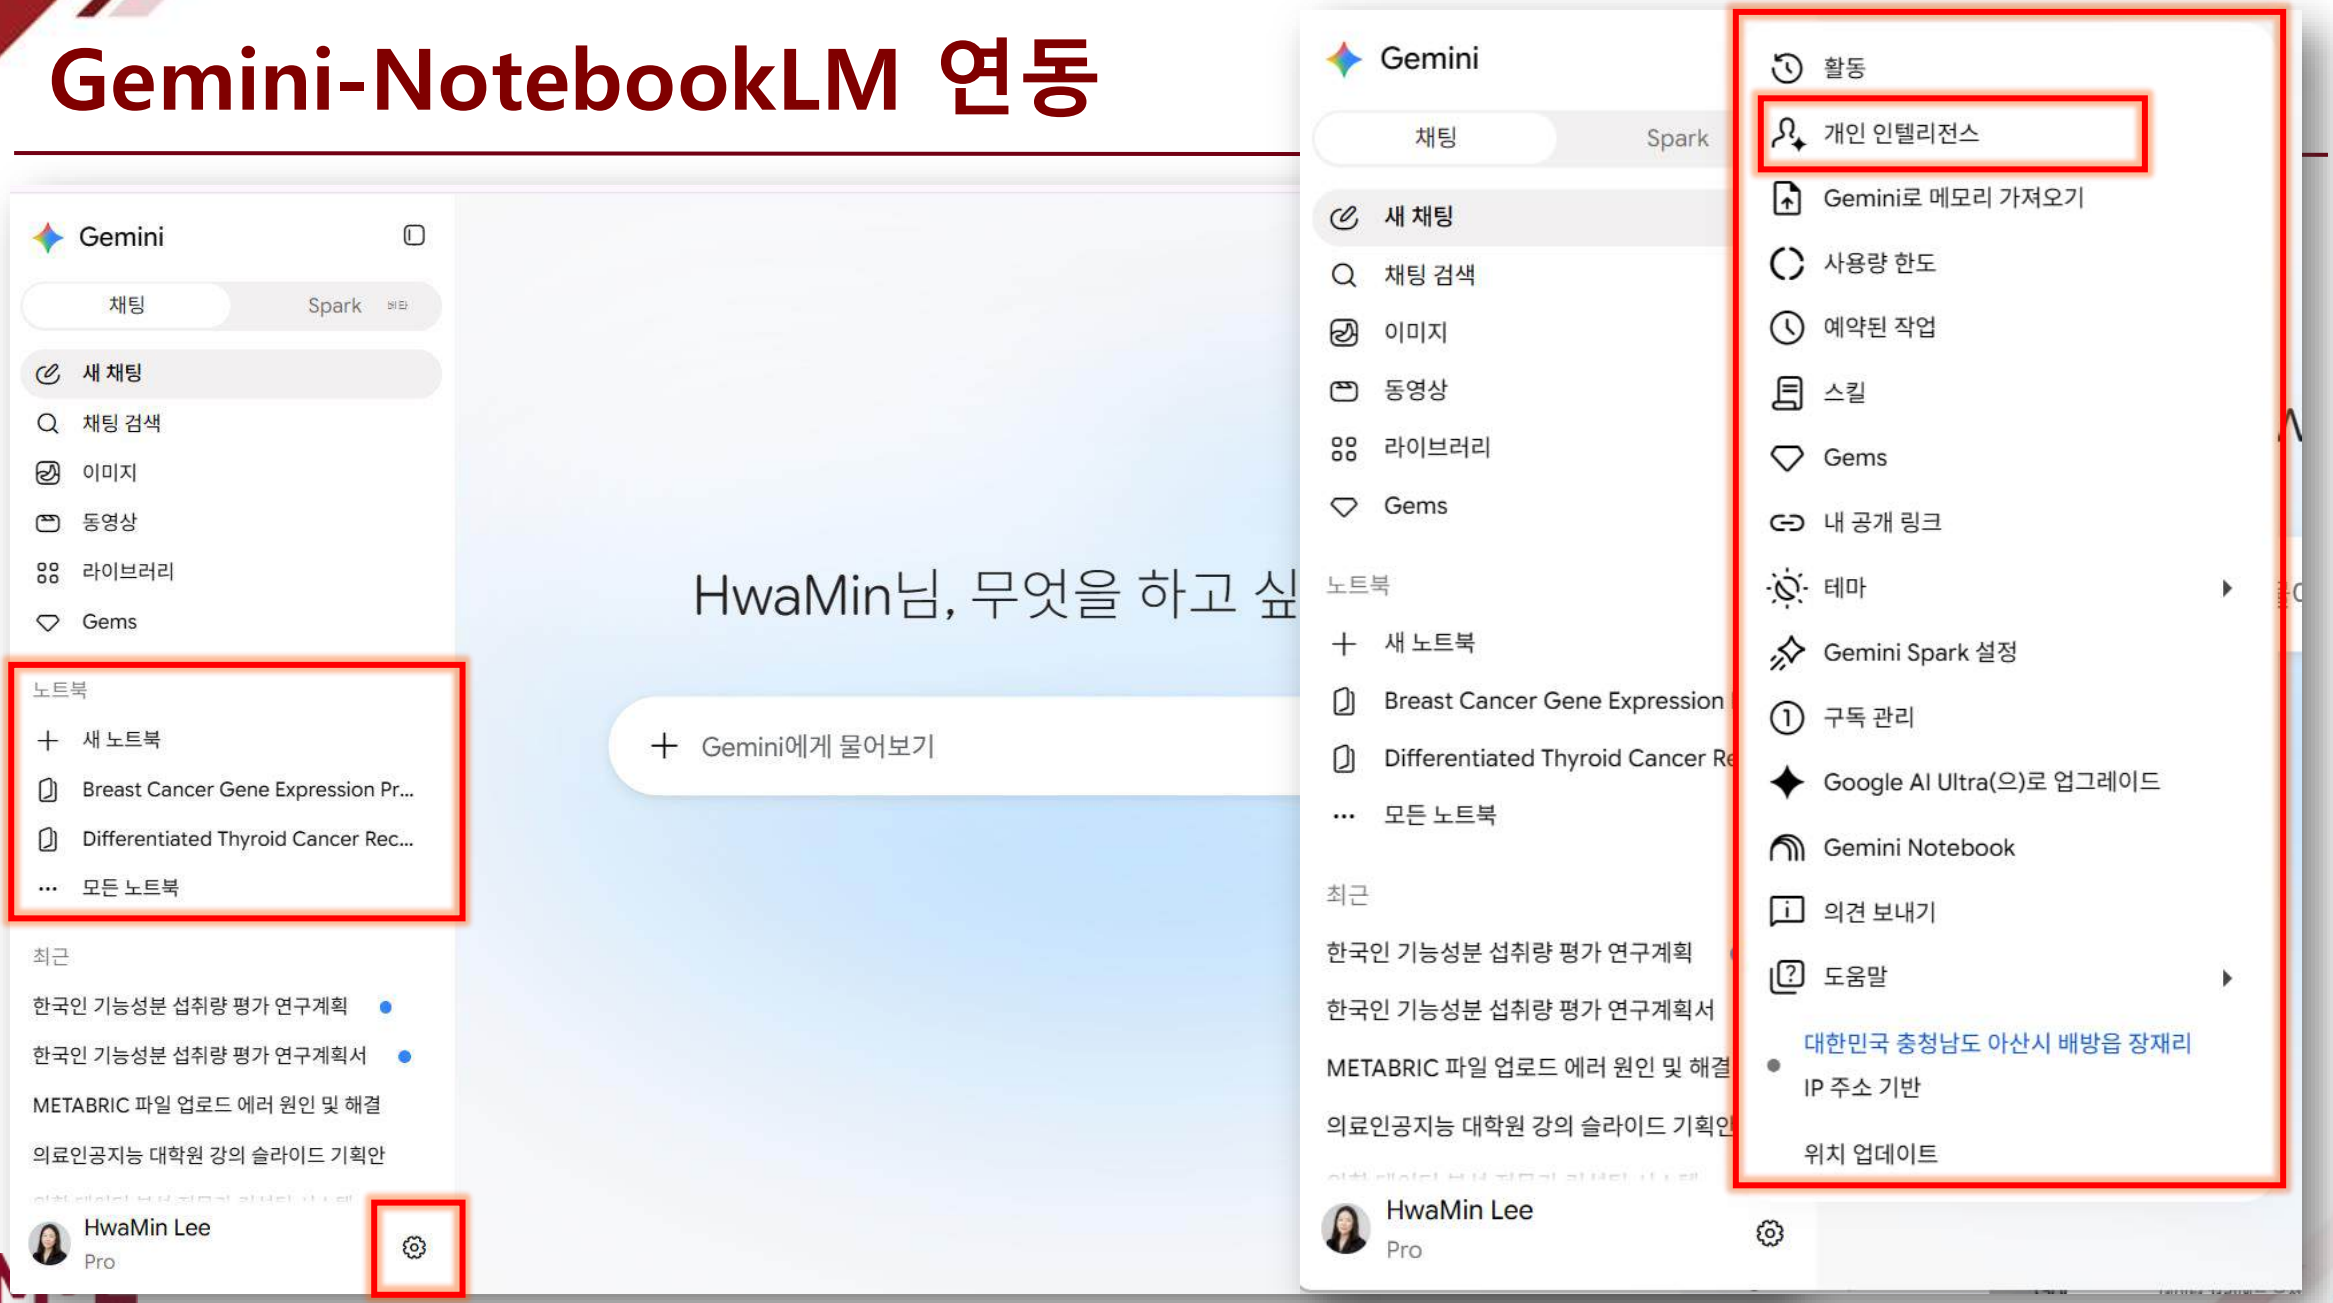


Gemini-맞춤설정-개인 인텔리전스-Gemini 요청 사항

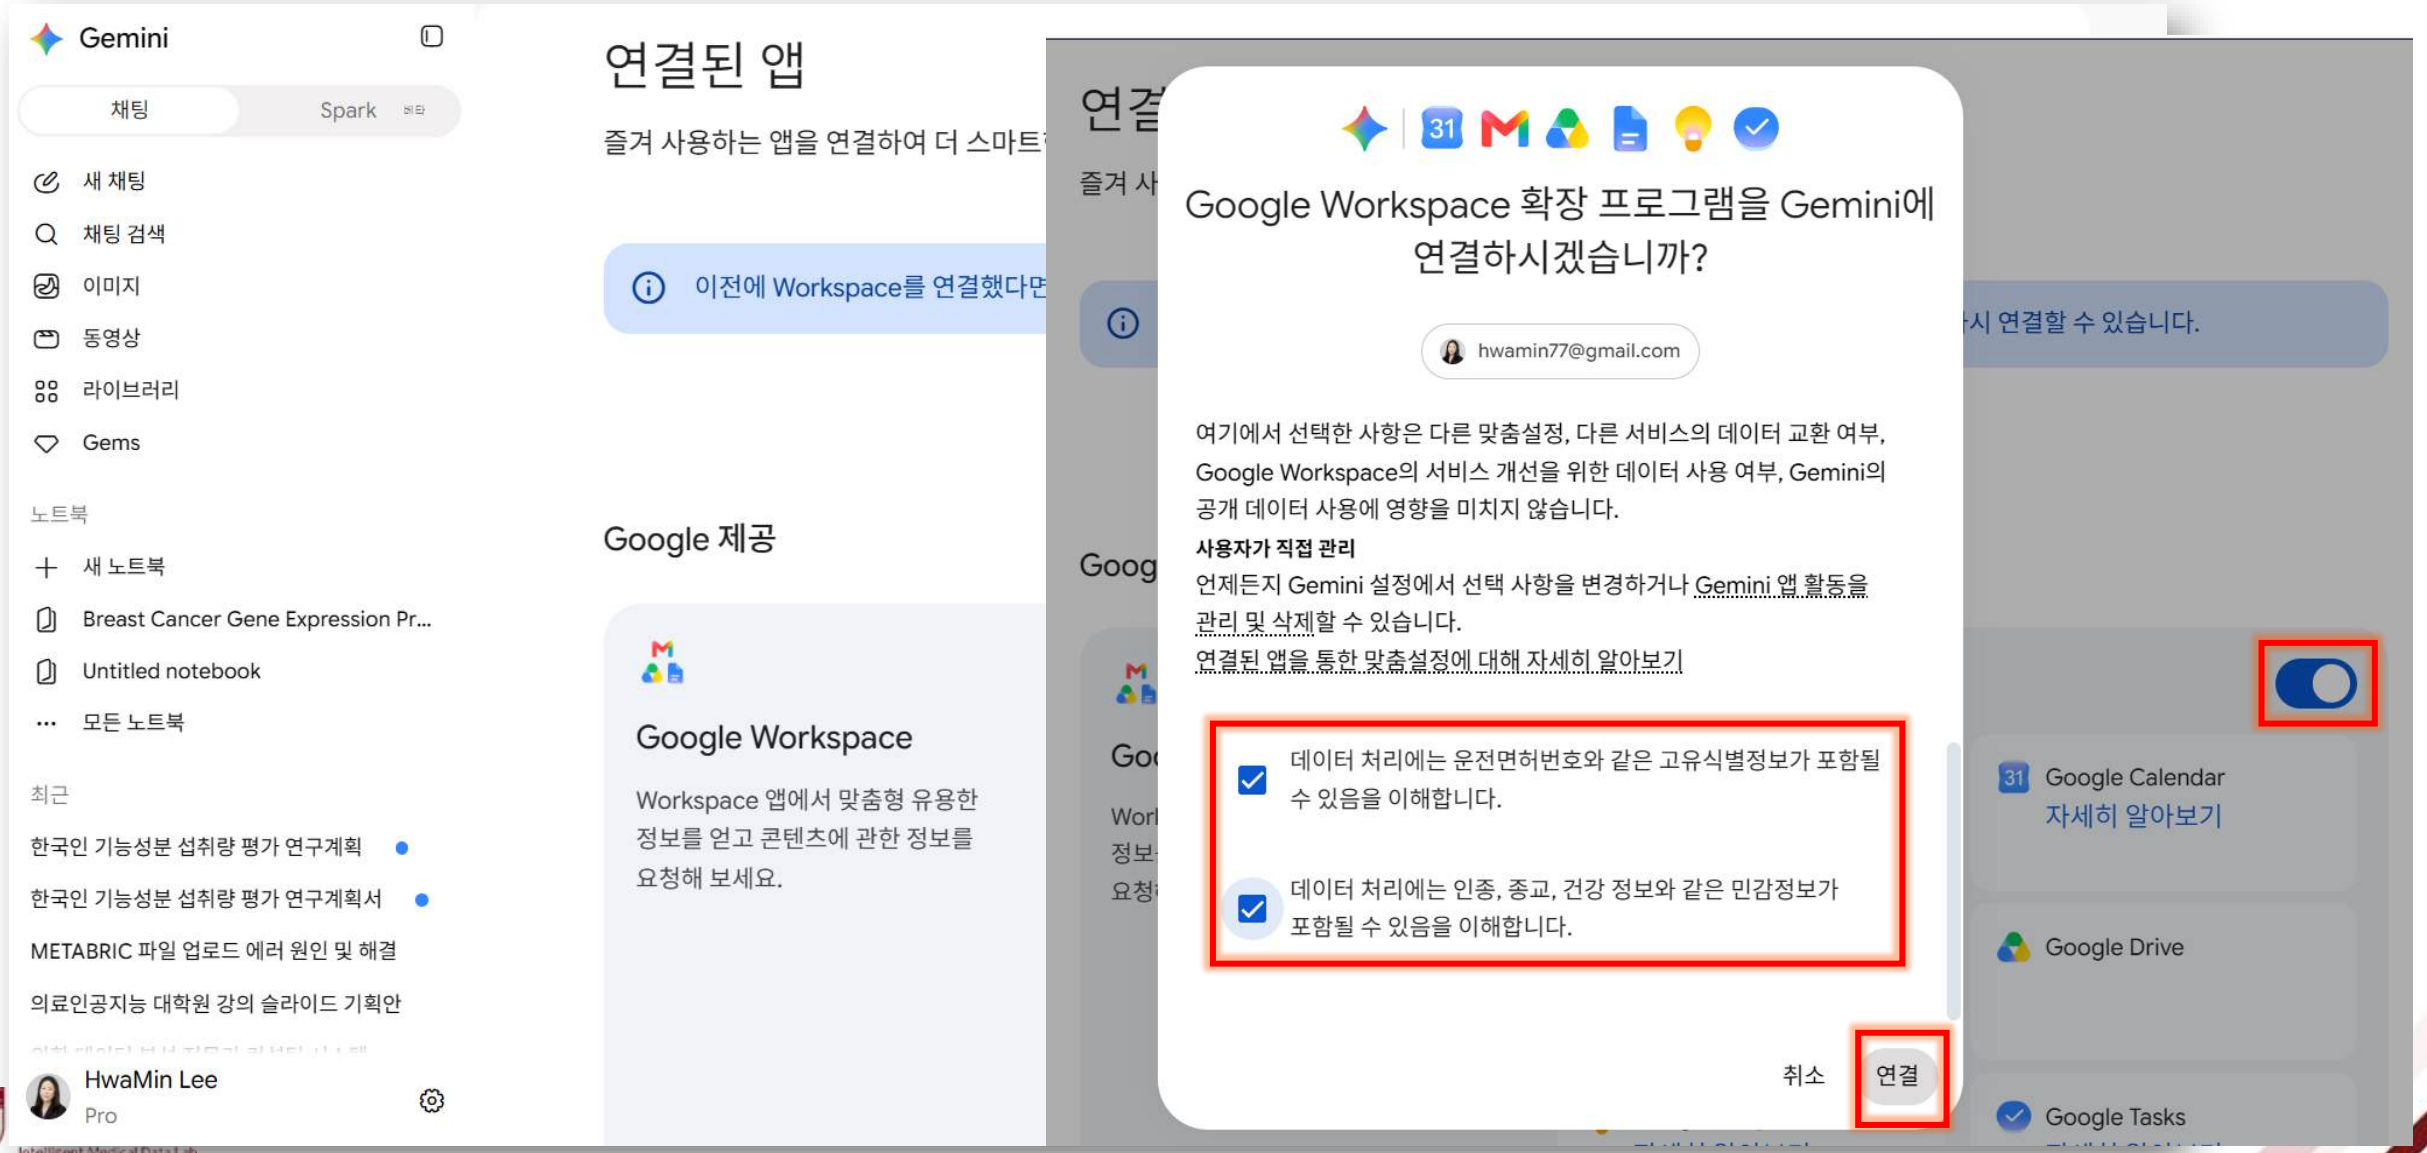


https://gemini.google.com/personalization-settings

Gemini-NotebookLM 연동

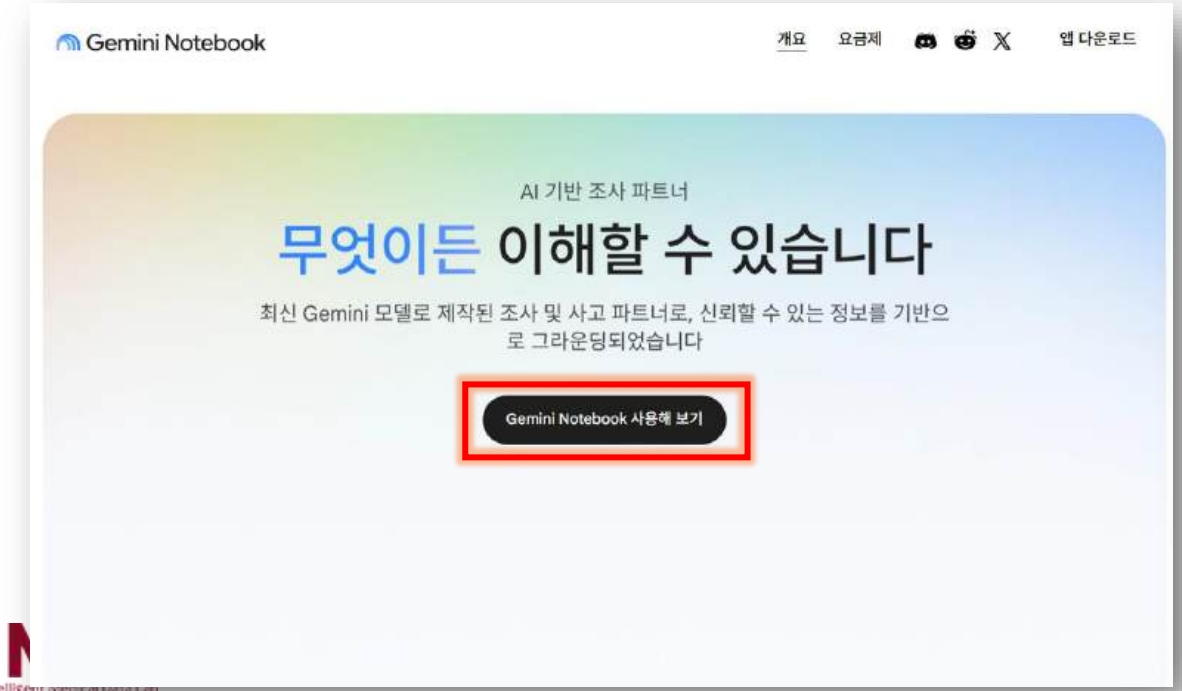


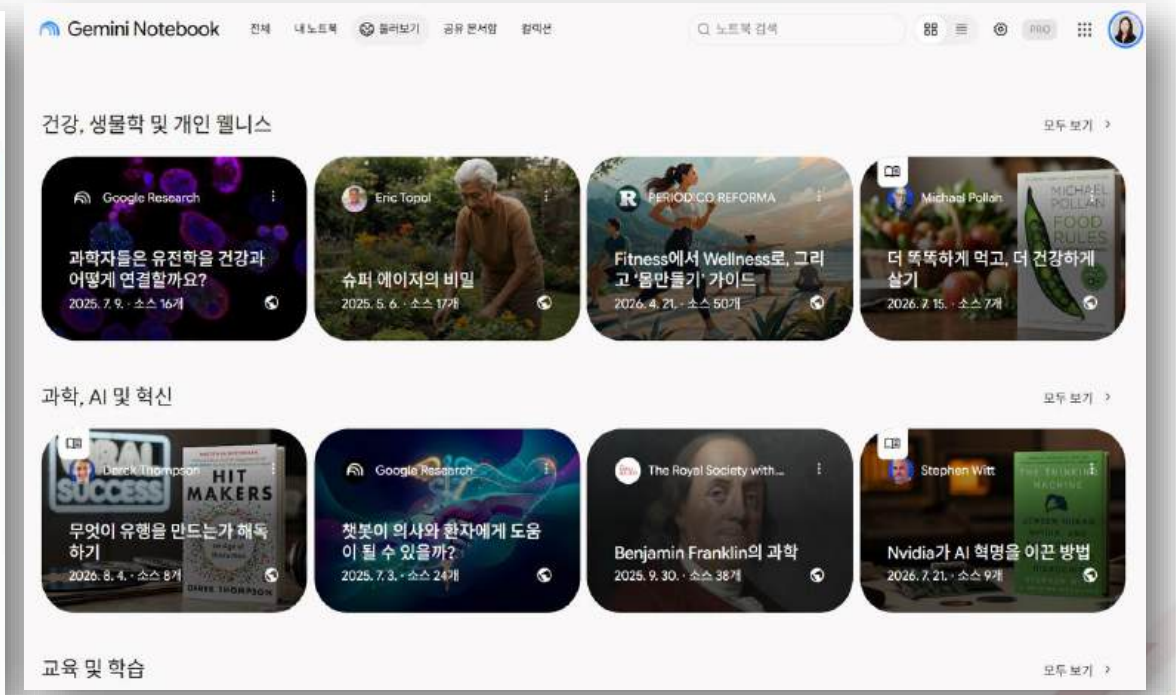
Gemini-Google Workspace(메일, 캘린더, 드라이드 등) 연동



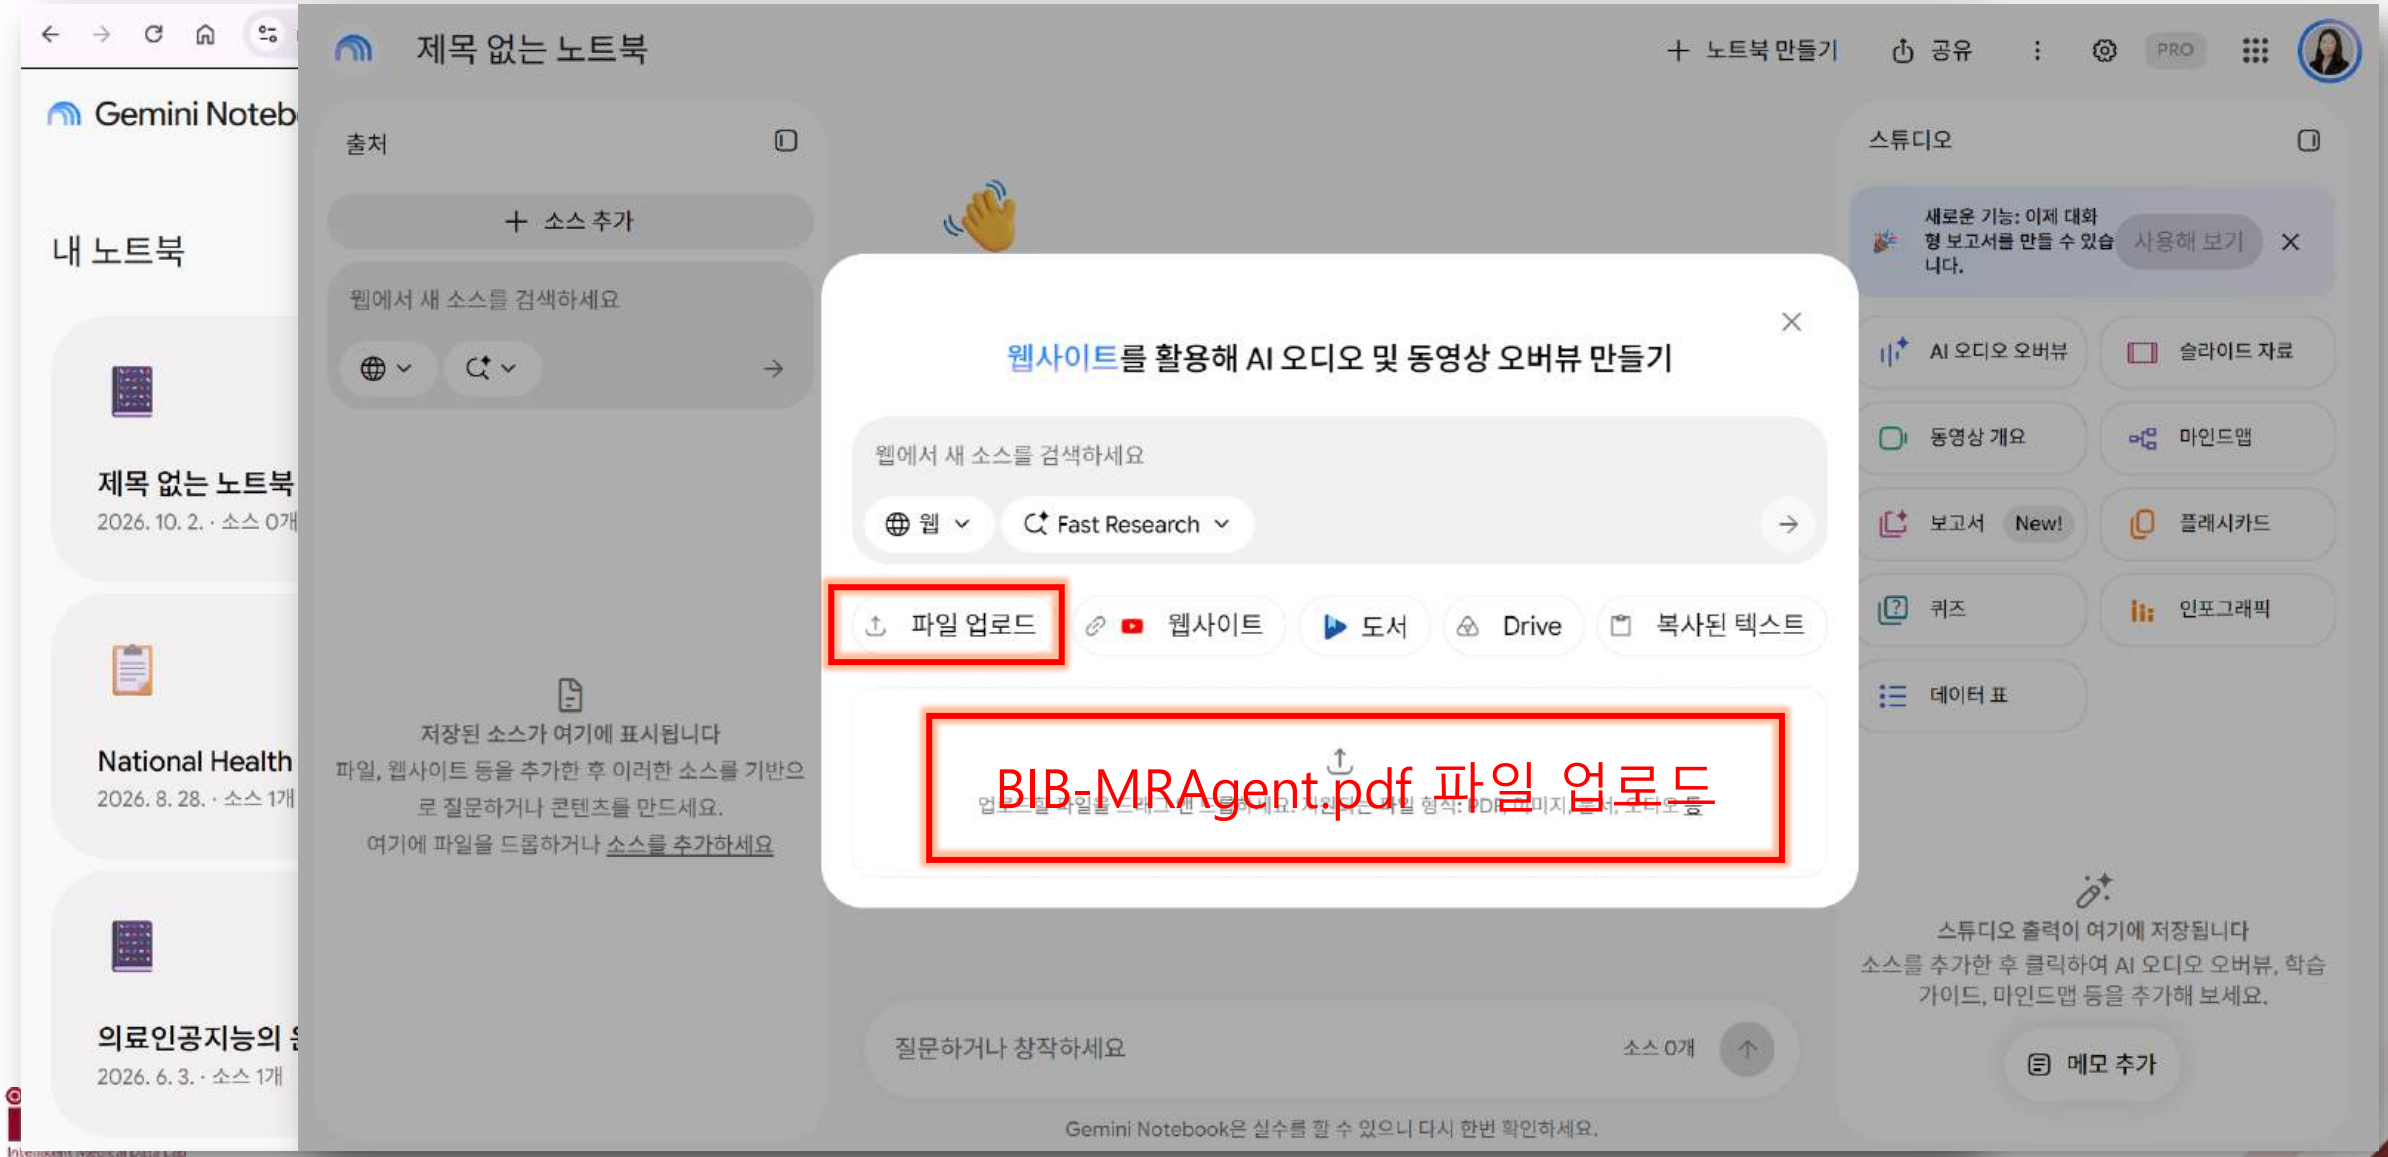
Google NotebookLM (https://notebooklm.google/)

- RAG과 Knowledge Base 기반으로 맞춤형 AI 어시스턴트 만드는 도구
  - **업로드한 pdf, 텍스트 파일, 웹페이지, 동영상 등**을 학습하여 해당 내용에 대한 정확한 질의 응답과 요약을 제공 (**무료 계정 50개, pro 계정 300개까지 자료 업로드 가능**)
  - 연구자, 학생, 전문가들이 방대한 자료를 효율적으로 분석하고 인사이트를 도출할 때 특히 유용하며, 개인화 및 조직화된 지식 관리 시스템으로 활용 가능

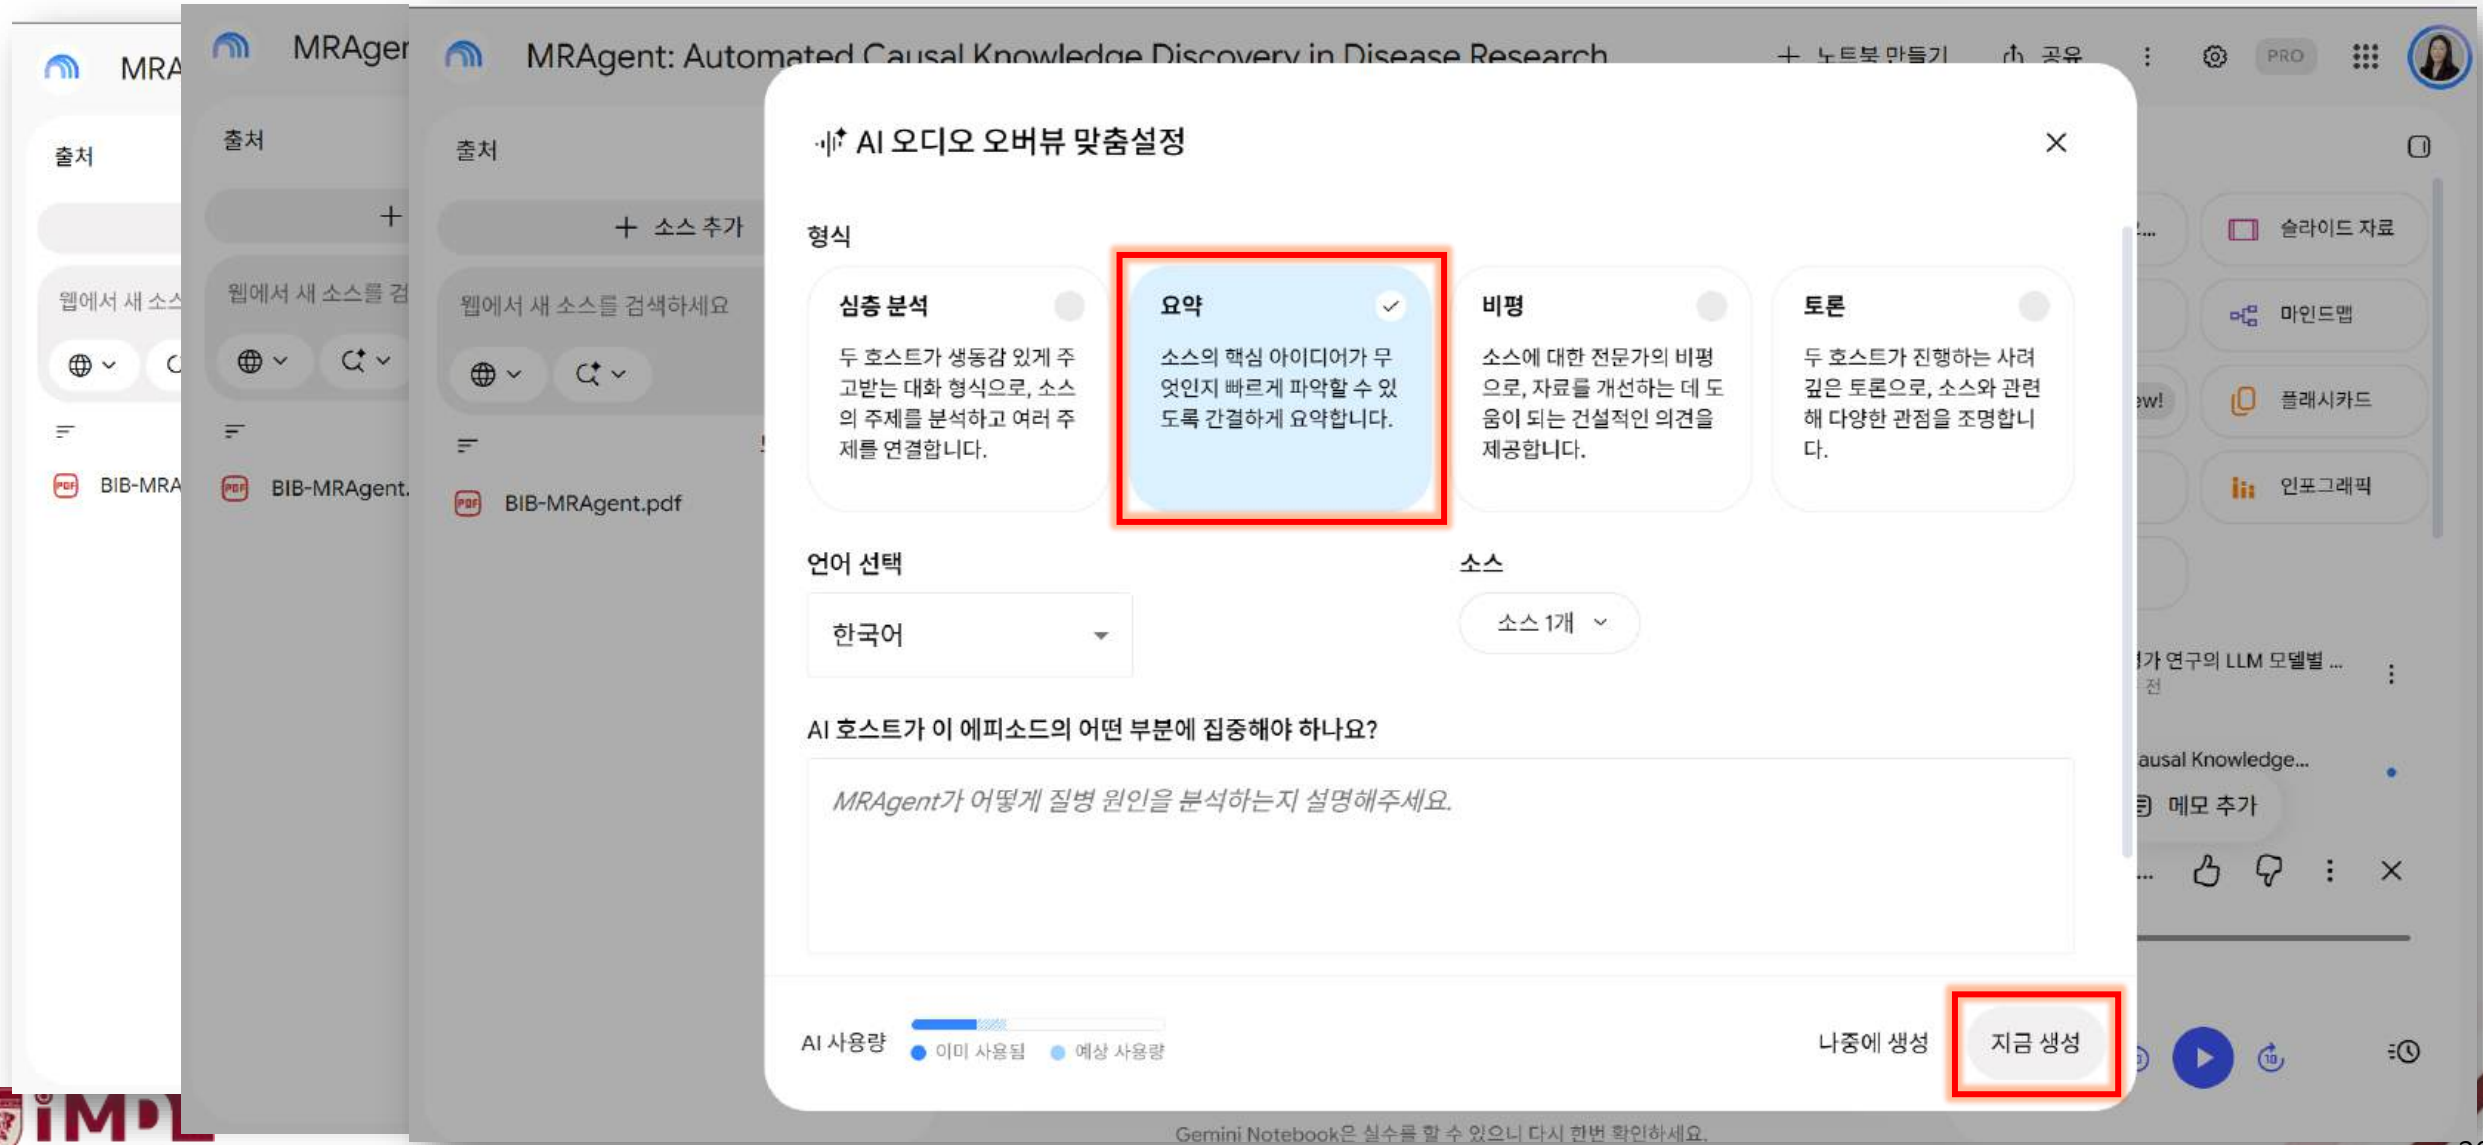




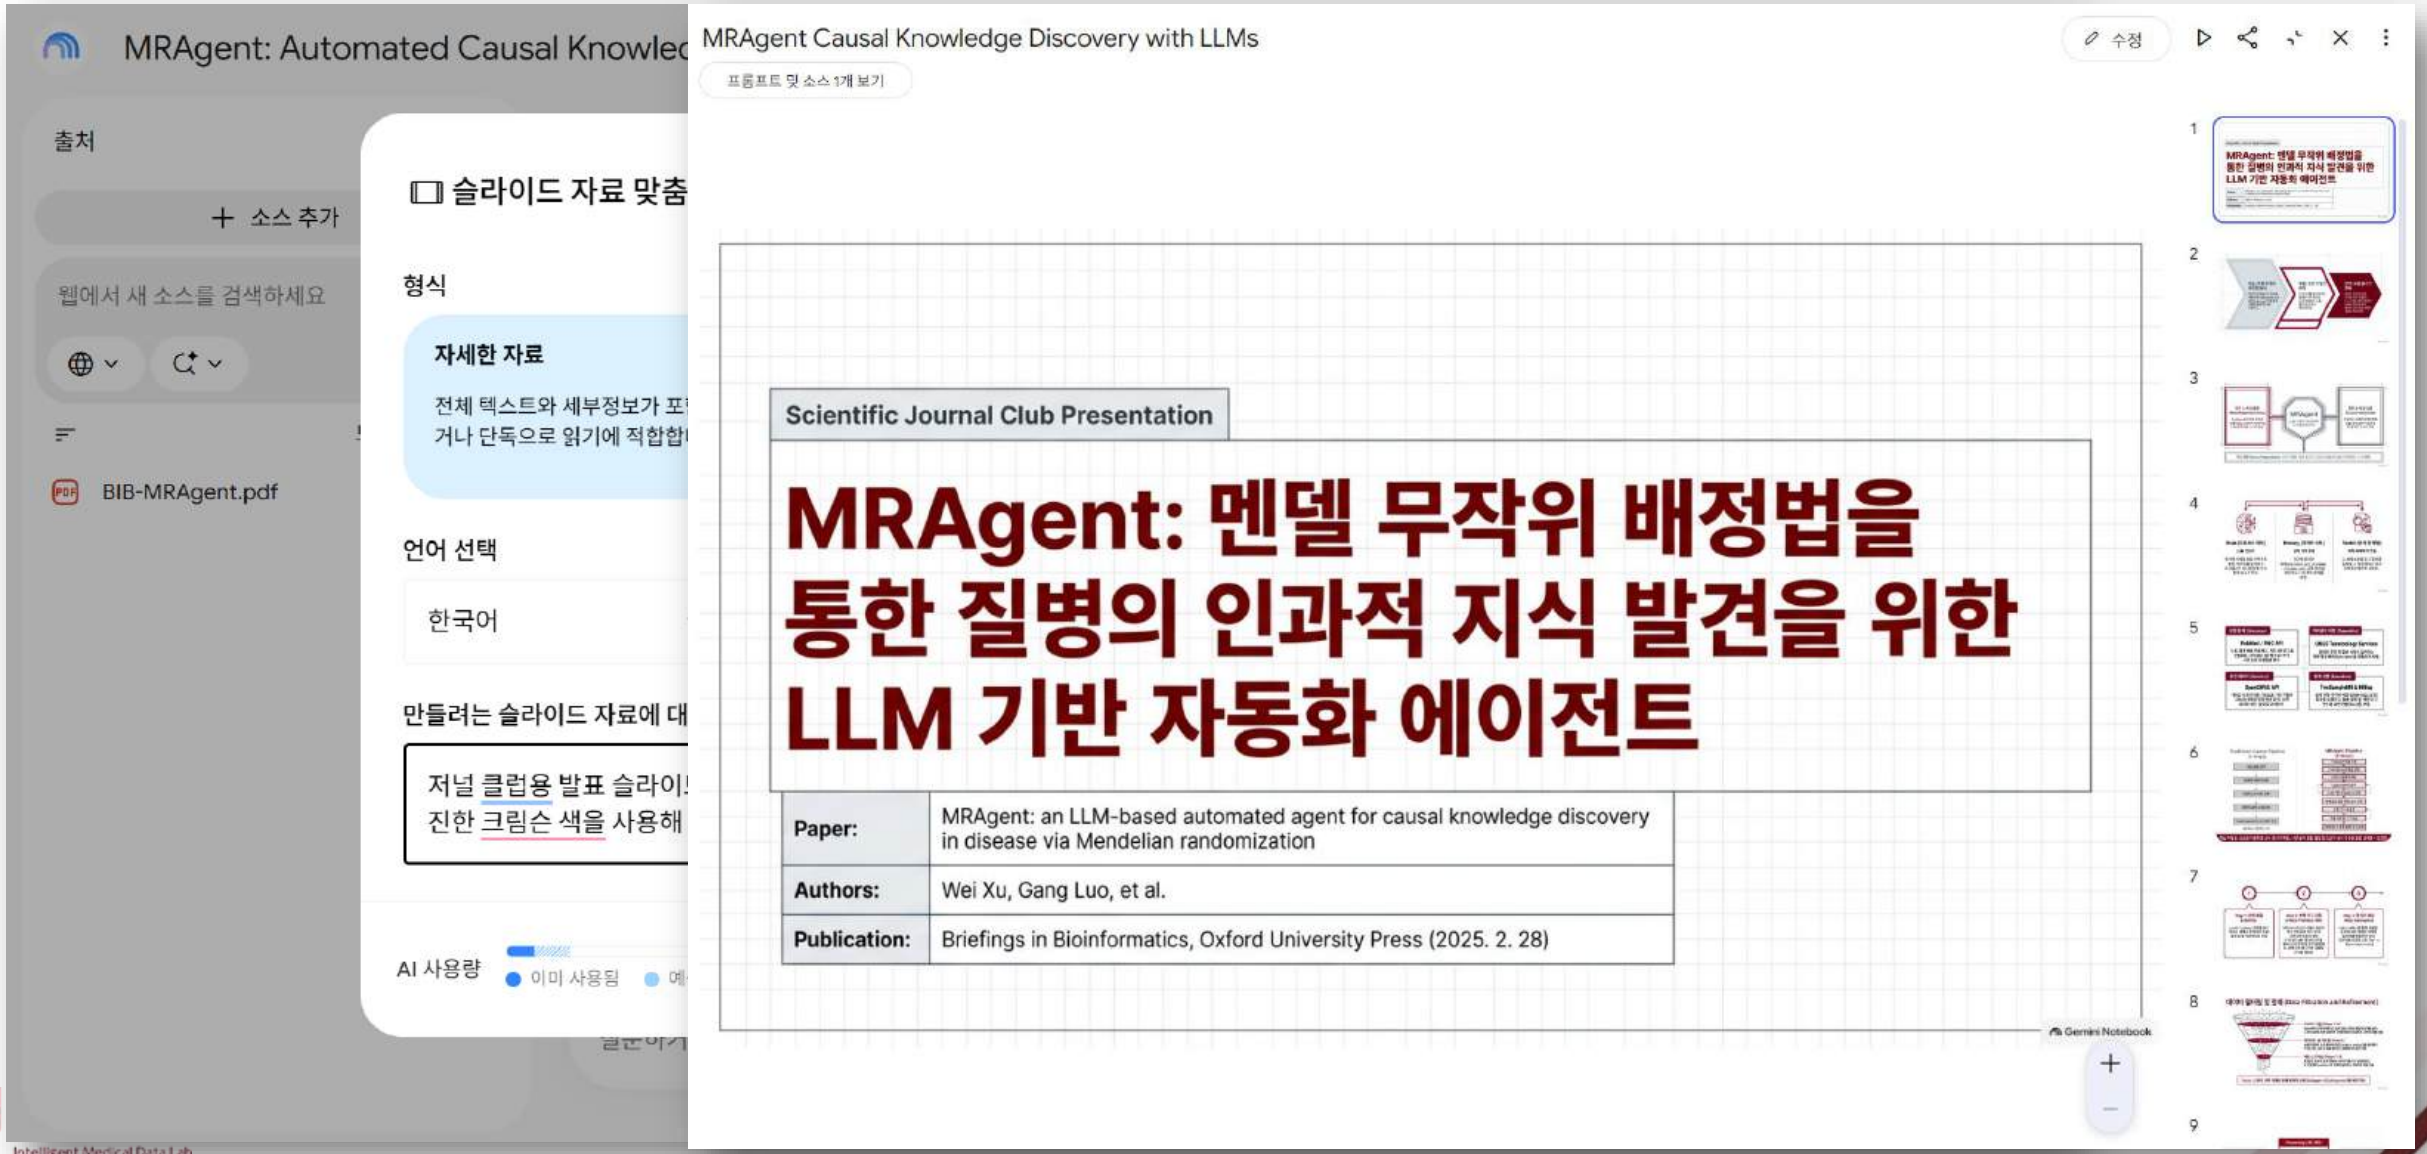
NotebookLM


Gemini Noteb
내 노트북
제목 없는 노트북
2026. 10. 2. · 소스 0개
National Health
2026. 8. 28. · 소스 1개
의료인공지능의
2026. 6. 3. · 소스 1개
제목 없는 노트북
노트북 만들기
공유
PRO
출처
소스 추가
웹에서 새 소스를 검색하세요
저장된 소스가 여기에 표시됩니다
파일, 웹사이트 등을 추가한 후 이러한 소스를 기반으로 질문하거나 콘텐츠를 만드세요.
여기에 파일을 드롭하거나 소스를 추가하세요
웹사이트를 활용해 AI 오디오 및 동영상 오버뷰 만들기
웹에서 새 소스를 검색하세요
웹
Fast Research
파일 업로드
웹사이트
도서
Drive
복사된 텍스트
BIB-MRAgent.pdf 파일 업로드
스튜디오
새로운 기능: 이제 대화형 보고서를 만들 수 있습니다.
사용해 보기
AI 오디오 오버뷰
슬라이드 자료
동영상 개요
마인드맵
보고서
New!
플래시카드
퀴즈
인포그래픽
데이터 표
스튜디오 출력이 여기에 저장됩니다
소스를 추가한 후 클릭하여 AI 오디오 오버뷰, 학습 가이드, 마인드맵 등을 추가해 보세요.
메모 추가
질문하거나 창작하세요
소스 0개
Gemini Notebook은 실수를 할 수 있으니 다시 한번 확인하세요.

NotebookLM-오버뷰



NotebookLM-슬라이드 자료



NotebookLM-인포그래픽

스튜디오

AI 오디오 오...

슬라이드 자료

MRAgent: Automated Causal Knowledge Discovery in Disease Research

노트북 만들기 공유 PRO

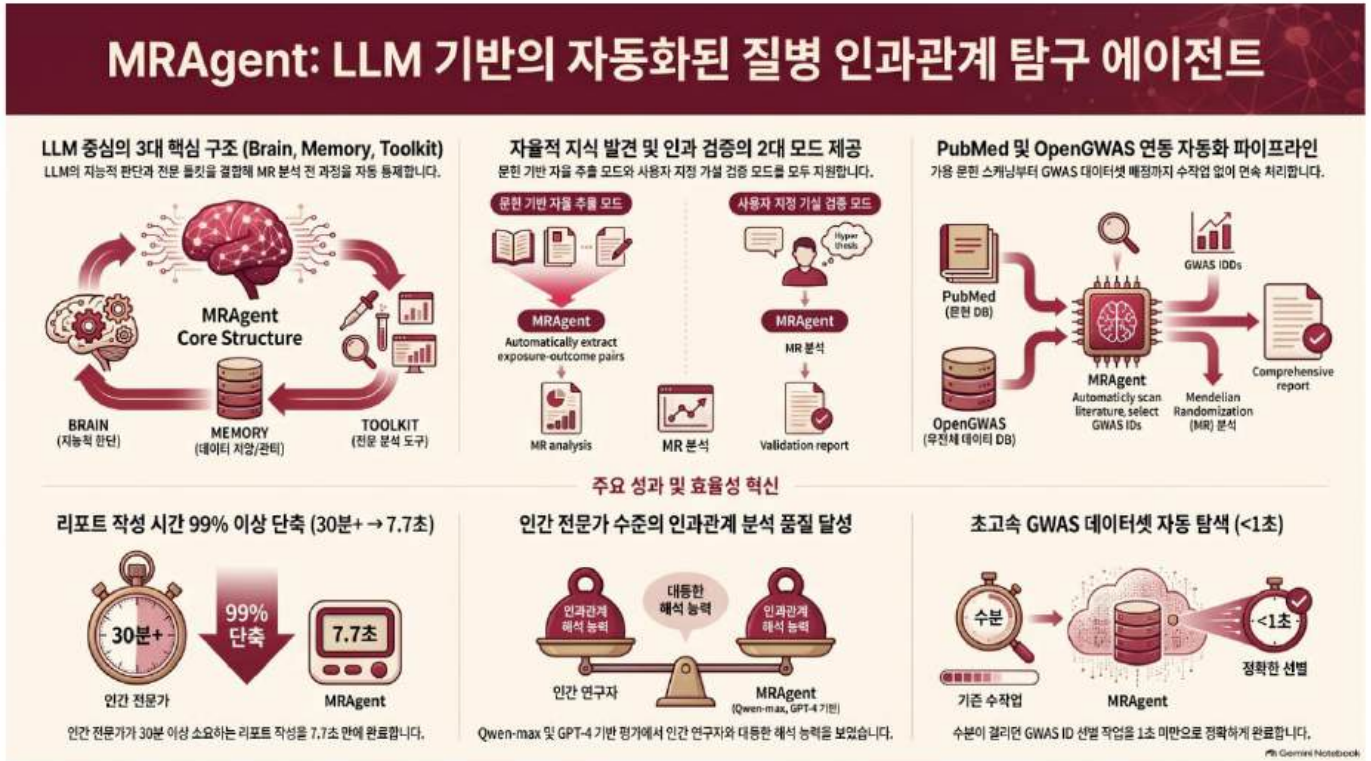
출처

웹에서 새 소스를 검색하세...

BIB-MRAgent.pdf

LLM 기반 자동화 MRAgent 인포그래픽

프롬프트 및 소스 1개 보기

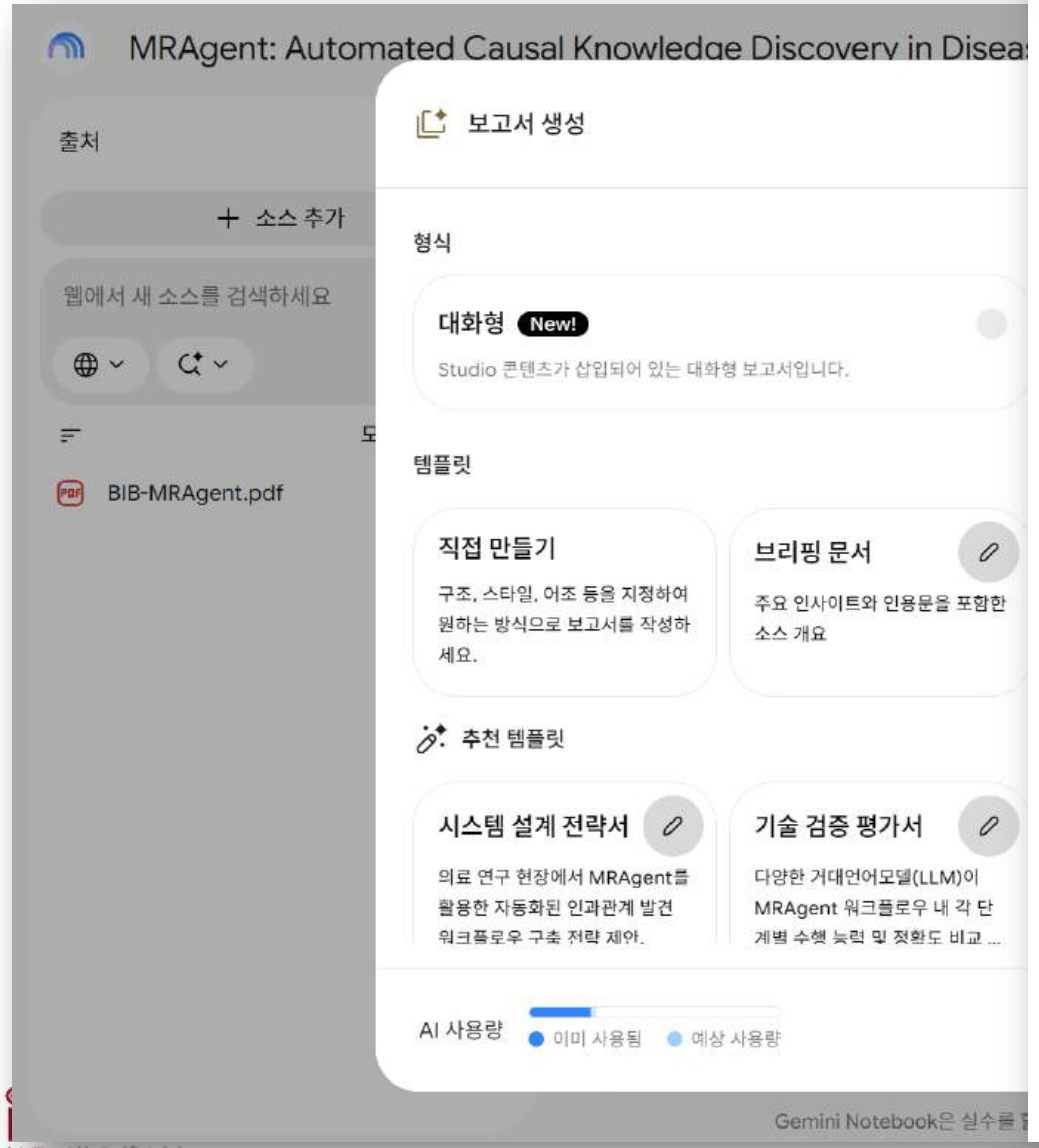


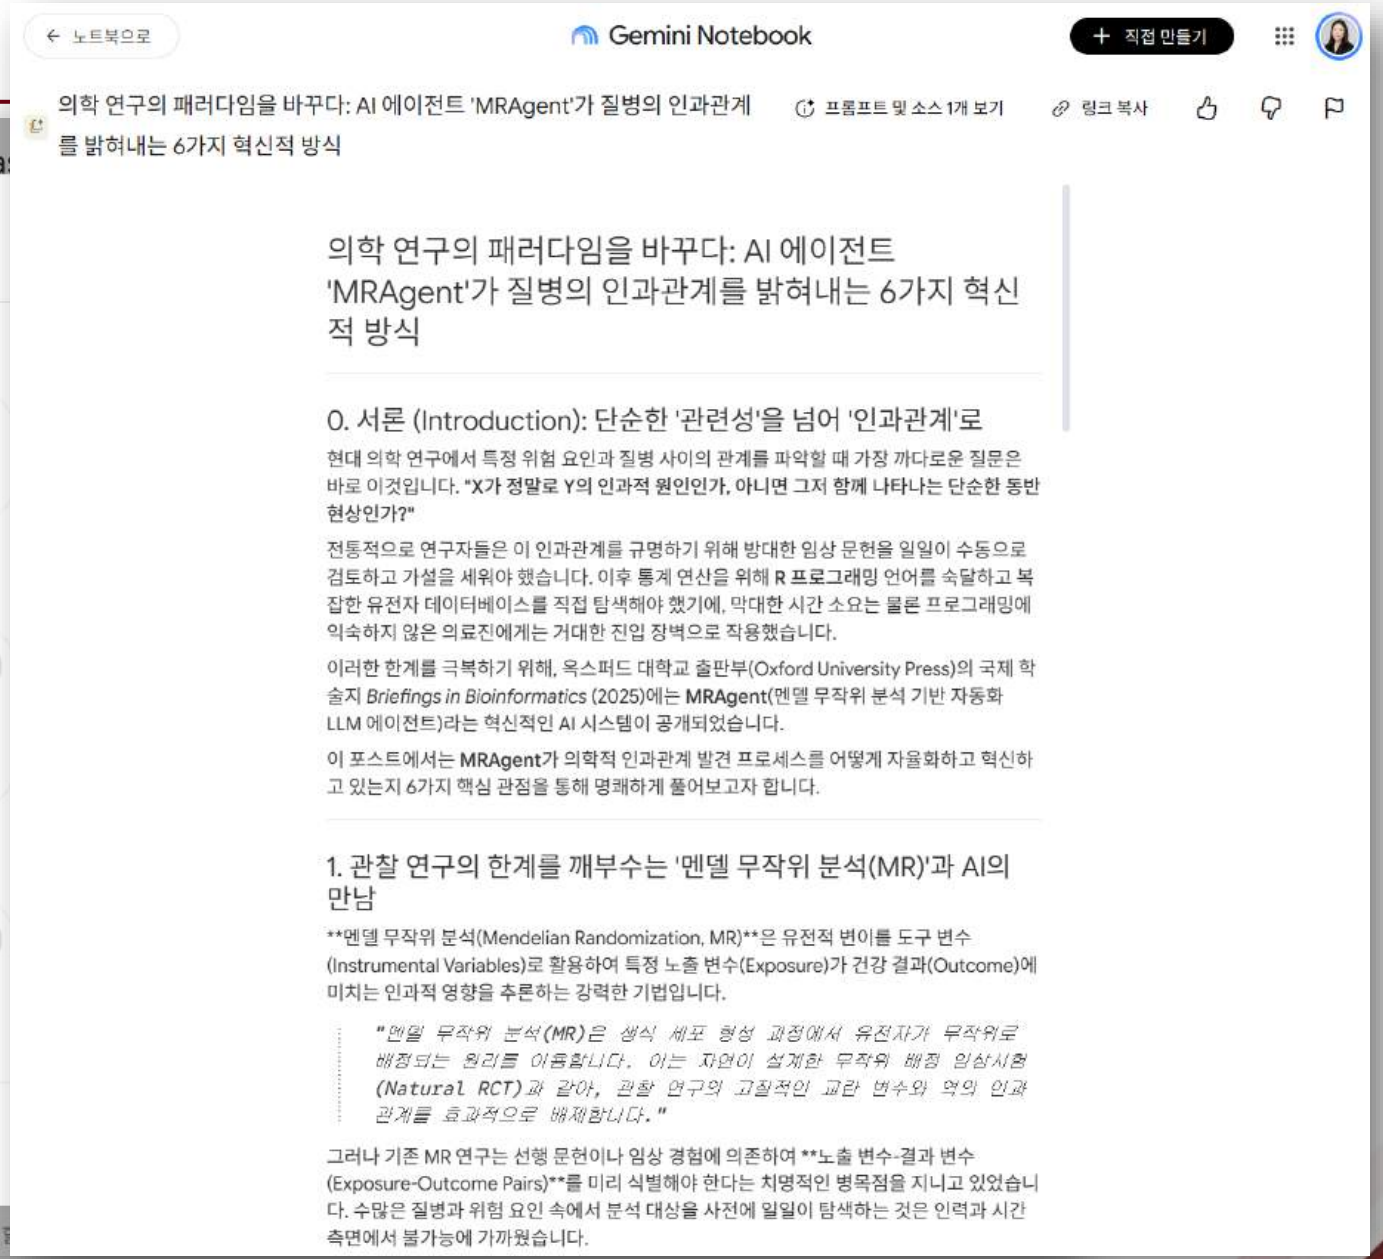
만족스러운 콘텐츠 불만족스러운 콘텐츠

Gemini Notebook은 실수를 할 수 있으니 다시 한번 확인하세요.

NotebookLM-보고서

https://notebooklm.link.google/6r5RsfFqmo2e





https://notebooklm.link.google/gxmVVHzNWtDg

NotebookLM-보고서(대화형)

MRAgent: Automated Causal Knowledge Discovery in Disease Res

출처

+ 소스 추

웹에서 새 소스를 검색하

BIB-MRAgent.pdf

보고서 생성

형식

대화형 New!

Studio 콘텐츠가 삽입되어 있는 대화형 보고서입니다.

문서

구조화된 텍스트

템플릿

학습 개요

학습에 도움이 되도록 스튜디오 콘텐츠와 함께 주요 개념을 요약합니다.

AI 사용량

이미 사용됨 예상 사용량

질문하거나 창작하세요

Gemini Notebook은 실수를 할 수 있으니 다시 한

노트북으로

Gemini Notebook

+ 직접 만들기

MRAgent: AI 기반 멘델 무작위 분석으로 질병의 인과관계를 발견하는 법

프롬프트 및 소스 1개 보기

링크 복사

1. Introduction
2. 질병 인과관계 추론의 혁명과 멘델 무작위 분석(MR)
3. MRAgent의 내부 구조: Brain, Memory, 그리고 Toolkit
4. 9단계로 펼쳐지는 완벽 자동화 워크플로우
5. AI 연구원의 능력 검증: LLM 성능 평가와 프롬프트 전략
6. 실전 검증: 요통(Back Pain)의 숨은 원인을 찾아서
7. Summary

MRAgent의 내부 구조: Brain, Memory, 그리고 Toolkit

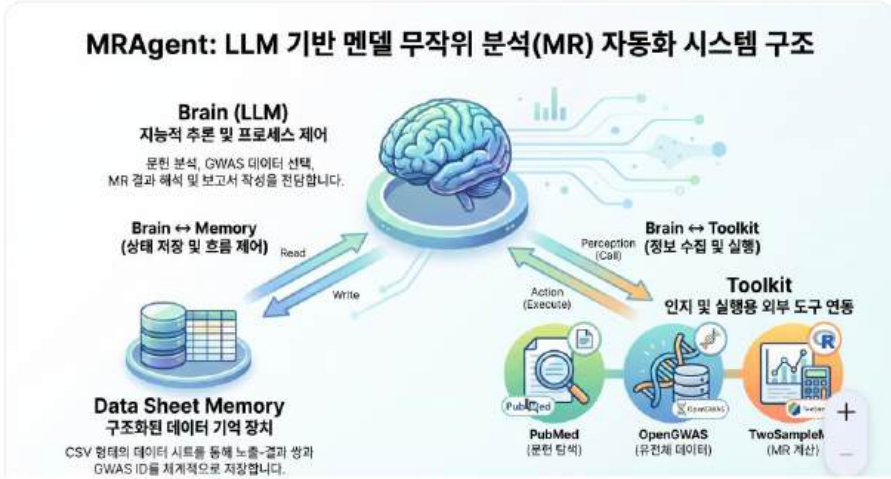
MRAgent는 단순한 질문-답변형 AI가 아닙니다. 최신 자율형 에이전트 아키텍처를 기반으로 설계되어, 사람처럼 외부 환경을 인식하고 스스로 의사결정을 내리며 도구를 사용합니다. MRAgent의 시스템 구조는 크게 세 가지 핵심 구성 요소로 나뉩니다.

첫 번째는 에이전트의 **두뇌(Brain)**입니다. 두뇌는 LLM(예: GPT-4o, Qwen-max)으로 구현되며, 의학적 전문 지식 체계, 결과 해석을 위한 데이터 분석 능력, 전체 공정을 제어하는 공정 제어(Process Control) 기능을 담당합니다. MRAgent는 시스템 프롬프트를 통해 '의학 전문 바이오메디컬 과학자'의 페르소나를 부여받아 복잡한 유전적 수치 속에서 의학적 의미를 도출합니다.

두 번째는 **메모리(Memory)**입니다. 분석 과정에서 발생하는 수많은 데이터와 의사결정 기록을 효율적으로 관리하기 위해 표준 관계형 데이터베이스 정규화 원칙에 따른 CSV 데이터 시트를 사용합니다.

- `exposure_and_outcome` : 문헌에서 추출한 노출-결과 쌍과 이전 MR 연구 존재 여부 저장
- `outcome` : 노출 및 결과 질병의 정식 명칭, 동의어, GWAS ID 목록 저장
- `run` : 최종 검증을 거쳐 실제 MR 분석에 투입될 핵심 연구 대상 기록

세 번째는 **인식 및 행동 도구 상자(Perception and Action Toolkit)**입니다. MRAgent는 외부 세계와 소통하기 위해 다양한 전문 API와 패키지를 사용합니다. 문헌 검색을 위한 PubMed / PMC, 의학용어 표준화를 위한 UMLS Terminology Services, 대규모 유전체 데이터를 조회하는 OpenGWAS, 그리고 실제 MR 통계 분석을 수행하는 R 패키지 TwoSampleMR 및 샘플 중복 편향을 수정한 MRlap이 이 도구 상자에 포함되어 있습니다.



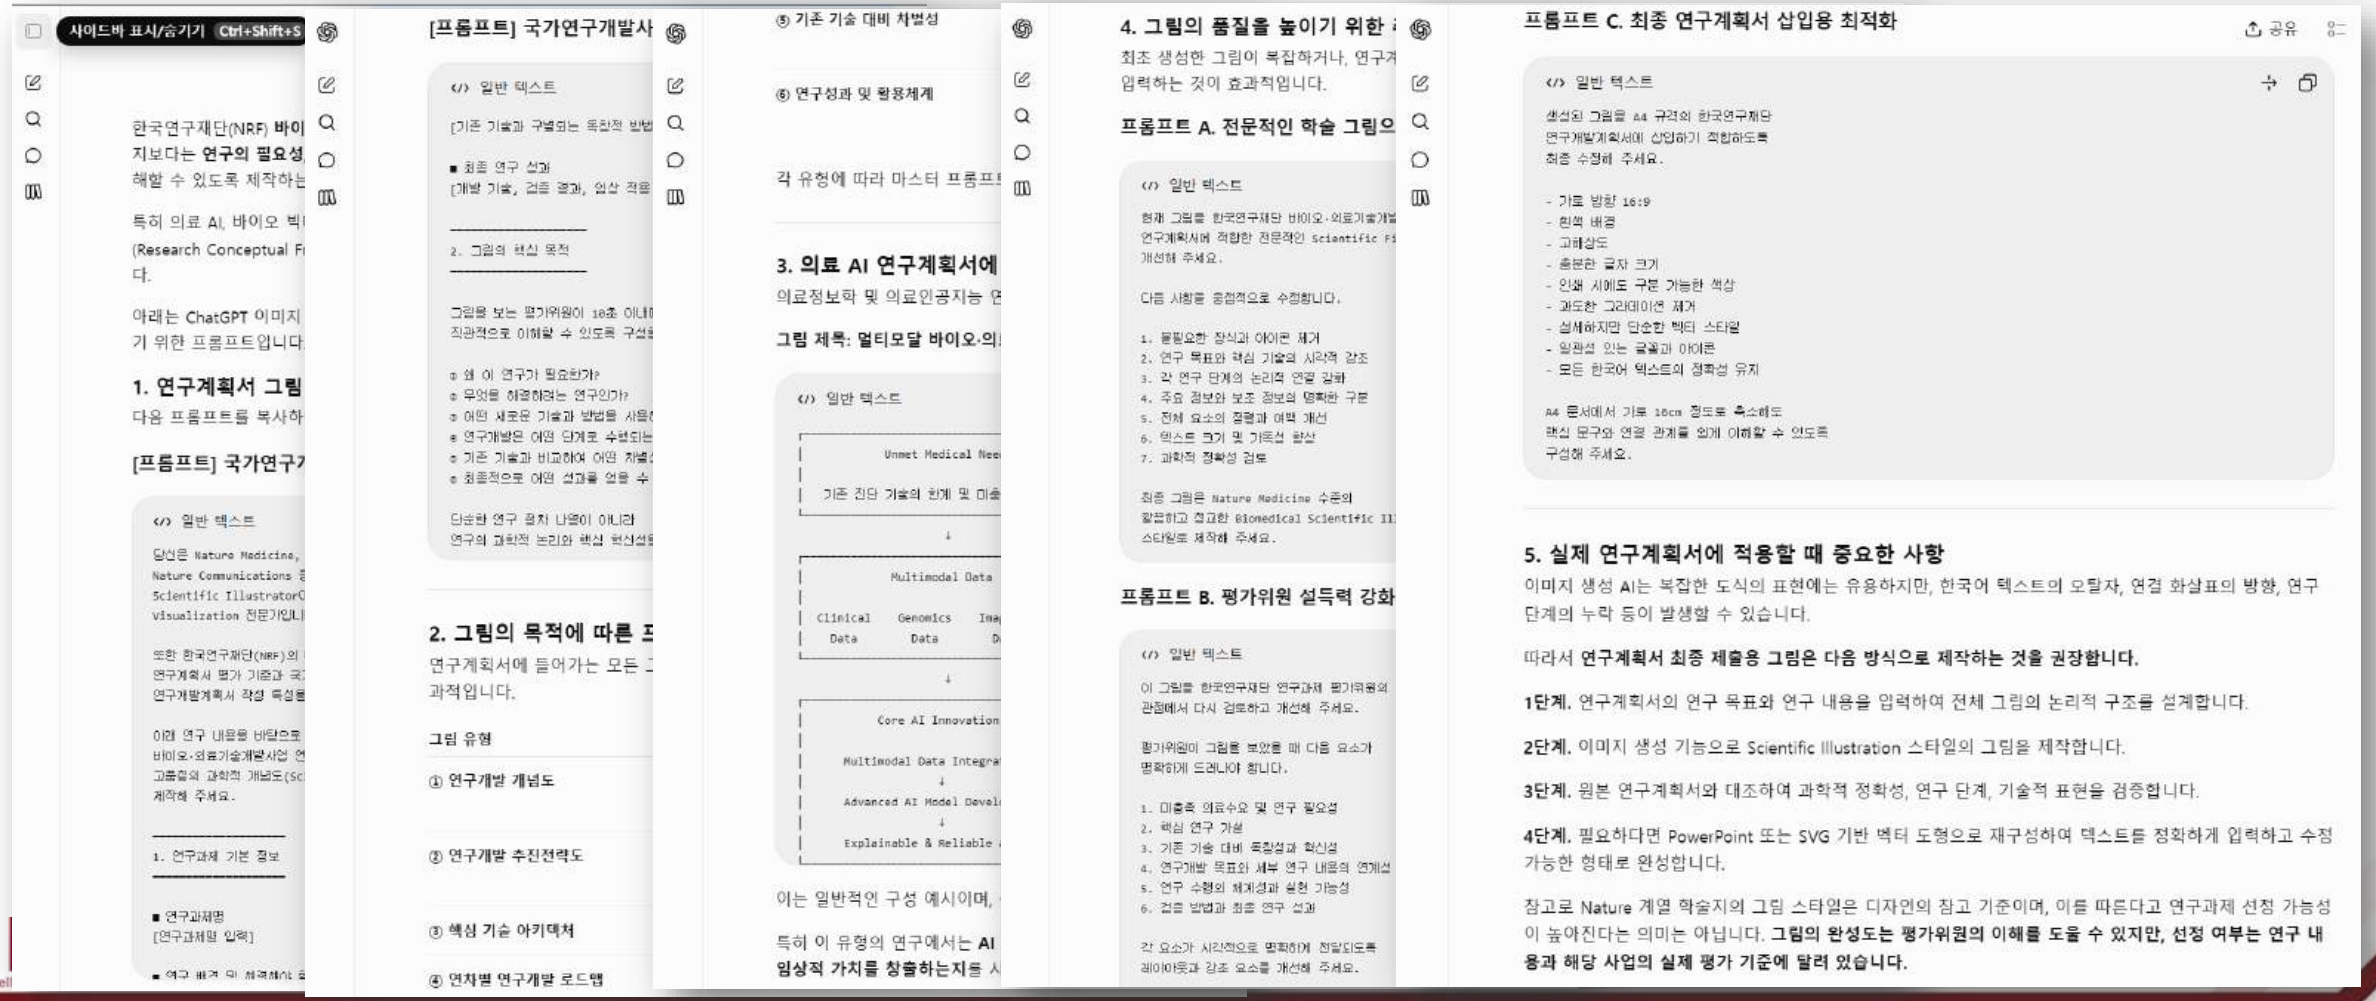
사용자가 제공한 소스 및 안내에 기반하여 AI로 생성되었습니다 서비스 약관 | 개인정보처리방침 | 자세히 알아보기

ChatGPT (https://chatgpt.com/)

구분	GPT-6 Astra	GPT-6.1 Sol	GPT-6 Luna	GPT-5.6 Terra
기본 성격	최고 성능의 플래그십 모델	고성능·비용 효율 균형형	경량·고효율 모델	범용 중급 모델
강점	고난도 추론, 복잡한 코딩, 심층 연구, 문서 작성	Astra에 근접한 성능, 에이전트 작업, 코딩, 전문 업무	빠른 응답, 저비용, 반복 작업 및 대량 처리	일반적인 분석, 문서 작성, 데이터 처리
판단·추론 능력	**최상급, 복잡한 다단계 추론에 적합**	**최상급에 근접, 높은 추론 품질**	비교적 단순하고 명확한 작업에 적합	중간 수준의 복잡한 추론에 적합
속도	고난도 추론 시 처리시간 증가 가능	빠른 처리에 중점, Ultrafast 모드 지원	**빠른 대량 처리에 최적화**	**범용 작업의 효율적 처리**
API 비용 (1M 토큰)	입력 $10 / 출력 $50	입력 $2 / 출력 $10	입력 $0.10 / 출력 $0.50	입력 $2 / 출력 $12
적합한 작업량	소량~중간 규모의 고난도 작업	중간~대규모의 복잡한 작업	대규모·고빈도 반복 작업	중간~대규모의 일반 작업
Knowledge cutoff	2026-04-30	2026-04-30	2026-05-18	2026-02-16
권장 상황	복잡한 연구설계, 논문 심층 검토, 고난도 문제 해결	전문 연구 업무, 논문 작성·검토, 코딩 및 연구 자동화	텍스트 분류·추출·요약, 대량 데이터 처리	일반적인 문서 작업, 통계·데이터 분석 보조

ChatGPT를 이용한 연구계획서 이미지 생성(1)

한국연구재단 바이오의료기술개발사업 과제가 선정될 수 있도록 연구계획서에 넣을 그림을 그리려고 한다. 이를 위한 프롬프트를 작성해줘.



뇌첨단의공학-AI및융합기술기반치매신규타겟.pdf
파일 다운받아 첨부

ChatGPT를 이용한 연구계획서 이미지 생성(2)



당신은 Natur
Engineering,
학술지의 Scie
Visualization
또한 한국연구
구계획서 평가
획서 작성 특
첨부한 RFP L
기술개발사업
념도(Scientifi
첨부한 RFP는
신청할 연구고
연구계획서의
구 내용, 연구
하게 분석해
먼저 연구계획
있는 핵심 그
핵심 메시지,



1. RFP 핵심 내

1.1. 사업 및 과

항목
사업명
RFP명
지원 분야
연구개발기간
정부지원금
기술성숙도
선정 규모
연구개발 유형
핵심 연구내용
필수 성과
추가 성과

출처: 첨부 RFP 1

선정 예정 과제가
해결하고, 그 결과
다.

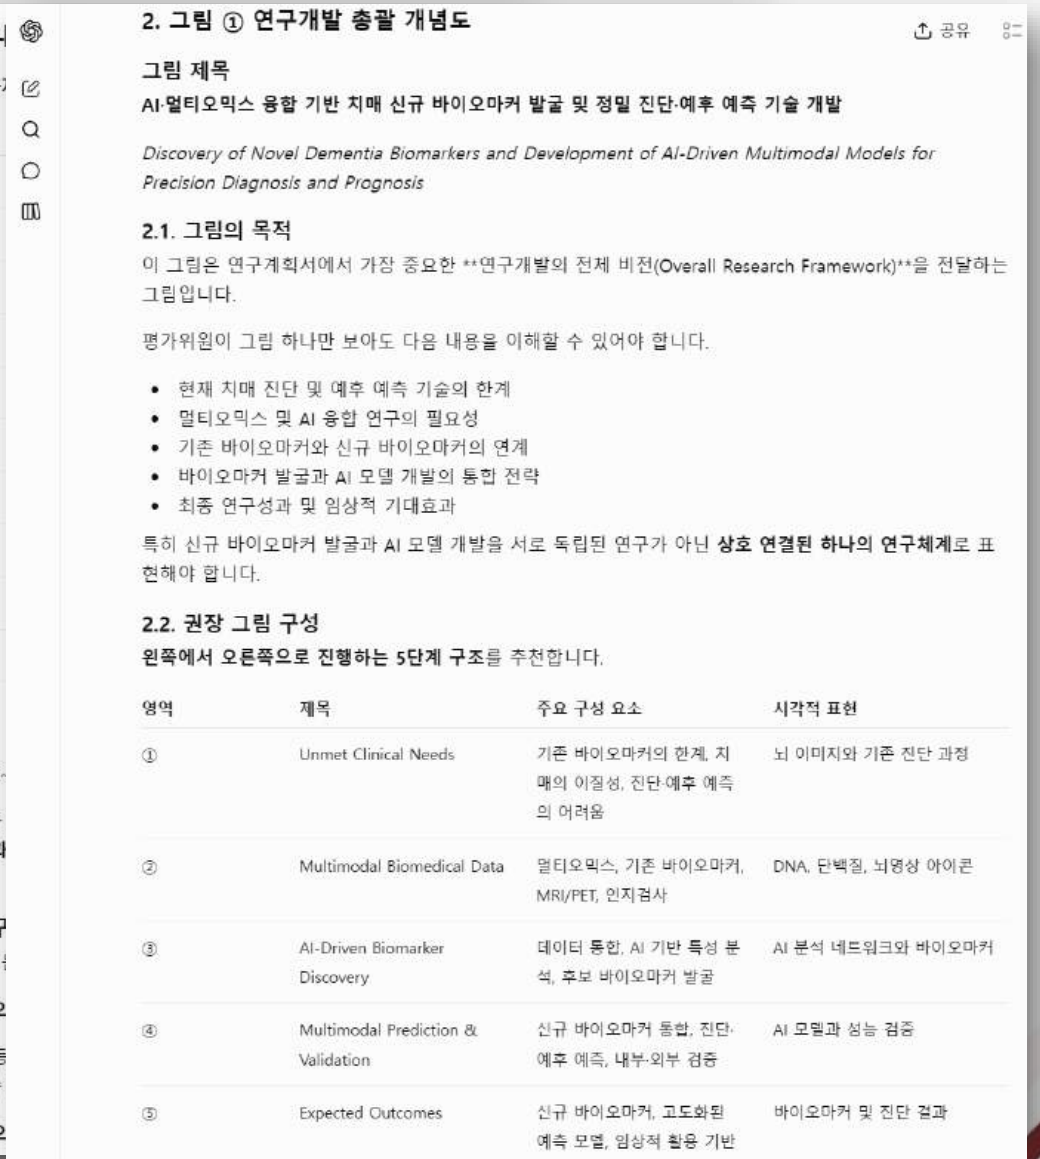
1.2. RFP가 요구

RFP 2페이지에서

첫째, 기존 바이오

pTau217, GFAP 등
도를 향상시킬 수

둘째, 신규 바이오



2. 그림 ① 연구개발 총괄 개념도

공유

그림 제목

AI·멀티오믹스 융합 기반 치매 신규 바이오마커 발굴 및 정밀 진단·예후 예측 기술 개발

Discovery of Novel Dementia Biomarkers and Development of AI-Driven Multimodal Models for Precision Diagnosis and Prognosis

2.1. 그림의 목적

이 그림은 연구계획서에서 가장 중요한 **연구개발의 전체 비전(Overall Research Framework)**을 전달하는 그림입니다.

평가위원이 그림 하나만 보아도 다음 내용을 이해할 수 있어야 합니다.

- 현재 치매 진단 및 예후 예측 기술의 한계
- 멀티오믹스 및 AI 융합 연구의 필요성
- 기존 바이오마커와 신규 바이오마커의 연계
- 바이오마커 발굴과 AI 모델 개발의 통합 전략
- 최종 연구성과 및 임상적 기대효과

특히 신규 바이오마커 발굴과 AI 모델 개발을 서로 독립된 연구가 아닌 **상호 연결된 하나의 연구체계**로 표현해야 합니다.

2.2. 권장 그림 구성

왼쪽에서 오른쪽으로 진행하는 5단계 구조를 추천합니다.

영역	제목	주요 구성 요소	시각적 표현
①	Unmet Clinical Needs	기존 바이오마커의 한계, 치매의 이질성, 진단·예후 예측의 어려움	뇌 이미지와 기존 진단 과정
②	Multimodal Biomedical Data	멀티오믹스, 기존 바이오마커, MRI/PET, 인지검사	DNA, 단백질, 뇌영상 아이콘
③	AI-Driven Biomarker Discovery	데이터 통합, AI 기반 특성 분석, 후보 바이오마커 발굴	AI 분석 네트워크와 바이오마커
④	Multimodal Prediction & Validation	신규 바이오마커 통합, 진단·예후 예측, 내부·외부 검증	AI 모델과 성능 검증
⑤	Expected Outcomes	신규 바이오마커, 고도화된 예측 모델, 임상적 활용 기반	바이오마커 및 진단 결과

ChatGPT를 이용한 연구계획서 이미지 생성(3)

한 가지 확인하고 싶습니다.

이번 과제에서 실제로 추진하
니면 **경도인지장애(MCI)에서**

두 방향은 연구 가설과 주요 평
먼저 확정하면 RFP에 더욱 부

이번 과제의 연구 방향을 **「A
하고, 앞서 제안한 세 가지 그

특히 첨부한 RFP는 pTau217,
멀티모달 AI 진단 모델 개발을

뇌첨단의공학-AI및융합기...

1. 연구과제의 핵심 개념

제안 연구과제명

국문: AI·멀티오믹스 융합 기반
개발

영문: AI-Driven Discovery of
Early Dementia Diagnosis

핵심 연구 가설

> 멀티오믹스와 뇌영상 및 임
> 신규 바이오마커를 발굴할
> 단의 정확도와 임상적 활용

이는 제안 가설이며, 실제로 입

4. 다음 단계에서 결정할

세 그림을 실제 연구계획서에 삽

이번 연구의 치매 조기진단 대상

1. **알츠하이머병(Alzheimer's**
   유용한 신규 바이오마커 발
2. **다양한 치매 유형을 포함하**
   신규 바이오마커 발굴 및 치
3. **경도인지장애(MCI) 중심:**

**현재 RFP의 연구 범위와 신규 바
히 설정하되 확보 가능한 데이터**
경쟁력은 연구진이 확보한 코호

이 방향을 결정하면 그림 3종의
수 있습니다.

연구 방향을 ① **알츠하이머병(A
치매(FTD), 루이소체 치매(DLB)**

이 방향에서는 **알츠하이머병 조
진단 가능성까지 평가하는 단계**

1. 최종 연구개발 방향

제안 연구과제명

국문

AI·멀티오믹스 융합 기반 알츠하

영문

AI-Driven Discovery of Novel E
Diagnosis of Dementia Using M

다음 단계: 그림 1 제작

이제 연구개발 총괄 개념도를 저

다만 그림의 과학적 정확성을 높

이번 연구에서 신규 바이오마커

① **혈액 기반 멀티오믹스** — 혈
활용

② **뇌 조직 기반 멀티오믹스** —

③ **혈액 기반 + 뇌 조직 기반 멀
석을 연계**

**연구의 핵심이 임상적으로 활용
합니다.** 혈액 기반 바이오마커를
생물학적 타당성을 보완하는 방

다만 이는 혈액·뇌 조직 데이터의
확보 자료를 먼저 확인해야 합니

연구 방향을 ③ **혈액 기반 멀티오**

이번 한국연구재단 과제에서는

최종 연구개발 전략

연구과제명(제안)

**AI 기반 혈액·뇌 조직 멀티오믹스
매 감별진단 기술 개발**

*AI-Driven Integration of Blood
Alzheimer's Disease Detection,*

최종 제작할 연구계획서 핵심 그림 3종

공유

그림 1. 연구개발 총괄 개념도

AI 기반 혈액·뇌 조직 멀티오믹스 융합을 통한 신규 치매 바이오마커 발굴 및 조기진단 기술 개발

가장 중요한 그림으로, 다음 세 가지 축을 중심으로 설계합니다.

- **Discovery:** 혈액 및 뇌 조직 멀티오믹스에서 신규 바이오마커 발굴
- **Development:** 기존 바이오마커와 통합한 설명가능한 멀티모달 AI 조기진단 모델 개발
- **Validation & Expansion:** 독립 외부 검증 및 AD에서 FTD·DLB 감별진단으로 확장

핵심 혁신 요소인 **Blood–Brain Multi-Omics Integration**을 그림의 중앙에 배치하겠습니다.

그림 2. 핵심 AI 기술 아키텍처

혈액·뇌 조직 멀티오믹스 및 임상영상 융합 기반 설명가능한 치매 조기진단 AI 프레임워크

이 그림은 연구의 기술적 우수성을 강조합니다.

혈액과 뇌 조직에서 유래한 분자적 정보를 연계하여 바이오마커를 발굴하고, 선정된 혈액 바이오마커와 임상·영상 정보를 실제 진단 모델에 통합하는 구조로 설계합니다.

특히 혈액검사만 가능한 환자나 MRI가 없는 환자 등 **실제 임상 환경의 결측 모달리티 상황**을 반영하겠습니다.

그림 3. 신규 바이오마커 발굴 및 검증 전략

혈액·뇌 조직 멀티오믹스 기반 신규 바이오마커 발굴과 기존 바이오마커 대비 추가적 진단 가치 검증

이 그림은 신규 바이오마커의 과학적 타당성과 임상적 가치를 강조합니다.

혈액 기반 후보 발굴 → 뇌 조직 기반 생물학적 근거 검토 → 기존 pTau217/GFAP와 비교 → 신규 바이오마커의 추가적 진단 가치 평가 → 독립 외부 검증으로 연결합니다.

특히 신규 바이오마커가 기존 바이오마커 대비 얼마나 유용한지 검증하는 **Incremental Diagnostic Value**를 시각적으로 강조하겠습니다.

그림 제작을 위한 공통 디자인

세 그림 모두 연구계획서에서 일관된 스타일을 유지하도록 다음 기준을 적용하는 것이 좋습니다.

- **스타일:** Nature Medicine 및 Nature Biomedical Engineering의 전문적인 Scientific Illustration 참고
- **비율:** 16:9 가로형
- **배경:** 흰색

그림 2 설명가능하고 결측 모달리티에 강건한 멀티모달 AI 기반 치매 조기진단 및 다중 치매 감별진단 프레임워크

① 멀티모달 입력 데이터 (Multimodal Inputs)

혈액 기반 멀티오믹스
- 단백체 (Proteomics)
- 전사체 (Transcriptomics)
- 대사체 (Metabolomics)
- 기존 바이오마커 (pTau217, GFAP 등)

뇌 조직 기반 멀티오믹스 (질환 기전 및 타당성)
- 단일세포 RNA-seq (scRNA-seq)
- 공간전사체 분석 (Spatial Transcriptomics)
- 세포-분자 네트워크 분석
- 질환 연관 세포 유형 및 병리기전

임상·영상·인지 데이터
- 뇌영상 (MRI, PET)
- 뇌파 (EEG)
- 임상정보 (연령, 성별, 병력 등)
- 인지기능 검사 (MMSE, MoCA 등)

② 모달리티별 특성 추출 (Modality-specific Encoders)

오믹스 인코더 (단백체/전사체/대사체)

영상 인코더 (3D CNN / ViT)

임상·인지 인코더 (표 구조 데이터)

사전학습 기반 특성 추출 및 임베딩 (Pretrained & Fine-tuning)
- 대규모 공개 데이터 활용
- 도메인 특화 사전학습
- 모달리티 불균형 대응
- 환자 수준 통합 임베딩

③ 멀티모달 융합 및 AI 모델 (Multimodal Fusion & AI Model)

적응형 멀티모달 융합 (Adaptive Multimodal Fusion)

멀티모달 트랜스포머 (Multimodal Transformer)

공통 잠재표현 (Shared Representation)

결측 모달리티 대응 학습 전략 (Missing-Modality Robustness)
- 전체 모달리티
- 영상 없음
- 오믹스 없음
- 임상정보 없음

④ 진단 및 예측 (Multi-task Learning)

알츠하이머병 조기진단 모델 (Early AD Detection)

AD 가능성 확률 (이전분류 또는 위험도 예측)

낮음 ~ 높음

다중 치매 감별진단 모델 (Differential Diagnosis)
- 정상인지 (CN)
- 알츠하이머병 (AD)
- 전두측두엽 치매 (FTD)
- 루이소체 치매 (DLB)

다중 분류 확률 (Multi-class Classification)

1.0 / 0.0 — CN AD FTD DLB

⑤ 모델 해석 및 임상적 활용 (Interpretability & Clinical Utility)

바이오마커 중요도 분석

Gene A, Protein B, Metabolite C, Protein D, Gene E

뇌 영상 기여도 분석 (Grad-CAM++)

모달리티 기여도 분석
- 혈액 오믹스
- 뇌영상
- 임상정보
- 인지검사

임상적 의사결정 지원
- 개인별 위험도 예측
- 주요 기여 바이오마커 제시
- 임상적 해석 정보 제공

핵심 기술적 혁신성

결측 모달리티에 강건한 AI
- 모듈리티 일부 결측 (실제 임상환경 반영)
- 안정적인 진단 성능 (Robustness)

멀티모달 통합 표현 학습
- 이질적 데이터의 통합 잠재표현
- UMAP 1, UMAP 2

설명가능한 AI
- 뇌 영역
- 바이오마커
- 임상 변수
- 진단 근거의 시각적·정량적 해석

임상 적용 가능성
- 다양한 데이터 가용성 상황에서 활용 가능한 진단 모델

기대 효과

- 알츠하이머병 조기진단의 정확도 향상
- 다중 치매 감별진단 기술 확보
- 신규 바이오마커의 임상적 활용 가능성 제시
- 개인 맞춤형 정밀의료 및 치매 관리 정책 기여

그림 2 설명가능하고 결측 모달리티에 강건한 멀티모달 AI 기반 치매 조기진단 및 다중 치매 감별진단 프레임워크

① 멀티모달 입력 데이터 (Multimodal Inputs)

혈액 기반 멀티오믹스
- 단백체 (Proteomics)
- 전사체 (Transcriptomics)
- 대사체 (Metabolomics)
- 기존 바이오마커 (pTau217, GFAP 등)

뇌 조직 기반 멀티오믹스
- 단일세포 RNA 시퀀싱 (scRNA-seq)
- 공간전사체 분석 (Spatial Transcriptomics)
- 세포·분자 네트워크 분석

임상·영상·인지 데이터
- 뇌영상 (MRI, PET)
- 뇌파 (EEG)
- 임상정보 (연령, 성별, 병력 등)
- 인지기능 검사 (MMSE, MoCA 등)

② 모달리티별 특성 추출 (Modality-specific Encoders)
- 혈액 오믹스 인코더 (단백체/전사체/대사체)
- 뇌 조직 오믹스 인코더 (scRNA-seq/공간전사체)
- 영상 인코더 (3D CNN / ViT)
- 임상·인지 인코더 (표 구조화 데이터)

사전학습 기반 특성 추출 및 임베딩 (Pretrained & Fine-tuning)

③ 멀티모달 융합 및 AI 모델 (Multimodal Fusion & AI Model)

적응형 멀티모달 융합 (Adaptive Multimodal Fusion)

멀티모달 트랜스포머 (Multimodal Transformer)

공통 잠재표현 (Shared Representation)

결측 모달리티 대응 학습 전략 (Missing-Modality Robustness)
- 전체 데이터
- 영상 없음
- 오믹스 없음
- 임상정보 없음

④ 진단 및 예측 (Multi-task Learning)

알츠하이머병 조기진단 모델 (Early AD Detection)

AD 가능성 예측 (이전분류 또는 위험도 예측)

AD probability: 0 ~ 1

다중 치매 감별진단 모델 (Differential Diagnosis)

정상인지 (CN) 알츠하이머병 (AD) 전두측두엽 치매 (FTD) 루이소체 치매 (DLB)

다중 분류 확률 (Multi-class Probabilities)

1 / 0 — CN AD FTD DLB

⑤ 모델 해석 및 임상적 활용 (Interpretability & Clinical Utility)

AI 모델 해석 (Explainable AI)

모달리티별 기여도

주요 바이오마커 중요도 분석

Gene A, Protein B, Metabolite C, Gene D, Protein E

뇌 영역 기여도 분석 (Grad-CAM++)

개인별 설명 (Patient-level explanation)

오믹스, 영상, 임상정보, 인지

핵심 기술적 특징 (Key Technical Features)
- 이질적 멀티모달 데이터 통합
- 결측 모달리티 대응 학습 전략
- 사전학습 기반 특성 추출 및 파인튜닝
- 다중 작업 학습 (조기진단 및 감별진단)

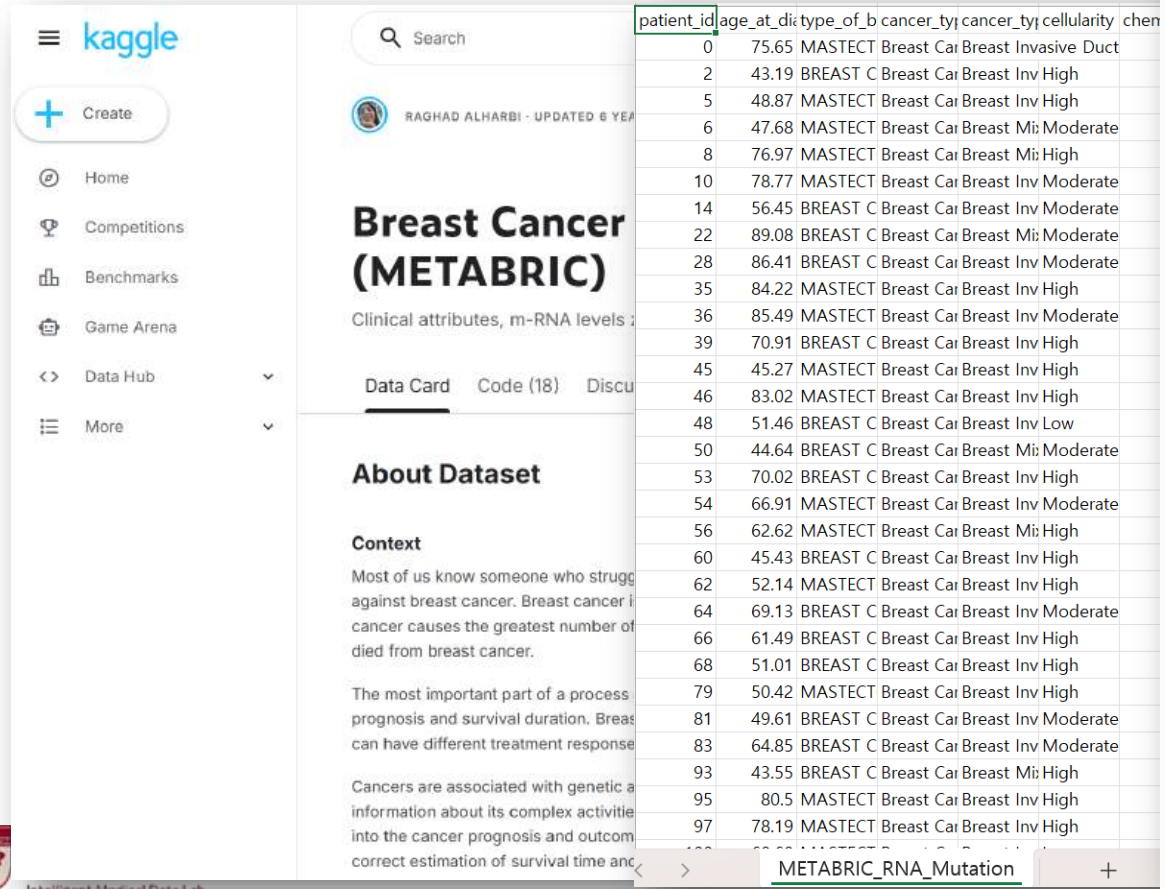
AI

기대 효과 (Expected Outcomes)
- 조기진단 정확도 및 일반화 가능성 향상
- 다양한 치매 유형의 감별진단 가능
- 바이오마커 기반 해석 가능한 진단 결과 제공
- 임상 현장 적용 가능성 및 확장성 확보

Breast Cancer Gene Expression METABRIC Dataset

https://www.kaggle.com/datasets/raghadalharbi/breast-cancer-gene-expression-profiles-metabric

- 유방암의 임상적 특성과 유전체·전사체 특성을 통합하여 유방암의 분자적 이질성과 예후 차이를 규명하기 위해 구축된 대표적인 코호트



patient_id	age_at_di	type_of_b	cancer_ty	cancer_ty	cellularity	chem
0	75.65	MASTECT	Breast Ca	Breast	Invasive Duct	
2	43.19	BREAST C	Breast Ca	Breast Inv	High	
5	48.87	MASTECT	Breast Ca	Breast Inv	High	
6	47.68	MASTECT	Breast Ca	Breast Mi	Moderate	
8	76.97	MASTECT	Breast Ca	Breast Mi	High	
10	78.77	MASTECT	Breast Ca	Breast Inv	Moderate	
14	56.45	BREAST C	Breast Ca	Breast Inv	Moderate	
22	89.08	BREAST C	Breast Ca	Breast Mi	Moderate	
28	86.41	BREAST C	Breast Ca	Breast Inv	Moderate	
35	84.22	MASTECT	Breast Ca	Breast Inv	High	
36	85.49	MASTECT	Breast Ca	Breast Inv	Moderate	
39	70.91	BREAST C	Breast Ca	Breast Inv	High	
45	45.27	MASTECT	Breast Ca	Breast Inv	High	
46	83.02	MASTECT	Breast Ca	Breast Inv	High	
48	51.46	BREAST C	Breast Ca	Breast Inv	Low	
50	44.64	BREAST C	Breast Ca	Breast Mi	Moderate	
53	70.02	BREAST C	Breast Ca	Breast Inv	High	
54	66.91	MASTECT	Breast Ca	Breast Inv	Moderate	
56	62.62	MASTECT	Breast Ca	Breast Mi	High	
60	45.43	BREAST C	Breast Ca	Breast Inv	High	
62	52.14	MASTECT	Breast Ca	Breast Inv	High	
64	69.13	BREAST C	Breast Ca	Breast Inv	Moderate	
66	61.49	BREAST C	Breast Ca	Breast Inv	High	
68	51.01	BREAST C	Breast Ca	Breast Inv	High	
79	50.42	MASTECT	Breast Ca	Breast Inv	High	
81	49.61	BREAST C	Breast Ca	Breast Inv	Moderate	
83	64.85	BREAST C	Breast Ca	Breast Inv	Moderate	
93	43.55	BREAST C	Breast Ca	Breast Mi	High	
95	80.5	MASTECT	Breast Ca	Breast Inv	High	
97	78.19	MASTECT	Breast Ca	Breast Inv	High	

METABRIC_RNA_Mutation

3. 데이터의 전체 구조

실제 CSV는 크게 다음 세 부분으로 나누어집니다.

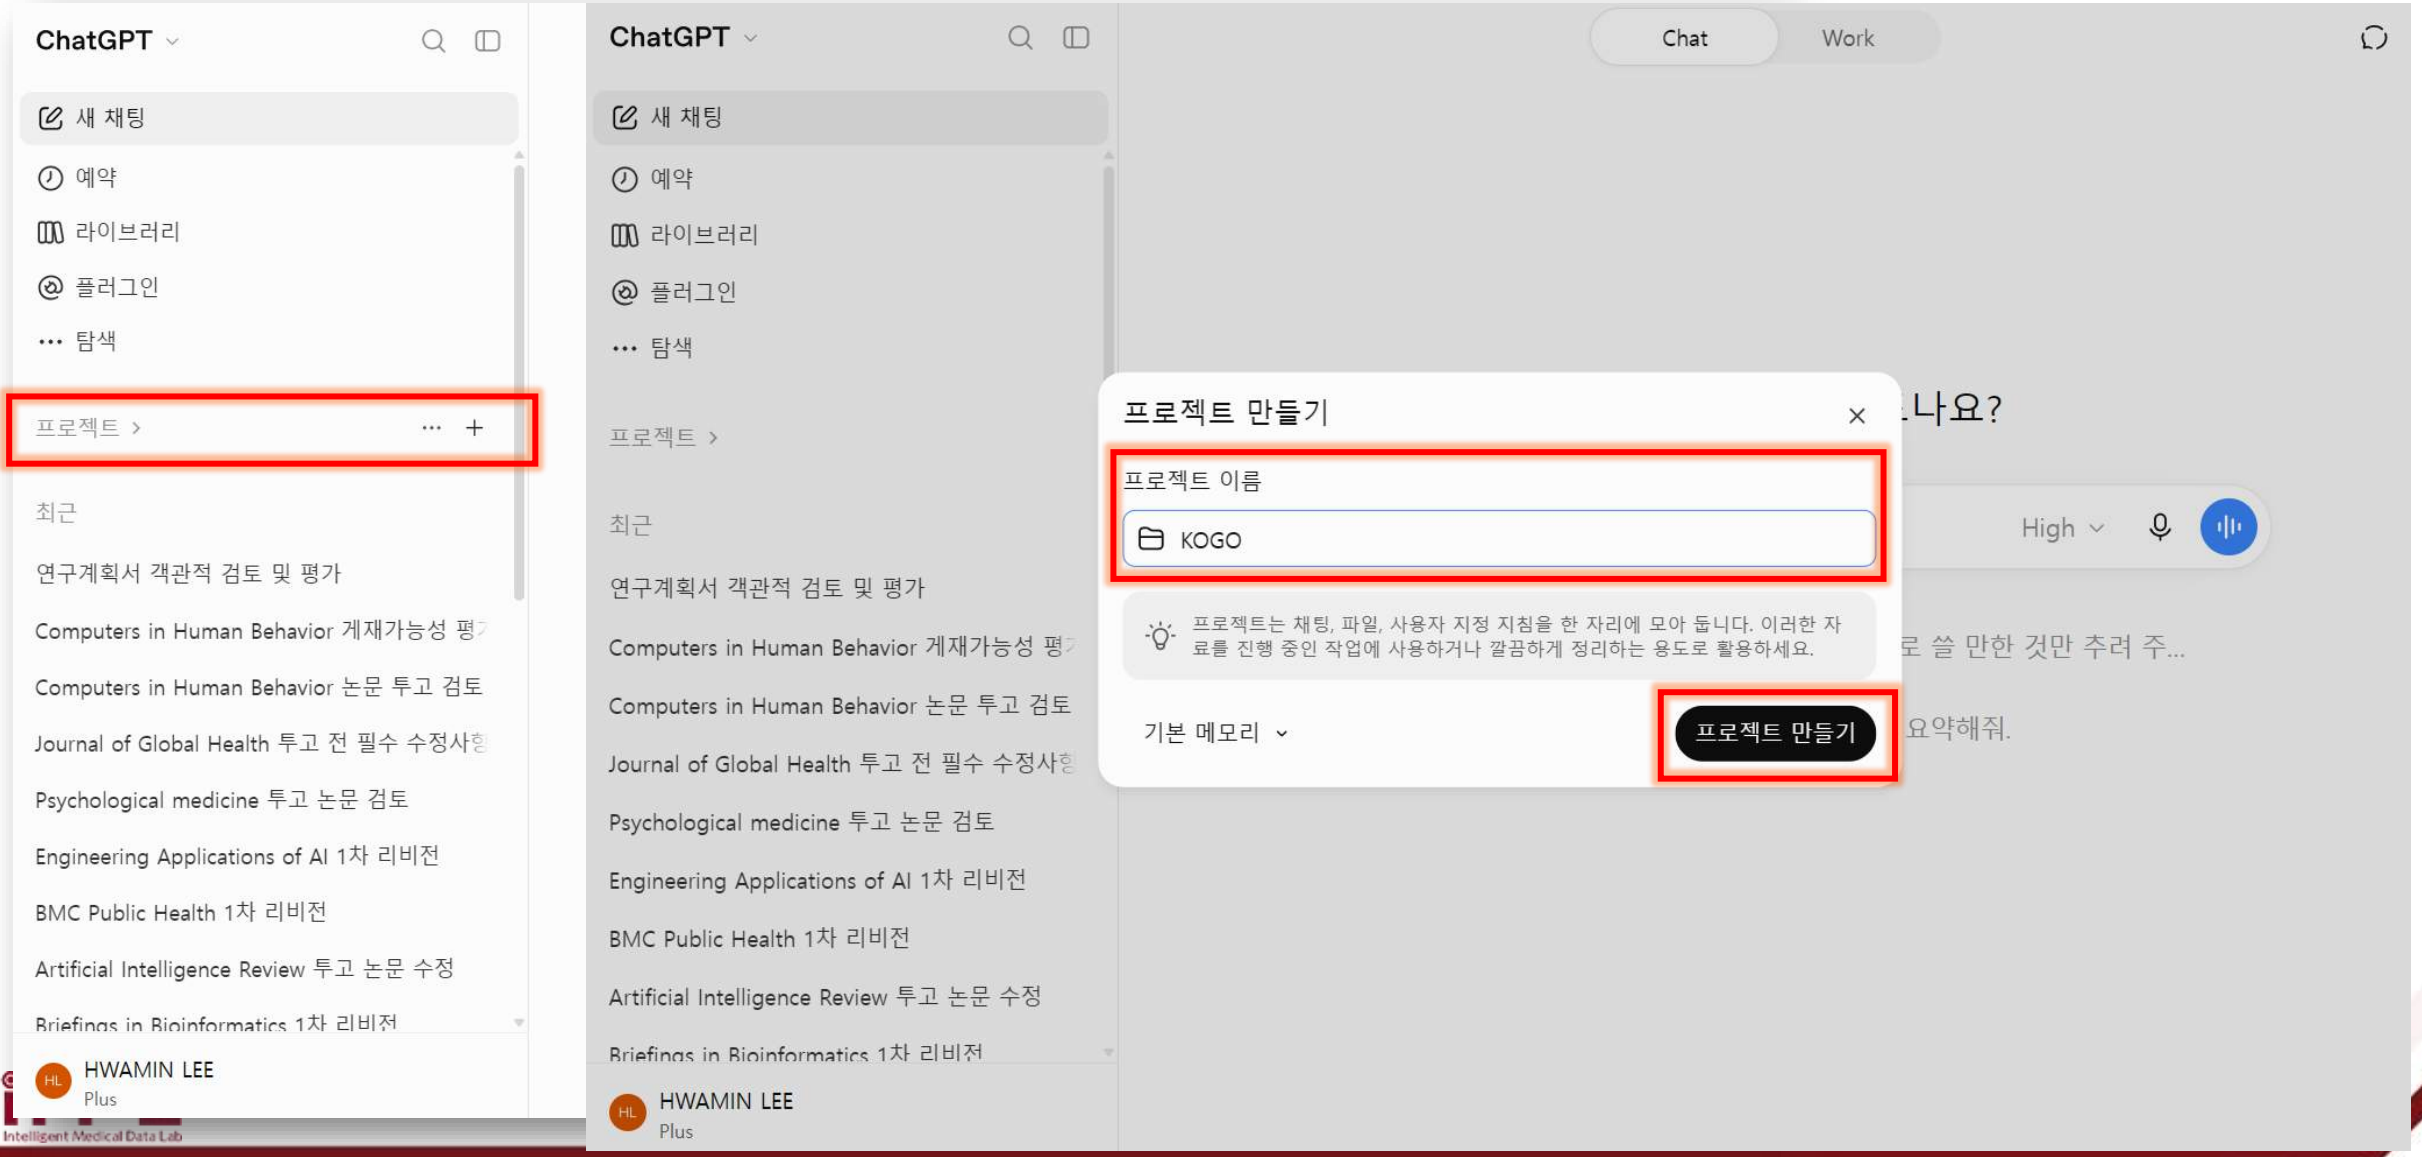
```
METABRIC_RNA_Mutation.csv
│
├── Clinical / demographic / pathological variables
│      └── 31 variables
│
├── mRNA expression
│      └── 489 genes
│
└── Somatic mutation
       └── 173 genes
```

그리고 중요한 결과변수는

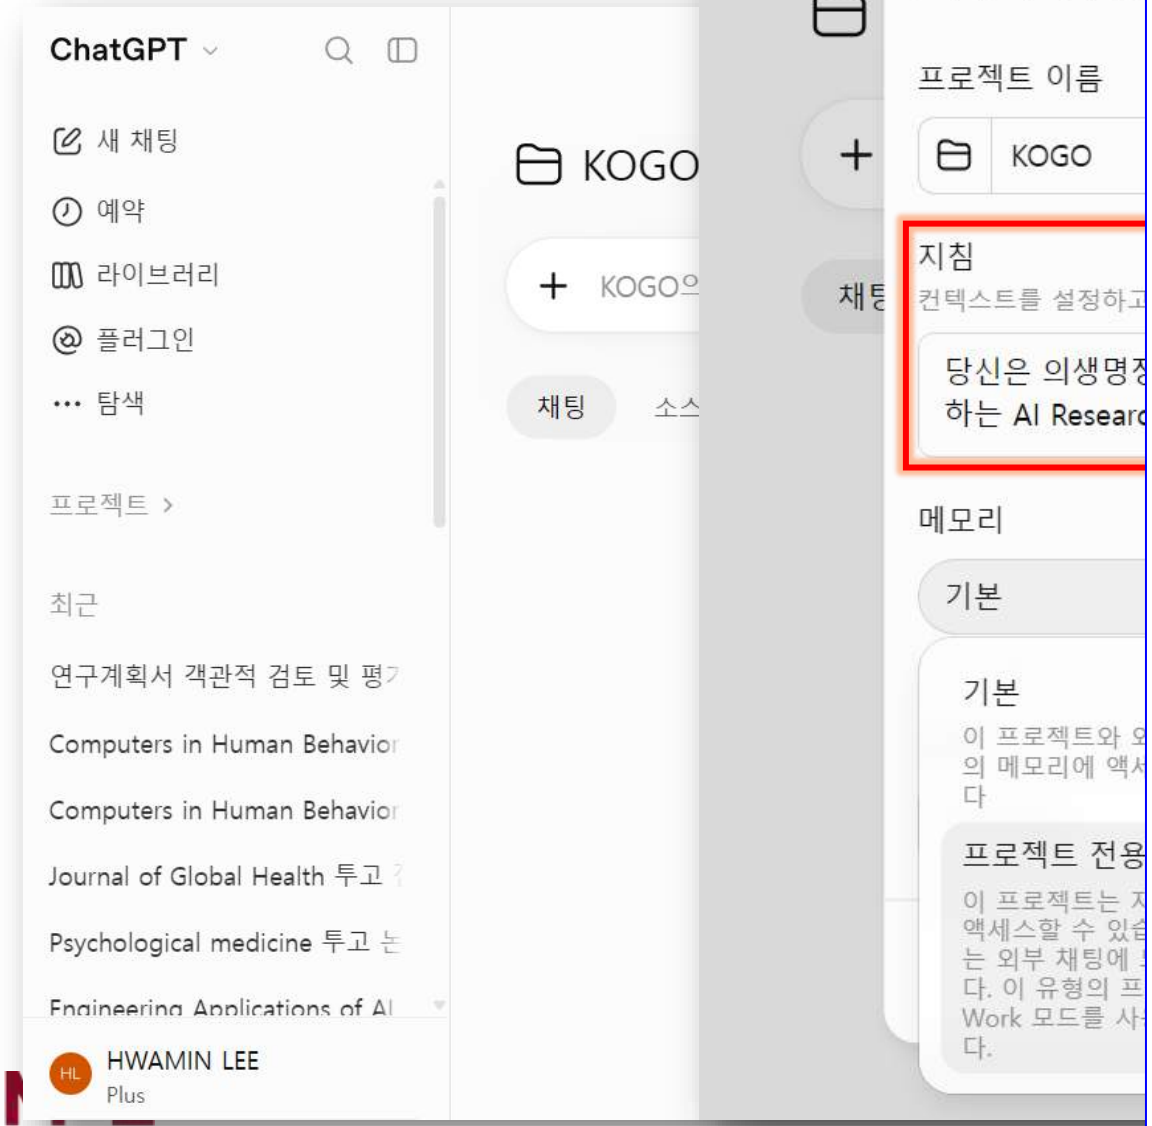
```
overall_survival_months
overall_survival
death_from_cancer
```

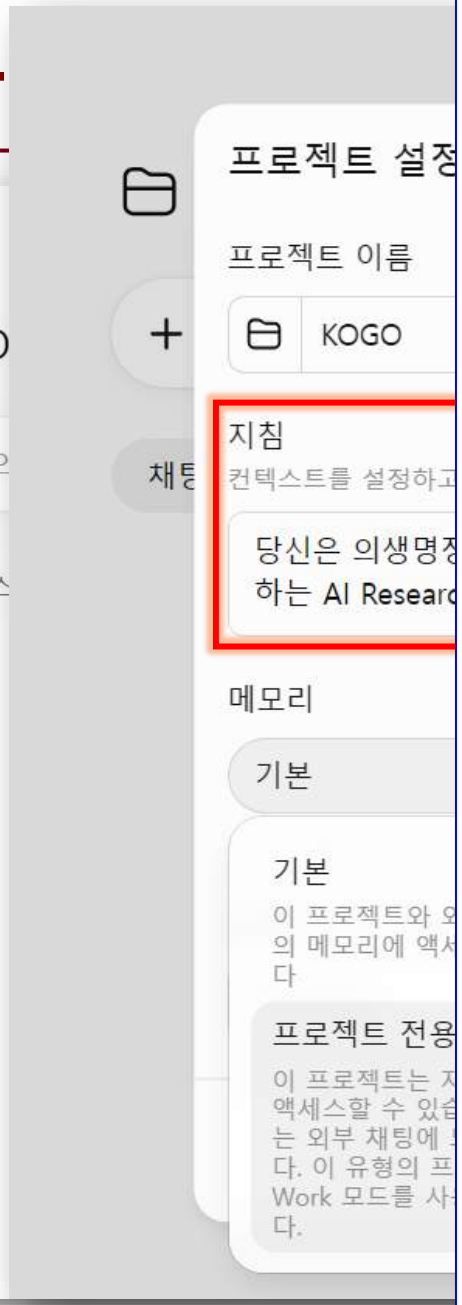
입니다.

ChatGPT를 이용한 데이터 분석



ChatGPT를 이용

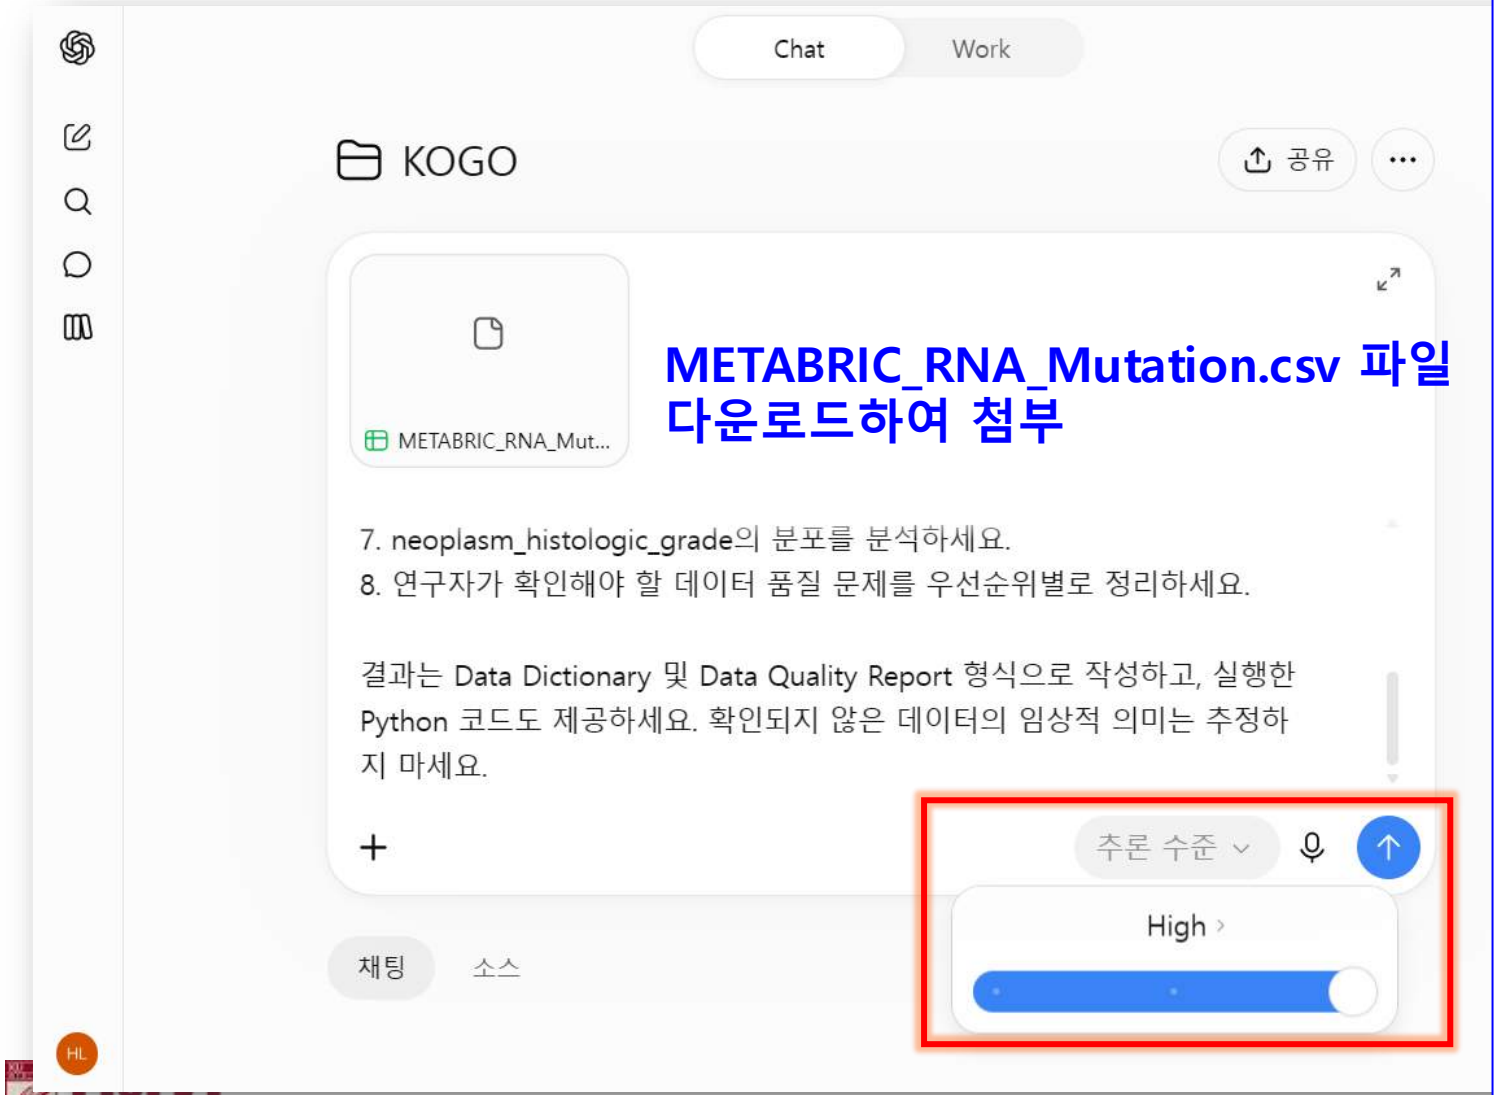




당신은 의생명정보학, 유전체학, 의학통계 및 머신러닝 연구를 지원하는 AI Research Assistant입니다.

다음 원칙을 반드시 준수하세요.
1. 업로드된 파일을 실제로 확인하고, 확인하지 않은 데이터나 분석 수치를 생성하지 마세요.
2. 통계 분석과 머신러닝은 실행 가능한 Python 코드를 작성하고 실제 실행 결과를 기준으로 보고하세요.
3. 모든 분석에서 대상자 수(N), 결측값 처리 방법, 통계 방법, 분석에 사용한 변수를 명시하세요.
4. 데이터 누출(Data Leakage), 과적합 및 부적절한 통계 방법을 사전에 점검하세요.
5. 연구 논문은 전문적인 academic English로 작성하되, 실제 분석 결과에 근거하지 않은 결과나 참고문헌을 생성하지 마세요.
6. 데이터 분석 결과는 표와 그림으로 정리하고, 가능하면 재현 가능한 Python 코드도 제공하세요.
7. 불확실한 사항과 연구의 한계는 명확하게 구분하여 보고하세요.
8. 사용자가 요청한 분석을 수행하기 전에 간략한 분석 계획을 제시한 다음 실행하세요.
9. 분석을 완료할 때마다 생성한 코드, 결과 파일, 주요 가정을 목록화하세요.

ChatGPT를 이용한 데이터 분석



첨부한 METABRIC_RNA_Mutation.csv 파일을 분석해 주세요.

1. 전체 환자 수, 변수 수, 자료형을 확인하세요.
2. Clinical, Gene Expression, Mutation 데이터를 구분하고 각 변수 수를 계산하세요.
3. 변수별 결측값 개수와 결측률을 계산하세요.
4. patient_id의 중복 여부를 확인하세요.
5. 주요 범주형 변수의 빈도와 연속형 변수의 기초통계를 작성하세요.
6. Mutation 변수에 저장된 0 및 변이 문자열의 의미를 구분하세요.
7. neoplasm_histologic_grade의 분포를 분석하세요.
8. 연구자가 확인해야 할 데이터 품질 문제를 우선순위별로 정리하세요.

결과는 Data Dictionary 및 Data Quality Report 형식으로 작성하고, 실행한 Python 코드도 제공하세요. 확인되지 않은 데이터의 임상적 의미는 추정하지 마세요.

추론(thinking/reasoning) 기능- ChatGPT & Gemini & Claude

- LLM 모델이 질문을 받자마자 즉시 답변하지 않고, 시간이 소요되더라도 최종 답을 내놓기 전에 내부적으로 여러 가지 해결책을 시도하고, 스스로 합리적인 해결책을 검증하고, 오류를 수정하는 '**사고 과정**'을 거치는 것
  - **얼마나 많은 추론 자원을 사용할 것인지/얼마나 많이 생각할지**를 조절하는 설정
  - 단순히 "답변을 길게 쓰는 정도"가 아니라, 검토하고 대안이나 오류 가능성을 점검

설정	의미	적합한 작업	속도
Instant	추론을 최소화하고 빠르게 답변	간단한 질문, 번역, 요약, 일반 정보	★★★★★
Medium	표준 수준 추론	일반 연구·분석·코딩·문서 작업	★★★★
High	더 깊은 다단계 추론	논문 검토, 통계 판단, 복잡한 코딩, 연구 설계	★★★
Extra High	GPT-5.6 Sol에서 제공되는 최고 수준의 추론	매우 복잡한 연구·분석·검증	★★
Pro	추론 강도만 높이는 것이 아니라 별도의 최고성능 실행 방식	최고난도 문제, 장기·복합 workflow	★ ~ ★★

KOGO

종합 분석 결과 (Excel)

Data Dictionary, Missingness, Clinical Statistics, Mutation Summary, Quality Issues 등 16개 시트

METABRIC_Data_Quality_Report.xlsx ↗

Data Quality Report (Markdown)

METABRIC_Data_Quality_Report.md ↗

실제 실행한 Python 코드

analyze_metabric.py ↗

개별 분석 결과 CSV

전체 Data Dictionary ↗ · 693개 변수별 결측 통계 ↗ · 유전자별 Mutation 통계 ↗ · 품질 문제 목록 ↗

재현 방법

원본 CSV와 제공된 Python 파일을 같은 폴더에 저장한 뒤 다음 명령어를 실행하면 됩니다. Google Colab에서도 파일을 업로드하고 `artifact_tool` 이 설치된 환경에서 동일한 분석을 재현할 수 있습니다.

Bash

```
python analyze_metabric.py \
  --input METABRIC_RNA_Mutation.csv \
  --output-dir .
```

분석의 주요 가정: 전체 1,904명을 유지했고, 결측값 대체(Imputation)는 수행하지 않았습니다. 기초통계는 변수별 유효 관측값을 사용했습니다. Mutation의 `0`은 기본적으로 원본 코드 그대로 유지했으며, 발현값의 정규화 방법이나 변이의 임상적 의미는 외부 근거 없이 부여하지 않았습니다.

METABRIC_Data_Dictionary.csv
스프레드시트

METABRIC_Missingness_All.csv
스프레드시트

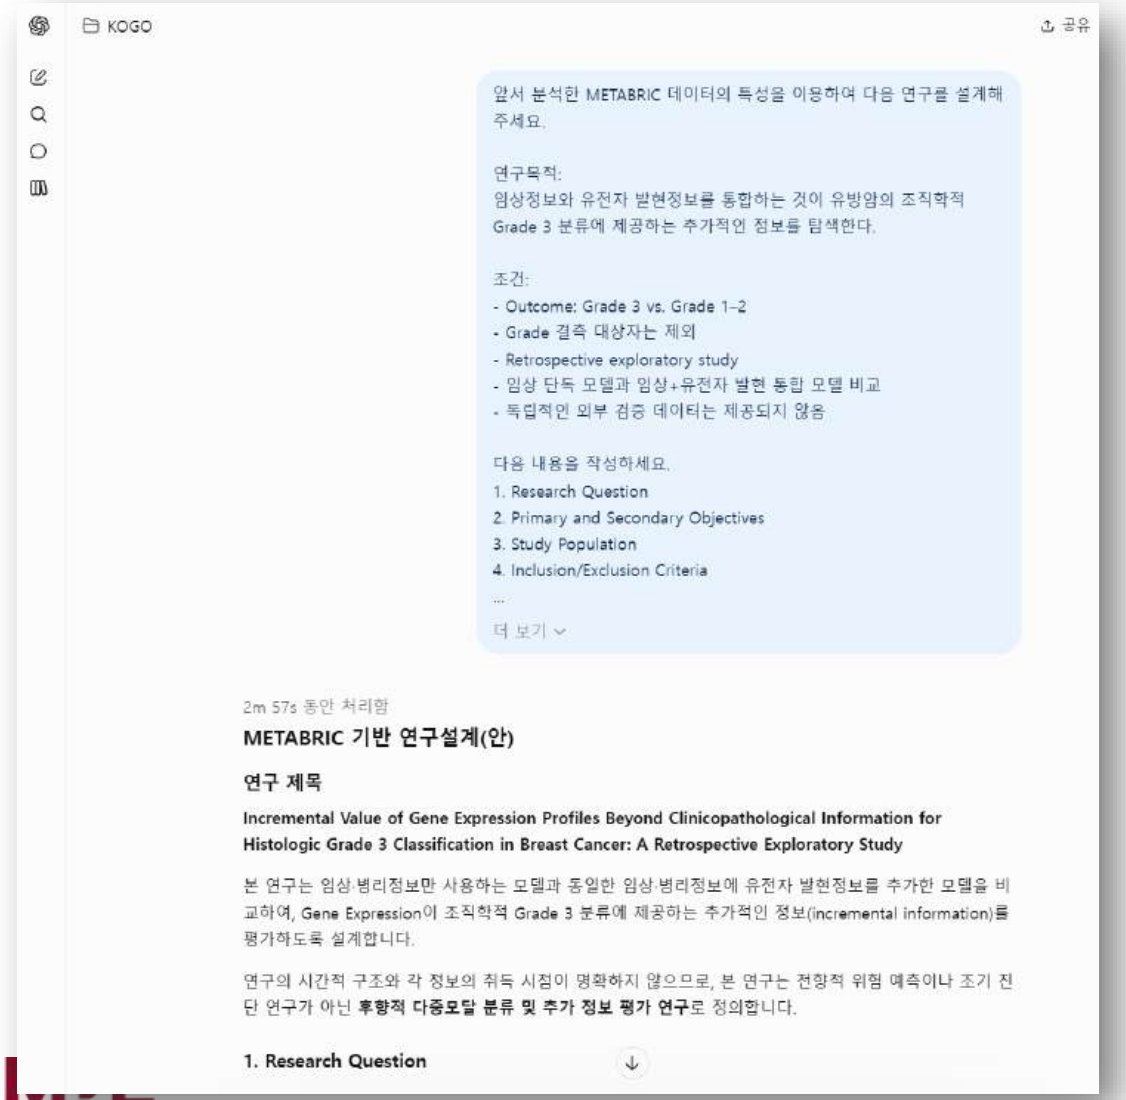
METABRIC_Mutation_By_Gene.csv
스프레드시트

1개 더

ChatGPT에게 물어보세요

High

ChatGPT를 이용한 데이터 분



앞서 분석한 METABRIC 데이터의 특성을 이용하여 다음 연구를 설계해 주세요.
연구목적:
임상정보와 유전자 발현정보를 통합하는 것이 유방암의 조직학적 Grade 3 분류에 제공하는 추가적인 정보를 탐색한다.
조건:
- Outcome: Grade 3 vs. Grade 1–2
- Grade 결측 대상자는 제외
- Retrospective exploratory study
- 임상 단독 모델과 임상+유전자 발현 통합 모델 비교
- 독립적인 외부 검증 데이터는 제공되지 않음
다음 내용을 작성하세요.
1. Research Question
2. Primary and Secondary Objectives
3. Study Population
4. Inclusion/Exclusion Criteria
5. Candidate Predictors
6. Statistical Analysis Plan
7. Machine Learning Analysis Plan
8. 예상되는 연구의 한계
연구의 시간적 구조가 불분명한 경우,
'조기 예측'이라는 표현은 사용하지 마세요.

2m 57s 동안 처리함

METABRIC 기반 연구

연구 제목

Incremental Value of Gen
Histologic Grade 3 Classif

본 연구는 임상·병리정보만
교하여, Gene Expression이
평가하도록 설계합니다.

연구의 시간적 구조와 각 정
단 연구가 아닌 **후향적 다중**

1. Research Question

Primary Research Questio

> Does integrating tumor
> incremental information
> cancer, compared with u

핵심 연구 질문은 임상정보
분류 성능을 어느 정도 개선

Research Hypothesis

- **H_0:** 두 모델의 내부 검
- **H_1:** 통합 모델의 AURO

다만 본 연구는 탐색적 연구
기, 95% 신뢰구간 및 보조

2. Primary and Second

구분	연구목적
Primary	유전자 발현정보 지 평가
Secondary 1	통합 모델의 분류
Secondary	예측확률의 보정

Secondary 3	성능 개선이 특
Secondary 4	Cohort 차이에
Exploratory	통합 모델에서 유전자 탐색

Primary estimand

ΔAUROC는 동일 대상자에

3. Study Population

앞서 분석한 원본 CSV를 자
있습니다. Grade 정보가 존
유전자 발현변수 489개에서
았습니다.

Study population flo

Positive class
927
Grade 3
50.60%

연구 대상자의 Grade
링 등의 불균형 보정 가

4. Inclusion / Exclu

구분	기준
Inclusion 1	METABR
Inclusion 2	neoplas
Inclusion 3	연구에
Exclusion 1	neoplas
Exclusion 2	Grade 값
Exclusion 3	주요 분

원본 기준 최종 분석대

임상 예측변수에 일부
결측값은 학습 데이터

Outcome이 결측인 72

5. Candidate Predi

본 연구에서 중요한 것
전자 발현정보의 추가

5.1 Model A: Clinicop

Primary analysis에는

변수명
age_at_diagnosis
inferred_menopausal_stat
er_status
pr_status
her2_status
tumor_size

`tumor_size`의 17건 결측은 전

변수 선택의 전제: 종양 크기,
임상·병리정보라는 분석적 전
또는 진단 전 예측 모델이라고

5.2 Model B: Integrated Clin

Model A — Clinical only
7 Clinical predictors

Model B — Integrated
7 + 489 Clinical + Gene Ex
총 496개 원본 변수(범주형 인코

Gene Expression 영역은 원본

다만 489개 유전자를 통합 모
regression)를 통해 과적합을

5.3 기본 모델에서 제외할 변수

다음 변수들은 연구 타당성 확

제외 변수
neoplasm_histologic_grade
nottingham_prognostic_index
overall_survival, overall_survival_m death_from_cancer
chemotherapy, hormone_therapy,
type_of_breast_surgery
tumor_stage
pam50_+_claudin-low_subtype
integrative_cluster
3-gene_classifier_subtype
her2_status_measured_by_s
mutation_count 및 Mutatio
patient_id

특히 `nottingham_prognc`
평가 이전에 임상 단독 모

5.4 추가 임상변수를 이용

Clinical baseline이 지나
확장 임상모델도 평가합

- Core clinical model:
- Expanded clinical m
- 두 모델 모두 동일한

확장 분석은 조직학적 아
하기 위한 것입니다. `cel`
본 모델에 포함하지 않고

6. Statistical Analysis

6.1 Descriptive Analysis

Grade 3 그룹과 Grade 1

변수 유형	요약통계
연속형 변수	Mean ±
범주형 변수	N (%)
결측값	Missing
유전자 발현	유전자별

연속형 변수는 정규성 및
를 파악할 수 있도록 Star

단변량 분석의 p-value를 기준으로 변수를 선별하지는 않습니다. 임상변수는 연구 목적과 데이터 가용성을 기준으로 사전에 정의합니다.

6.2 Missing Data Handling

결측값 처리는 다음과 같이 사전에 정의합니다.

데이터 영역	처리 원칙
Outcome	Grade 결측 72명 제외, 대체하지 않음
Clinical	학습 데이터에서만 추정한 median 또는 most frequent value 이용
Gene Expression	현재 명시적 결측은 없으나 분석 시작 시 재확인
Mutation	연구에 사용하지 않음

결측값 대체 과정에서 검증 데이터의 정보가 학습 데이터에 유입되지 않도록 모든 전처리를 Cross-validation Pipeline 내부에 배치합니다.

6.3 Cohort Heterogeneity Assessment

METABRIC 데이터는 5개 Cohort로 구성되어 있습니다. Grade 유효 대상자의 Cohort별 분포는 다음과 같습니다.

Cohort	전체 N	Grade 3 (N)	Grade 3 비율
1	467	246	52.68%
2	283	147	51.94%
3	689	367	53.27%
4	227	111	48.90%
5	166	56	33.73%
Total	1,832	927	50.60%

Cohort 5는 Grade 3 비율이 상대적으로 낮습니다. 또한 종양 병기 정보의 결측률도 Cohort별로 크게 다릅니다.

따라서 Cohort 구성에 따른 성능 차이가 통합 모델의 추가적인 분류 정보로 잘못 해석되지 않도록 다음 사항을 점검합니다.

- Cohort별 Grade 3 분포와 임상변수 분포 비교.
- Gene Expression 분포의 Cohort 간 차이 탐색.
- 기본 분석에서는 Outcome 및 Cohort를 고려한 층화 분할 적용.

- 기본 분석에서는 O
- Cohort별 모델 성능
- 추가적으로 Leave-C

cohort 는 기본 모델의

7. Machine Learning

7.1 Overall Study Fram

본 연구는 두 모델에 동
Model Comparison으로

Proposed machine le

Model A

Clinical only

7

Clinical predictors

Imputation → Scaling –
Regression

7.2 Model Selection

Primary analysis에서는 두
권장합니다.

그 이유는 다음과 같습니다

- Gene Expression은 총
- 유전자 발현변수 간 상
- L2 regularization은 계
- 두 모델에 동일한 알고

Hyperparameter인 C 는 In

예를 들어 다음 탐색 범위를

```
C = [0.001, 0.01, 0.1,
```

민감도 분석에서는 Elastic
는지 확인합니다.

7.3 Data Preprocessing

모든 전처리 과정은 학습 데

전처리 단계
Clinical missing values
Categorical variables
Continuous variables
Lymph node count
Gene Expression
Feature filtering
Class balancing
Hyperparameter tuning

Gene Expression의 원본 정
를 확인하기 전에는 raw co

또한 전체 데이터를 이용해
다. Feature selection, PCA

7.4 Internal Validation S

독립적인 외부 검증 데이터
니다.

구분	방
Primary validation	Ne
Inner CV	5-f
Repeated CV	Re
Cohort sensitivity	Lea

두 모델에는 반드시 같은

Inner CV에서 각각의 모델
확률을 산출합니다.

최종적으로 1,832명 전체
Prediction을 확보하고, 두

중요: Leave-One-Cohort-
법입니다. 이를 독립적인

7.5 Model Performance

성능은 다음 지표로 평가

Evaluation Metric
AUROC (Primary)
AUPRC
Brier Score
Calibration Intercept
Calibration Slope
Sensitivity
Specificity
F1-score

Sensitivity, Specificity 및

7.6 Incremental Performa

본 연구의 핵심 분석입니다

AUROC 차이뿐 아니라, 동
니다.

- Primary Nested CV의
- 동일 환자의 Clinical 여
- Paired bootstrap(예: 2
- Bootstrap은 Cohort 및
- 반복 CV에서의 ΔAURO

다만 고정된 out-of-fold 예
못한다는 점을 명시합니다.

탐색적 연구이므로 AUROC
복 분석에서의 일관성을 중

7.7 Exploratory Gene Ana

통합 모델에서 추가적인 분

분석 항목은 다음과 같습니

1. Elastic Net을 이용한 유
2. Cross-validation 반복에
3. 주요 유전자들의 회귀계
4. 필요한 경우 Grade 3과

이 분석은 Secondary 또는

선택된 유전자가 조직학적
증되었다고 주장해서는 안

8. 예상되는 연구의 한계

구분	Poten
1. External validation	독립적 에 대한
2. Retrospective design	후향적 선후관
3. Selection bias	Grad 발생
4. Cohort heterogeneity	Coho 성이
5. High dimensionality	489개 위험
6. Measurement heterogeneity	원본 의 도
7. Outcome reliability	Histo 정에
8. Biological interpretation	모델 생물
9. Clinical applicability	Gene 제 임 없음

특히 종양의 유전자 발현
는 서로 다른 두 종류의 종

따라서 모델 성능이 높더라
성능을 보일 것이라고 주장

9. 최종 권장 연구설계

Recommended Stud

항목
Study Design
Dataset
Study Population
Outcome
Model A
Model B
Primary Algorithm
Primary Validation

9. 최종 권장 연구설계 요약

Recommended Study Protocol

항목	권장 설계
Study Design	Retrospective Exploratory Study
Dataset	METABRIC
Study Population	N = 1,832
Outcome	Grade 3 vs. Grade 1–2
Model A	7 Clinical Predictors
Model B	7 Clinical + 489 Gene Expression
Primary Algorithm	Ridge Logistic Regression
Primary Validation	Nested Stratified 5-fold CV
Primary Endpoint	ΔAUROC
Secondary Metrics	AUPRC, Brier Score, Calibration
Sensitivity Analysis	Expanded Clinical Model, Repeated CV, Leave-One-Cohort-Out
External Validation	Not available
Interpretation	Incremental classification information

논문에서 강조할 핵심 메시지

본 연구의 목표는 가장 높은 Grade 3 분류 정확도를 달성하는 것이 아니라, 이미 확보된 임상.병리정보에 유전자 발현정보를 추가하는 것이 어느 정도의 추가적인 정보를 제공하는지 정량적으로 평가하는 것입니다.

따라서 복잡한 Deep Learning 모델을 다수 비교하기보다는 해석과 재현이 가능한 Regularized Logistic Regression을 중심으로 연구를 설계하는 것이 적절합니다.

실제 머신러닝 학습 및 성능평가는 아직 수행하지 않았으므로 AUROC, p-value 또는 개선 효과에 대한 예상 수치는 제시하지 않았습니다. 본 설계는 원본에서 재확인한 표본 수, 변수 수, 결측 현황 및 Cohort 분포를 기반으로 작성했습니다.

ChatGPT를 이용한 데이터



METABRIC 데이터에서 TP53 변이와 종양의 조직학적 등급 간 연관성을 분석해 주세요.
1. tp53_mut에서 문자열 '0'과 변이가 보고된 문자열을 구분하여 이진변수를 생성하세요.
2. Grade 1–2와 Grade 3에서 각각 TP53 변이 빈도를 계산하세요.
3. 적절한 통계검정을 수행하고, Odds Ratio 및 95% CI를 계산하세요.
4. 두 집단에서 TP53 mRNA expression의 분포를 비교하세요.
5. 그룹별 Mutation Frequency Bar Plot을 생성하세요.
6. TP53 expression의 Box Plot을 생성하세요.

Figure 조건:
- 흰색 배경
- 학술 논문에 적합한 간결한 디자인
- 제목, 축 이름 및 범례는 영어
- 300 dpi 이상의 PNG로 저장
- Figure Legend를 academic English로 작성

실제 분석 결과와 해석을 구분하여 보고하고, 연관성을 인과관계로 표현하지 마세요.

4m 45s 동안 처리함

Table 1 분석 대상 및 통계

원본 CSV에서 Grade 결측 72명

Study group
Histological Grade 1–2
Histological Grade 3
Total

Table 1에는 사전 정의한 임상
포함합니다. 유의하지 않은 변수

분포 확인 결과, 연령은 두 군 모
크기와 양성 림프절 수는 오른쪽
니다. 범주형 변수는 기대빈도를

백분율은 각 변수의 **결측값을 제**
시합니다.

1. Publication-ready Table

Table 1. Clinicopathological C
in the METABRIC Cohort

실제 Python 분석에서 총 12개
Laterality도 누락하지 않고 표에

Characteristic	
Demographic characteristics	
Age at diagnosis, years	
Inferred menopausal state	
Pre	
Post	
Clinicopathological characteristics	
Tumor size (recorded units)	
Positive lymph nodes, n	
Estrogen receptor status	
Positive	1
Negative	
Progesterone receptor status	
Positive	
Negative	
HER2 status	
Positive	
Negative	1
Tumor cellularity	
Low	
Moderate	
High	
Histologic subtype (recorded)	
Ductal/NST	1
Mixed	
Lobular	
Medullary	
Mucinous	
Tubular/cribriform	
Other	
Recorded tumor stage	
Stage 0	
Stage 1	
Stage 2	
Stage 3	
Stage 4	
Primary tumor laterality	
Left	8
Right	8
Dataset characteristics	
METABRIC cohort	
Cohort 1	4
Cohort 2	2
Cohort 3	6
Cohort 4	2
Cohort 5	

Missing 값 표기 예: `17 [10; 7]` 은
7건임을 의미합니다.

2. Statistical Tests Used for Ea

총 12개 변수의 검정 결과입니다. 모

Variable	S
Age at diagnosis	V
Inferred menopausal state	F
Tumor size	N
Positive lymph nodes	N
ER status	F
PR status	F
HER2 status	F
Tumor cellularity	F
Histologic subtype	F
Recorded tumor stage	F
Primary tumor laterality	F
METABRIC cohort	F

통계 방법 관련 주의사항

- Age는 Shapiro–Wilk 검정에서
  본 수가 충분하여 Welch's t-t
- Tumor stage는 희소 범주로
  exact test(199,999회, 고정 난
- Tumor stage는 476명(26.0%)
  합니다.
- Table 1의 p-value는 기술적·탐

3. Publication-ready Footno

아래 문구를 논문 Table 1 하단에

글쓰기

Table 1. Clinicopathological
Grade 3 in the METABRIC Co

Footnote. Data are presented
Q3]), or number (percentage),
nonmissing observations for e
overall count [Grade 1–2; Grad

Between-group comparisons
continuous variables, the Man
square test for categorical var
tables, the Fisher–Freeman–Ha

All tests were two-sided, and
missing histological grade (n
performed for descriptive ana

HER2, human epidermal grow
IQR, interquartile range.

4. 결과 파일 및 실행 Python

Publication-ready Excel

Publication-ready Excel

METABRIC_Table1_Publication_Ready.xlsx ↗
Table 1과 통계검정, 분포 진단, 원자료 빈도 검증 등을 포함한 6개 시트

Reproducible Python Code

generate_metabric_table1.py ↗
데이터 전처리, 분포 진단, 통계검정, Table 1 생성 및 파일 저장까지 포함

추가 결과 파일

- Publication-ready Table 1 (CSV) ↗
- 영문 Table 1 및 Footnote (Markdown) ↗
- 변수별 검정 방법과 정확한 p-value (CSV) ↗
- 연속형 변수의 분포 진단 결과 (CSV) ↗

Python 재현 방법

원본 CSV와 제공한 Python 코드를 같은 폴더에 저장한 후 실행하면 됩니다.

Bash

```
pip install numpy scipy artifact-tool

python generate_metabric_table1.py \
    --input METABRIC_RNA_Mutation.csv \
    --output-dir .
```

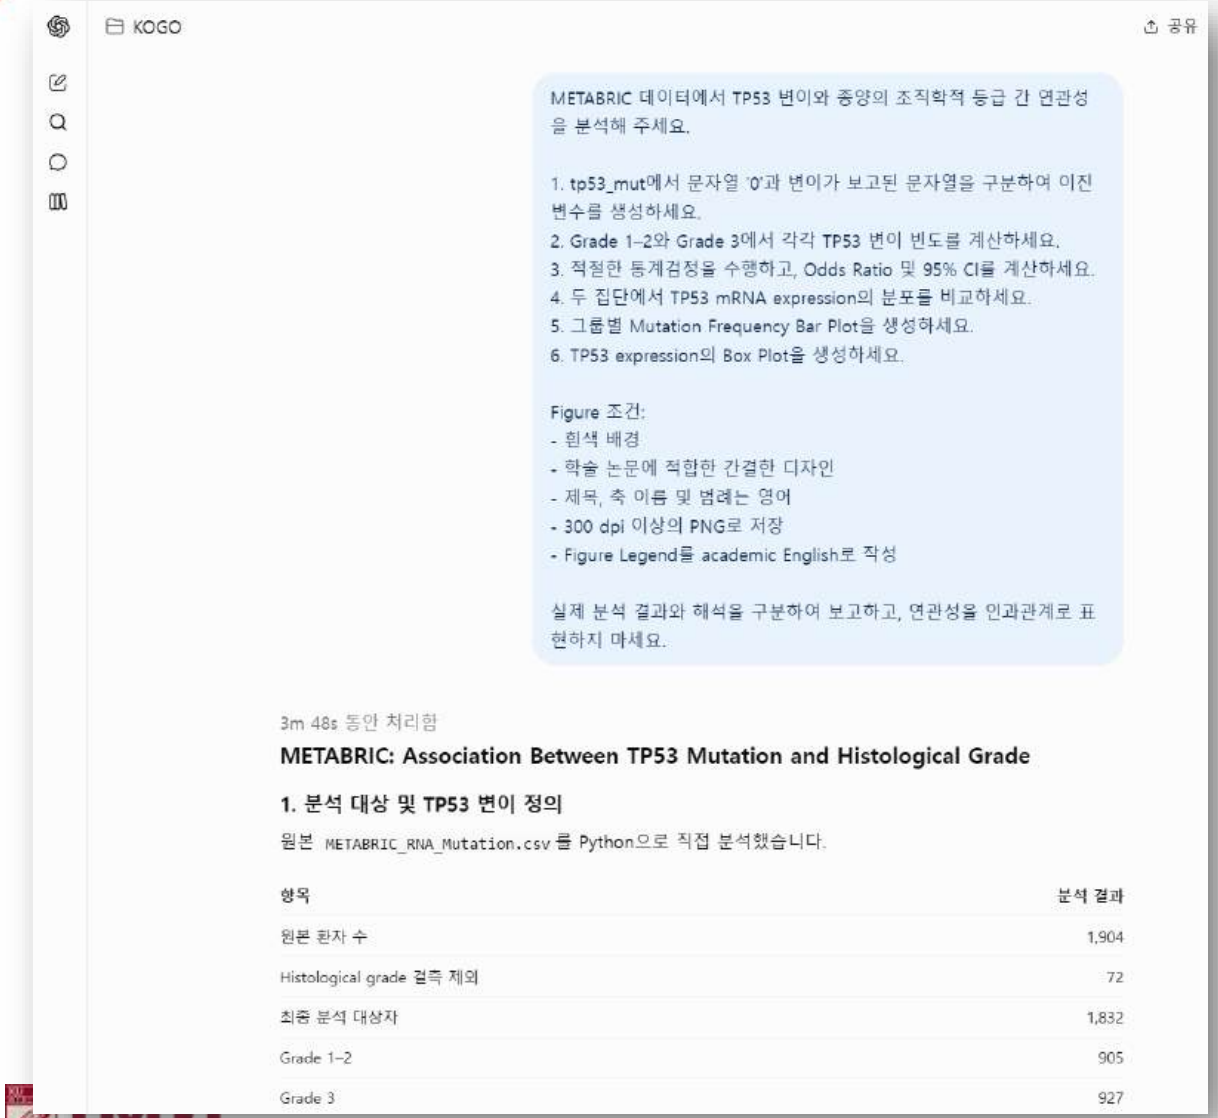
최종 검증: 생성된 Table 1의 12개 변수에 대해 유효 관측값과 결측값의 합이 각 분석군의 대상자 수와 일치하는지 확인했으며, 결과 파일의 존재 및 통계검정 출력값 검증을 완료했습니다.

논문 작성 시 권고: 현재 Table 1은 Primary Model의 임상 예측변수 7개와 추가 기술변수 5개를 포함합니다. 치료변수, 생존 결과변수, Grade가 계산에 포함된 Nottingham Prognostic Index 등은 연구설계상 구분하여 제외했습니다. 이 기준을 Methods의 *Study Variables and Statistical Analysis* 절에 명시하는 것이 좋습니다.

METABRIC_Table1.csv
스프레드시트

METABRIC_Table1_Manuscript.md

ChatGPT를 이용한 데이터 분



METABRIC 데이터에서 TP53 변이와 종양의 조직학적 등급 간 연관성을 분석해 주세요.
1. tp53_mut에서 문자열 '0'과 변이가 보고된 문자열을 구분하여 이진변수를 생성하세요.
2. Grade 1–2와 Grade 3에서 각각 TP53 변이 빈도를 계산하세요.
3. 적절한 통계검정을 수행하고, Odds Ratio 및 95% CI를 계산하세요.
4. 두 집단에서 TP53 mRNA expression의 분포를 비교하세요.
5. 그룹별 Mutation Frequency Bar Plot을 생성하세요.
6. TP53 expression의 Box Plot을 생성하세요.

Figure 조건:
- 흰색 배경
- 학술 논문에 적합한 간결한 디자인
- 제목, 축 이름 및 범례는 영어
- 300 dpi 이상의 PNG로 저장
- Figure Legend를 academic English로 작성

실제 분석 결과와 해석을 구분하여 보고하고, 연관성을 인과관계로 표현하지 마세요.

3m 48s 동안 처리함

METABRIC: Associa

1. 분석 대상 및 TP53

원본 `METABRIC_RNA_Muta`

항목
원본 환자 수
Histological grade 결측 제외
최종 분석 대상자
Grade 1–2
Grade 3
`tp53_mut` 결측
TP53 expression (`tp53`) 결측

TP53 Mutation Binary

`tp53_mut` 의 저장값을 다

원본 저장값

문자열 `"0"`
`"R175H"`, `"R248Q"` 등 비영
결측 또는 빈 문자열

주의: 이진변수의 0은 원
(wild-type)임을 독립적으

2. TP53 Mutation Fre

2.1 Mutation Frequency

TP53 mutation status
No mutation reported
Mutation reported
Total

Total

Grade 3 집단에서 TP53 변

2.2 Statistical Association

2×2 분할표의 모든 기대빈
Ratio(OR)는 Grade 1–2를

Statistic
Pearson's χ^2 (df=1)
p-value
Unadjusted Odds Ratio
95% CI
Fisher's exact test (sensitivity)

결과 해석: Grade 3 집단의
으로 유의한 연관성이지만,
다.

3. TP53 mRNA Express

Gene Expression 영역의 `tp`
도의 로그 변환이나 추가 정

3.1 Descriptive Statistics

Variable
Mean
SD
Median
Q1
Q3
Minimum
Maximum

Minimum

Maximum

Skewness

3.2 Distribution Asse

Shapiro–Wilk 검정에서
기각되었습니다(p=1.0

이에 Mann–Whitney U

Statistical Test
Mann–Whitney U
Rank-biserial correlation
Welch's t-test (Sensitivity

Mann–Whitney U는 G

TP53 mRNA expressio
니다. 특히 평균 차이를

따라서 Mutation Freq
서는 안 됩니다.

4. Publication-read

두 그림 모두 흰색 배경
분석 결과와의 일치 여

Figure 1. TP53 Muta

TP53 mutation freque

Figure 1 – Download

Figure 2. TP53 mRNA

TP53 mRNA expressio

Figure 2 – Download

5. 추가 데이터 품질 민감

앞서 Data Quality Report에
어 있었습니다.

해당 사례를 제외하여 연관

분석
Primary Analysis
Sensitivity Analysis

민감도 분석에서도 결과가
지되었습니다.

다만 원본 변이 분석의 측정
Mutation annotation의 모든

6. Figure Legends (Aca

다음 문구는 SCIE 논문에 사

글쓰기

Figure 1. Frequency

Bars indicate the propor
1–2 (n = 905) and Grade
field, in which the literal
mutation annotation wa
histological grade group
was assessed using Pear

Figure 2. Distributio

Box plots illustrate TP53
Grade 3 (n = 927). The c
interquartile range (IQR)
the IQR. Individual point
directly from the `tp53` fi
compared using the two

7. 결과 파일 및 Python

Complete Analysis
METABRIC_TP53_Gra
Python 코드, PNG Figu

개별 파일

File
analyze_tp53_grade.py ↗
Mutation Frequency.csv ↗
Expression Summary.csv ↗
Statistical Tests.csv ↗
Derived Cohort.csv ↗
Full Report.md ↗

Python 실행 방법

Bash

```
pip install numpy pandas s

python analyze_tp53_grade.
    --input METABRIC_RNA_M
    --output-dir .
```

8. 연구 결과의 종합 해석

본 연구에서 확인된 핵심은 TP53 mutation frequency가 조직학적 Grade와 강하게 연관되어 있지만, TP53 mRNA expression의 두 집단 간 차이는 상대적으로 작다는 점입니다.

이는 변이 여부와 mRNA 발현량이 서로 다른 분자적 특성을 나타내므로 두 결과를 구분하여 분석하고 보고해야 함을 시사합니다.

다만 현재 결과는 단변량(unadjusted) 연관성 분석입니다. 향후 임상·유전자 발현 통합 모델에서는 TP53 변이의 기여를 추가적으로 탐색할 수 있으나, 현재 결과만으로 독립적인 예측인자 또는 인과적 요인이라고 결론 내릴 수는 없습니다.

- Figure_1_TP53_Mutation_Frequency.png — 이미지
- Figure_2_TP53_mRNA_Expression.png — 이미지
- analyze_tp53_grade.py — 코드
- METABRIC_TP53_Mutation_Frequency.csv — 스프레드시트
- METABRIC_TP53_Expression_Summary.csv — 스프레드시트
- METABRIC_TP53_Statistical_Tests.csv — 스프레드시트
- METABRIC_TP53_Derived_Cohort.csv — 스프레드시트
- METABRIC_TP53_Grade_Report.md — 문서

접기

8. 연구 결과의 종합 해석
본 연구에서 확인된 핵심은
mRNA expression의 두 집
이는 변이 여부와 mRNA 발

ChatGPT는 실수할 수 있습니다. 중요한 정보는 확인하세요.

ChatGPT에게 물어보세요 High

ChatGPT를 이용한 머신러닝 모델 만들기

앞서 분석한 METABRIC 데이터를 이용하여 머신러닝 분류모델을 개발해 주세요.
[Research Objective]
Histological Grade 3 여부를 분류하고, Clinical-only Model과 Clinical + RNA Model의 성능을 비교합니다.
[Outcome]
- Grade 3 = 1
- Grade 1 또는 2 = 0
- Grade 결측 대상자는 제외

[Predictors]
Model A (Clinical-only):
age_at_diagnosis, tumor_size, lymph_nodes_examined_positive, er_status, pr_status, her2_status

Model B (Clinical + RNA):
Model A의 변수에 다음 발현변수 추가:
brca1, brca2, tp53, pten, erbb2, pik3ca, ccnd1, myc

[Algorithms]
- Logistic Regression
- Random Forest

[Requirements]
1. Stratified Train/Test Split (80:20)
2. random_state=42
3. 결측값 처리는 Training Set에서 학습
4. 필요한 변수에 Scaling 및 Encoding 적용
5. sklearn Pipeline과 ColumnTransformer 사용
6. Training Set 내부에서 Stratified 5-fold CV 수행
7. 독립적으로 보존한 Test Set에서 최종 성능평가
8. Test Set은 모델 선택이나 튜닝에 사용하지 말 것
9. 모델별 AUROC, AUPRC, Accuracy, Sensitivity, Specificity, F1-score 산출
10. 모든 단계의 실행 가능한 Python 코드 제공

필요한 경우 라이브러리를 설치하고, 코드를 실제 실행하여 결과를 보고해 주세요.

ChatGPT를 이용

KOGO

앞서 분석한 META
해 주세요.

[Research Objectiv
Histological Grade
+ RNA Model의 성

[Outcome]
- Grade 3 = 1
- Grade 1 또는 2 =
- Grade 결측 대상

[Predictors]
Model A (Clinical-
age_at_diagnosis,
er_status, pr_status

Model B (Clinical
Model A의 변수에
...
더 보기

3m 43s 동안 처리함

1. 데이터 및 모델 구성

원본 파일을 다시 확인한 결과, 요청하신 예측변수 14
장되어 있습니다. 결측은 전체 원본 기준 tumor_size

항목	Clinical-
Clinical predictors	6개
RNA expression predictors	없음

3m 43s 동안 처리함

1. 데이터 및 모델 구성

원본 파일을 다시 확인한 결과,
장되어 있습니다. 결측은 전체

항목
Clinical predictors
RNA expression predictors
Logistic Regression
Random Forest
Outcome

실제 실행에서는 다음 원칙을 적

- 대상자 1,832명을 Train/Tes
- 두 모델과 두 알고리즘 모두
- 하이퍼파라미터는 Training
- RNA 변수의 표준화, tumor
- Test Set에서는 사전에 고정

Grade 자체 또는 Grade가 계산
모델 입력에 사용하지 않습니다

2. Logistic Regression 중간

Logistic Regression 두 모델은

Model
Clinical-only
Clinical + RNA

동일 알고리즘에서 8개 RNA 발

이 수치는 최종 학습된 두 Logis
일관된 개선 여부는 Random Fo

3. 최종 Test Set 성능평가

4개 모델 모두 실행을 완료했습
한 후, 보존한 Test Set 367명에

3.1 Performance Comparison

Algorithm	Model
Logistic Regression	Clinical
Logistic Regression	Clinical +
Random Forest	Clinical
Random Forest	Clinical +

AUPRC는 scikit-learn의 averag

3.2 Training Set 내부 5-fold

Algorithm	Mode
Logistic Regression	Clinica
Logistic Regression	Clinica
Random Forest	Clinica
Random Forest	Clinica

모델별 최적 하이퍼파라미터는

Model
Clinical – LR
Integrated – LR
Clinical – RF
Integrated – RF

Random Forest의 트리 수는 2

4. RNA 추가에 따른 Incremental Performance

동일한 Test Set에서 Clinical-only Model과 Integrated Model을 대응 비교했습니다.

Algorithm	ΔAUROC	ΔAUPRC	ΔAccuracy	ΔF1
Logistic Regression	+0.0269	+0.0126	+0.0136	+0.0370
Random Forest	+0.0328	+0.0231	+0.0218	+0.0326

추가적으로 2,000회 Paired Stratified Bootstrap을 수행한 결과입니다.

Algorithm	ΔAUROC	Bootstrap 95% CI
Logistic Regression	+0.0269	-0.0044 to 0.0591
Random Forest	+0.0328	-0.0016 to 0.0675

두 알고리즘 모두 RNA 추가 후 AUROC가 증가하는 방향을 보였습니다. 그러나 **95% CI가 모두 0을 포함하므로, 현재의 단일 내부 Test Set만으로 성능 개선이 통계적으로 확실하다고 결론 내리기는 어렵습니다.** 해당 신뢰구간 역시 학습된 모델을 고정한 조건의 탐색적 추정치입니다.

또한 RNA 추가 후 Sensitivity는 증가했지만 Specificity는 다소 감소했습니다. 실제 임상적 활용을 검토하려면 분류 임계값에 따른 균형도 추가로 평가해야 합니다.

Held-out Test Set ROC and PR Curves

ROC curves
350 dpi PNG

Precision–Recall curves
350 dpi PNG

5. Python 코드 및 결과 파일

실제로 실행한 분석 코드와 학습 완료된 모델 4개를 모두 저장했습니다.

Complete ML Analysis Package
METABRIC_Grade3_Classification_Complete.zip
Python 코드, 실행 환경, CSV 결과, Excel, Figure 및 학습된 모델 4개 포함

주요 개별 파일

파일	다운로드

5. Python 코드 및 결과 파일

실제로 실행한 분석 코드와 학습 완료된 모델 4

Complete ML Analysis Package

METABRIC_Grade3_Classification_Comp

Python 코드, 실행 환경, CSV 결과, Excel, Figu

주요 개별 파일

파일	다
Python 전체 분석 코드	de
분석 결과 Excel (8 sheets)	M
최종 Test 성능	He
Training CV 결과	Tra
RNA 추가 효과 비교	Pa
환자별 Test 예측확률	He
분석 방법 및 실행 결과	Re

Python 실행 방법

압축파일에 포함된 `requirements.txt` 를 이용
일한 분석을 재현할 수 있습니다.

Bash

```
pip install -r requirements.txt

python develop_metabric_grade3_models.py \
    --input METABRIC_RNA_Mutation.csv \
    --output-dir ./reproduced_results
```

저장된 4개 모델(`.joblib`)을 다시 불러와 Test
것을 확인했습니다. 압축파일 무결성 검사도 통

6. 연구적 해석

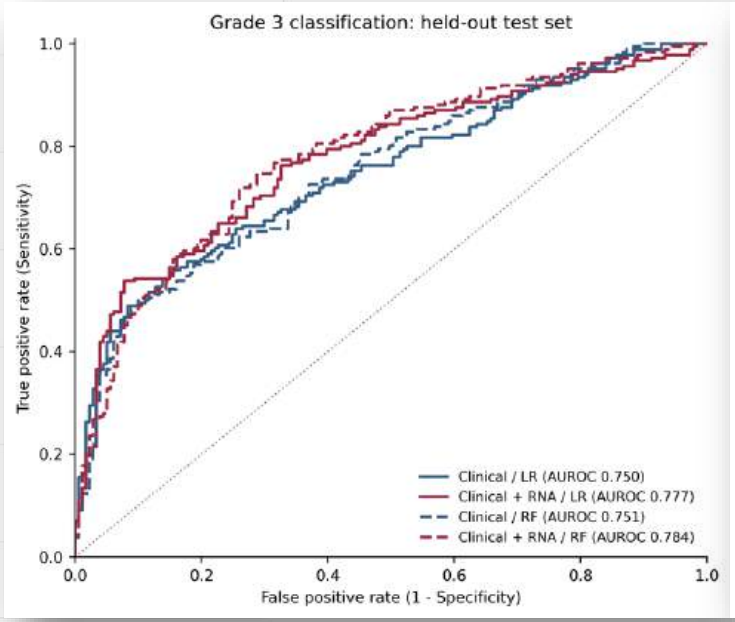
이번 실습 결과는 지정한 8개 RNA 발현변수가 임상정보에 추가적인 Grade 3 분류 정보를 제공할 가능성을 보여줍니다.

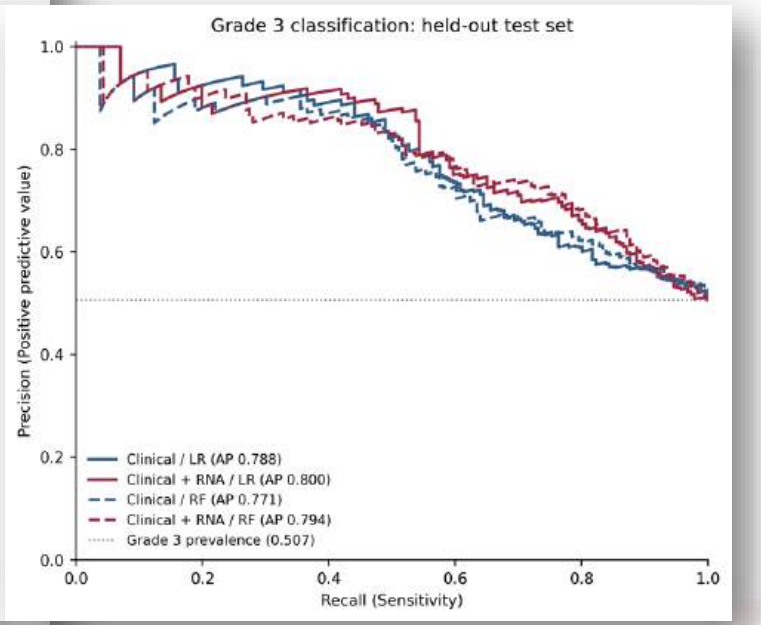
다만 가장 높은 Test AUROC를 기록한 모델을 Test 결과에 근거해 새롭게 선택해서는 안 됩니다. 최종 모델 선정은 사전에 정의한 Training CV 기준을 따르는 것이 적절합니다.

또한 현재 검증은 내부 Hold-out Validation입니다. 독립적인 외부 검증 결과가 아니며, RNA 데이터의 추가로 관찰된 성능 차이를 인과적 효과 또는 임상적 유용성의 입증으로 해석해서는 안 됩니다.

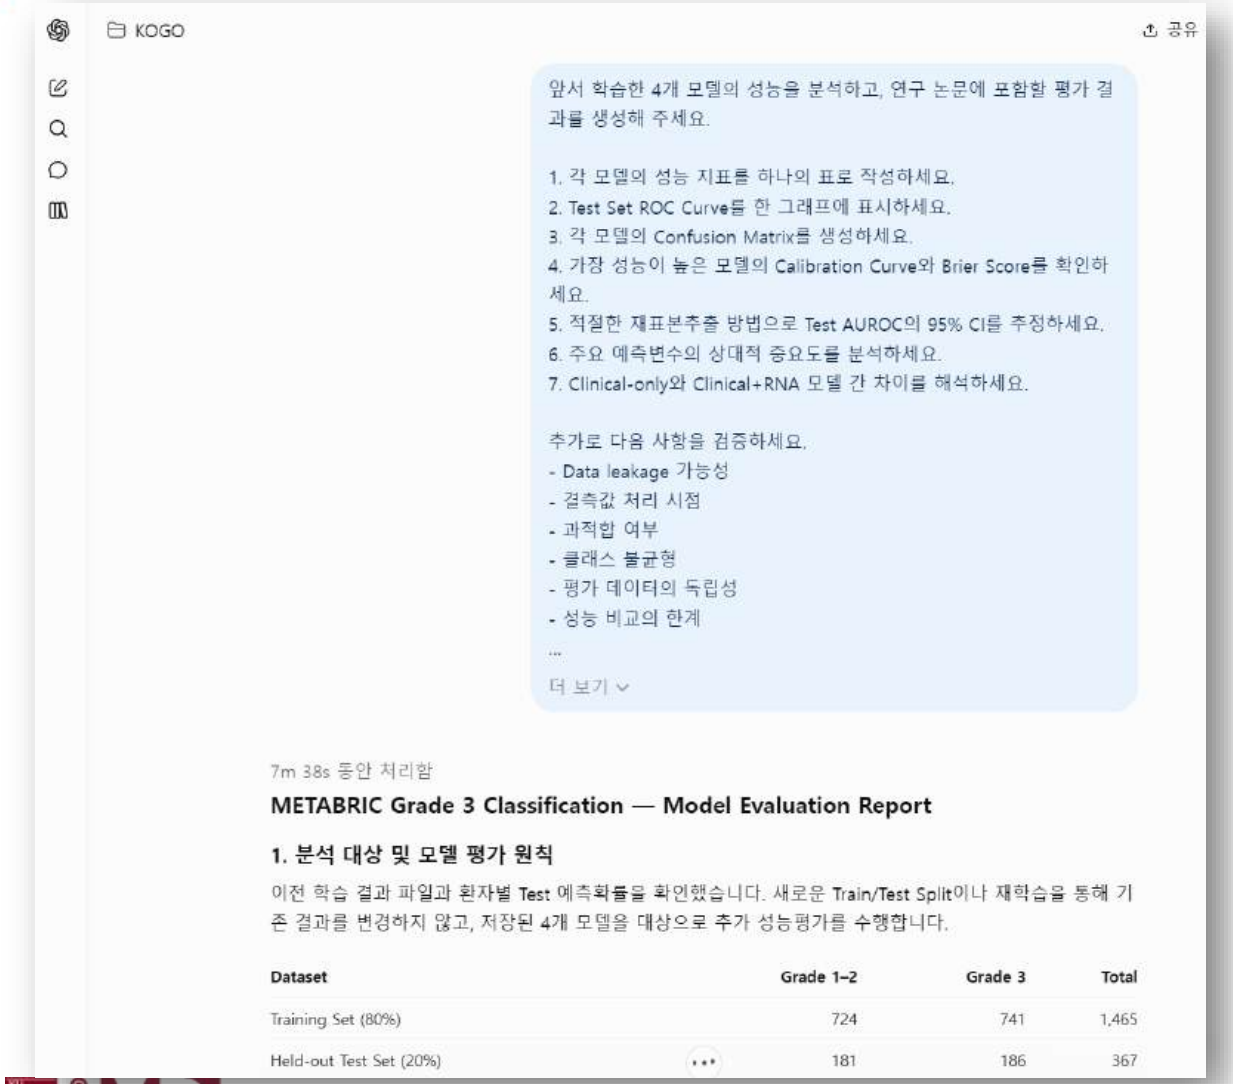
- develop_metabric_grade3_models.py
  코드
- METABRIC_Grade3_ML_Results.xlsx
  Excel
- Heldout_Test_Performance.csv
  스프레드시트
- Training_CV_Selected_Models.csv
  스프레드시트
- Paired_Incremental_Performance.csv
  스프레드시트
- Heldout_Test_Predictions.csv
  스프레드시트
- Results_and_Methods.md
  문서

접기





ChatGPT를 이용한 머신러닝



앞서 학습한 4개 모델의 성능을 분석하고, 연구 논문에 포함할 평가 결과를 생성해 주세요.
1. 각 모델의 성능 지표를 하나의 표로 작성하세요.
2. Test Set ROC Curve를 한 그래프에 표시하세요.
3. 각 모델의 Confusion Matrix를 생성하세요.
4. 가장 성능이 높은 모델의 Calibration Curve와 Brier Score를 확인하세요.
5. 적절한 재표본추출 방법으로 Test AUROC의 95% CI를 추정하세요.
6. 주요 예측변수의 상대적 중요도를 분석하세요.
7. Clinical-only와 Clinical+RNA 모델 간 차이를 해석하세요.

추가로 다음 사항을 검증하세요.
- Data leakage 가능성
- 결측값 처리 시점
- 과적합 여부
- 클래스 불균형
- 평가 데이터의 독립성
- 성능 비교의 한계

실제 분석 결과를 근거로 Publication-ready Table과 Figure를 생성하세요.

7m 38s 동안 처리함

METABRIC Grade 3 Classi

1. 분석 대상 및 모델 평가 원

이전 학습 결과 파일과 환자별 Tes
존 결과를 변경하지 않고, 저장된

Dataset
Training Set (80%)
Held-out Test Set (20%)
Total

Positive class는 Grade 3이며, 분류

Table 2. Classification performa

Model	AURO
Clinical LR	0.750
Clinical + RNA LR	0.777
Clinical RF	0.750
Clinical + RNA RF	0.783

LR, Logistic Regression; RF, Rand

모델 선정과 평가의 구분: Test AU
그러나 Training CV 평균 AUROC
다. 연구 논문에서는 전자를 관찰
해석하지 않는 것이 중요합니다.

2. Test AUROC의 95% Confi

5,000회 Class-stratified Bootstrap
습니다.

Model
Clinical LR
Clinical + RNA LR

2. Test AUROC의 95% Confide

5,000회 Class-stratified Bootstrap을
습니다.

Model
Clinical LR
Clinical + RNA LR
Clinical RF
Clinical + RNA RF

이 신뢰구간은 이미 학습된 모델과
변동성까지 포함하지는 않습니다.

3. Publication-ready Figures

모든 Figure는 흰색 배경, 영문 축·범
파일 무결성 검증을 완료했습니다.

Figure 1. ROC Curves of the Four

ROC curves

Figure 2. Confusion Matrices

Confusion matrices

혼동행렬의 실제 수치는 다음과 같

Model
Clinical LR
Clinical + RNA LR
Clinical RF
Clinical + RNA RF

두 알고리즘 모두 RNA 추가 후 Gra

Figure 3. Calibration Curve

관찰된 Test AUROC가 가장 높은 Cl
37명)의 Calibration Curve를 생성했

Calibration curve

Model
Clinical LR
Clinical + RNA LR
Clinical RF
Clinical + RNA RF

Random Forest가 가장 높은 Te
낮았습니다. 즉, 관찰된 분류 성

4. Relative Predictor Impo

변수 중요도는 Test Set을 사용
Importance로 평가했습니다.

각 변수에 대해 폴드당 2회, 총

Figure 4. Training-only Perm

Permutation importance

주요 변수들의 평균 AUROC 감

Integrated LR
er_status
her2_status
pten
pr_status
brca1

두 통합 모델 모두 ER status의
등이 상위권에 포함됐으나, 변수
이를 독립적인 생물학적 효과나

5. Clinical-only vs. Clinical

두 모델의 차이는 동일 환자를

Algorithm
Logistic Regression
Random Forest

두 알고리즘에서 RNA 추가 후
두 0을 포함했습니다.

따라서 이번 결과는 8개 RNA 변
계적으로 확정된 성능 향상이니

6. Data Leakage 및 연구 E

점검 항목	실제 확인 결과
Target leakage	Grade, NPI, 치료·생
결측값 처리	Training 결측 15건, 기록 단위)
전처리 누출	Imputation, Scaling
대상자 중복	Train/Test patient_i
클래스 불균형	Train Grade 3 약 5(
과적합	RF 모델에서 Trainir
외부 검증	별도 외부 데이터 입

특히 Random Forest의 과적합

Model
Clinical LR
Integrated LR
Clinical RF
Integrated RF

5. Clinical-only vs. Clinical

Integrated LR	0.7844	0.7712	0.0133
Clinical RF	0.8468	0.7507	0.0961
Integrated RF	0.9725	0.7700	0.2025

RF의 최종 Test AUROC가 CV와 유사하더라도, 학습 폴드 성능과 내부 검증 성능의 큰 차이는 과적합 경향을 보여줍니다.

추가적인 제한점: Test Set은 환자 수준에서 분리된 내부 검증자료이지만 이미 이전 분석에서 성능을 확인한 자료입니다. 이번 분석에서는 이를 이용한 재학습이나 하이퍼파라미터 수정은 하지 않았습니다. 향후 추가 모델 개발이나 모델 확정을 위해서는 새로운 검증자료를 확보하는 것이 적절합니다.

7. 최종 결과 파일

Complete Publication Package

METABRIC_Grade3_Model_Evaluation_Package.zip ↗

총 35개 파일. 평가 코드, 학습된 모델 4개, CSV, Excel, PNG/PDF Figures 및 영문 Results·Figure Legends 포함

주요 결과물	파일
Publication-ready Table 2 및 상세 결과 (Excel)	Model Evaluation.xlsx ↗
전체 재현 Python 코드	evaluate_metabric_models.py ↗
영문 Results, Methods, Figure Legends	Publication Report.md ↗
Test AUROC 및 95% CI	Performance and CI.csv ↗
전체 변수 중요도	Permutation Importance.csv ↗

코드 문법, 모델별 예측지표 재계산, 변수 중요도, Figure 해상도 및 압축파일의 무결성 검사를 모두 통과했습니다.

최종 연구적 판단: 본 연구는 유전자 발현정보의 추가적 분류 가능성을 탐색하는 연구로 보고하는 것이 적절합니다. 가장 높은 Test AUROC만을 근거로 RF를 최종 모델로 선정하기보다는, 기존 Training CV 선정 기준을 유지하고 Logistic Regression과 Random Forest를 함께 비교 보고할 것을 권장합니다.

ChatGPT를 이용한 머신러닝 모델 만들기



Table 2. Classification performance of prespecified models

Held-out test set n = 367 (186 Grade 3; 181 Grade 1–2); threshold = 0.50.

Model	Train 5-fold CV AUROC	Test AUROC (95% CI)	AUPRC	Accuracy	Sensitivity	Specificity	F1 score	Brier score
Clinical only / LR	0.744 ± 0.020	0.750 (0.700–0.799	0.788	0.692	0.575	0.812	0.654	0.197
Clinical + RNA / LR	0.771 ± 0.015	0.777 (0.728–0.823	0.8	0.706	0.651	0.762	0.691	0.188
Clinical only / RF	0.751 ± 0.014	0.751 (0.700–0.799	0.771	0.681	0.602	0.762	0.657	0.199
Clinical + RNA / RF	0.770 ± 0.010	0.784 (0.734–0.828	0.794	0.703	0.651	0.757	0.689	0.189

Values from the fixed test set. AUROC 95% CI: 5,000 class-stratified bootstrap resamples (percentile interval).

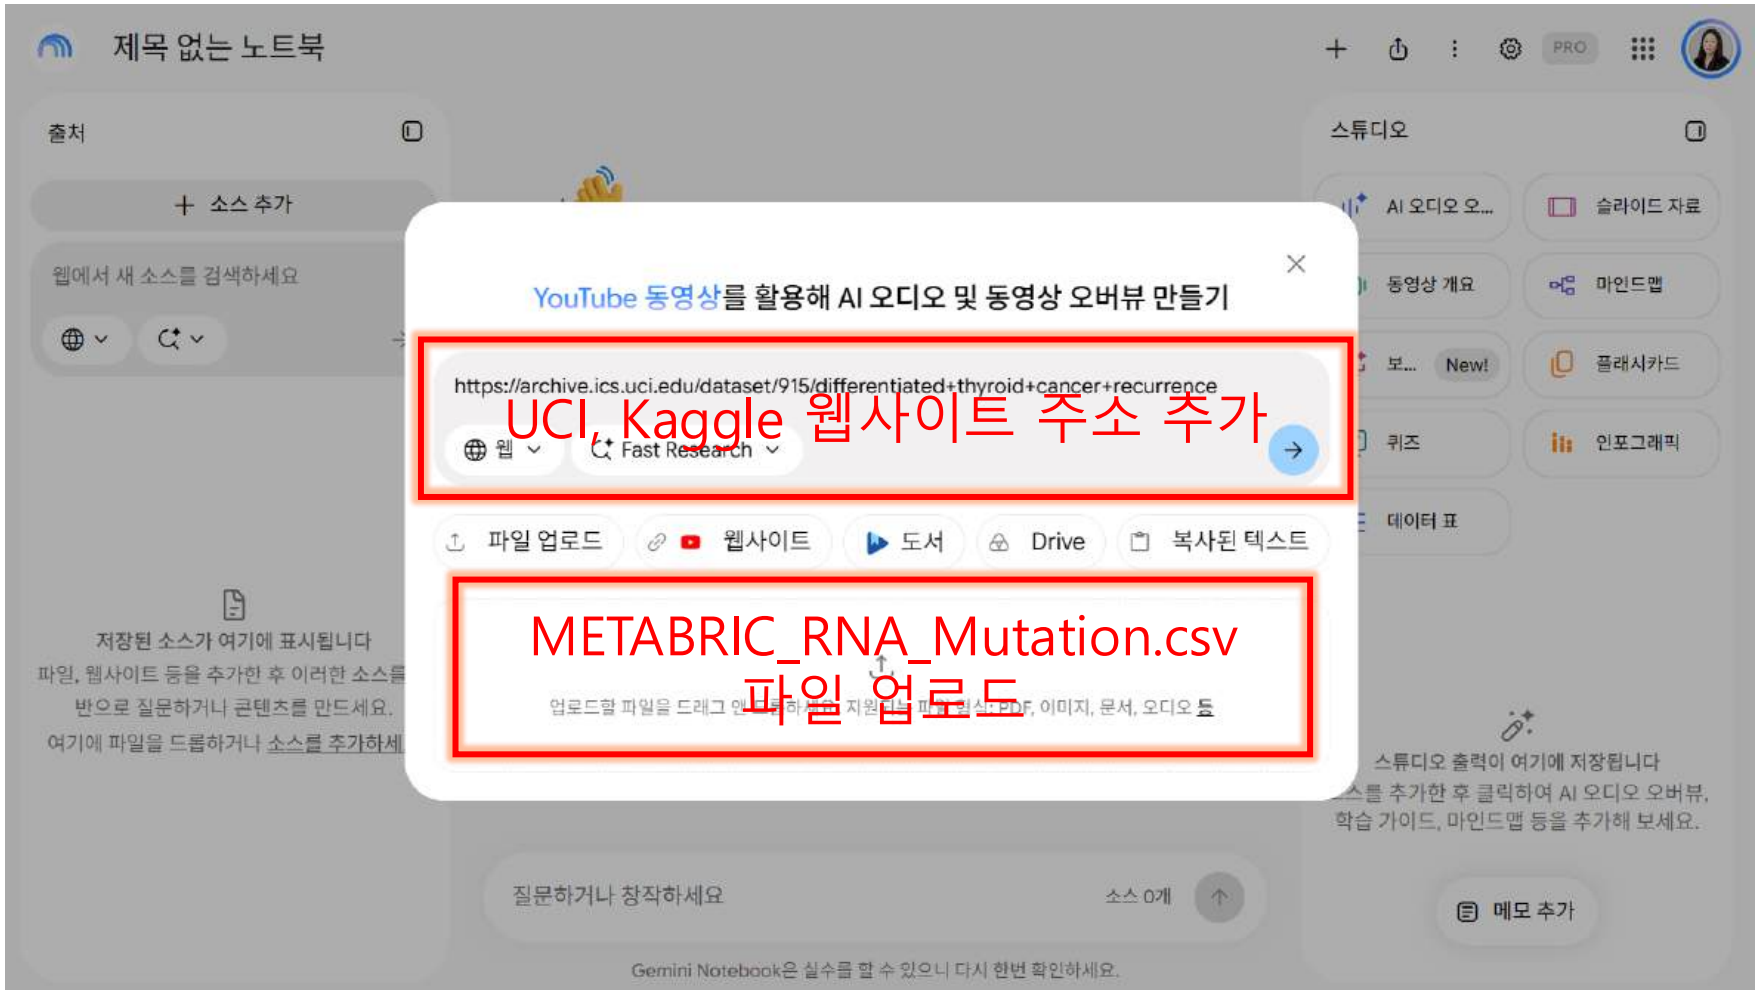
AUPRC is non-interpolated average precision. Lower Brier score is better; the highest test AUROC is descriptive, not a model-selection rule.

Table 2 - Performance | Raw Test Metrics | Confusion Matrices | Incrementa

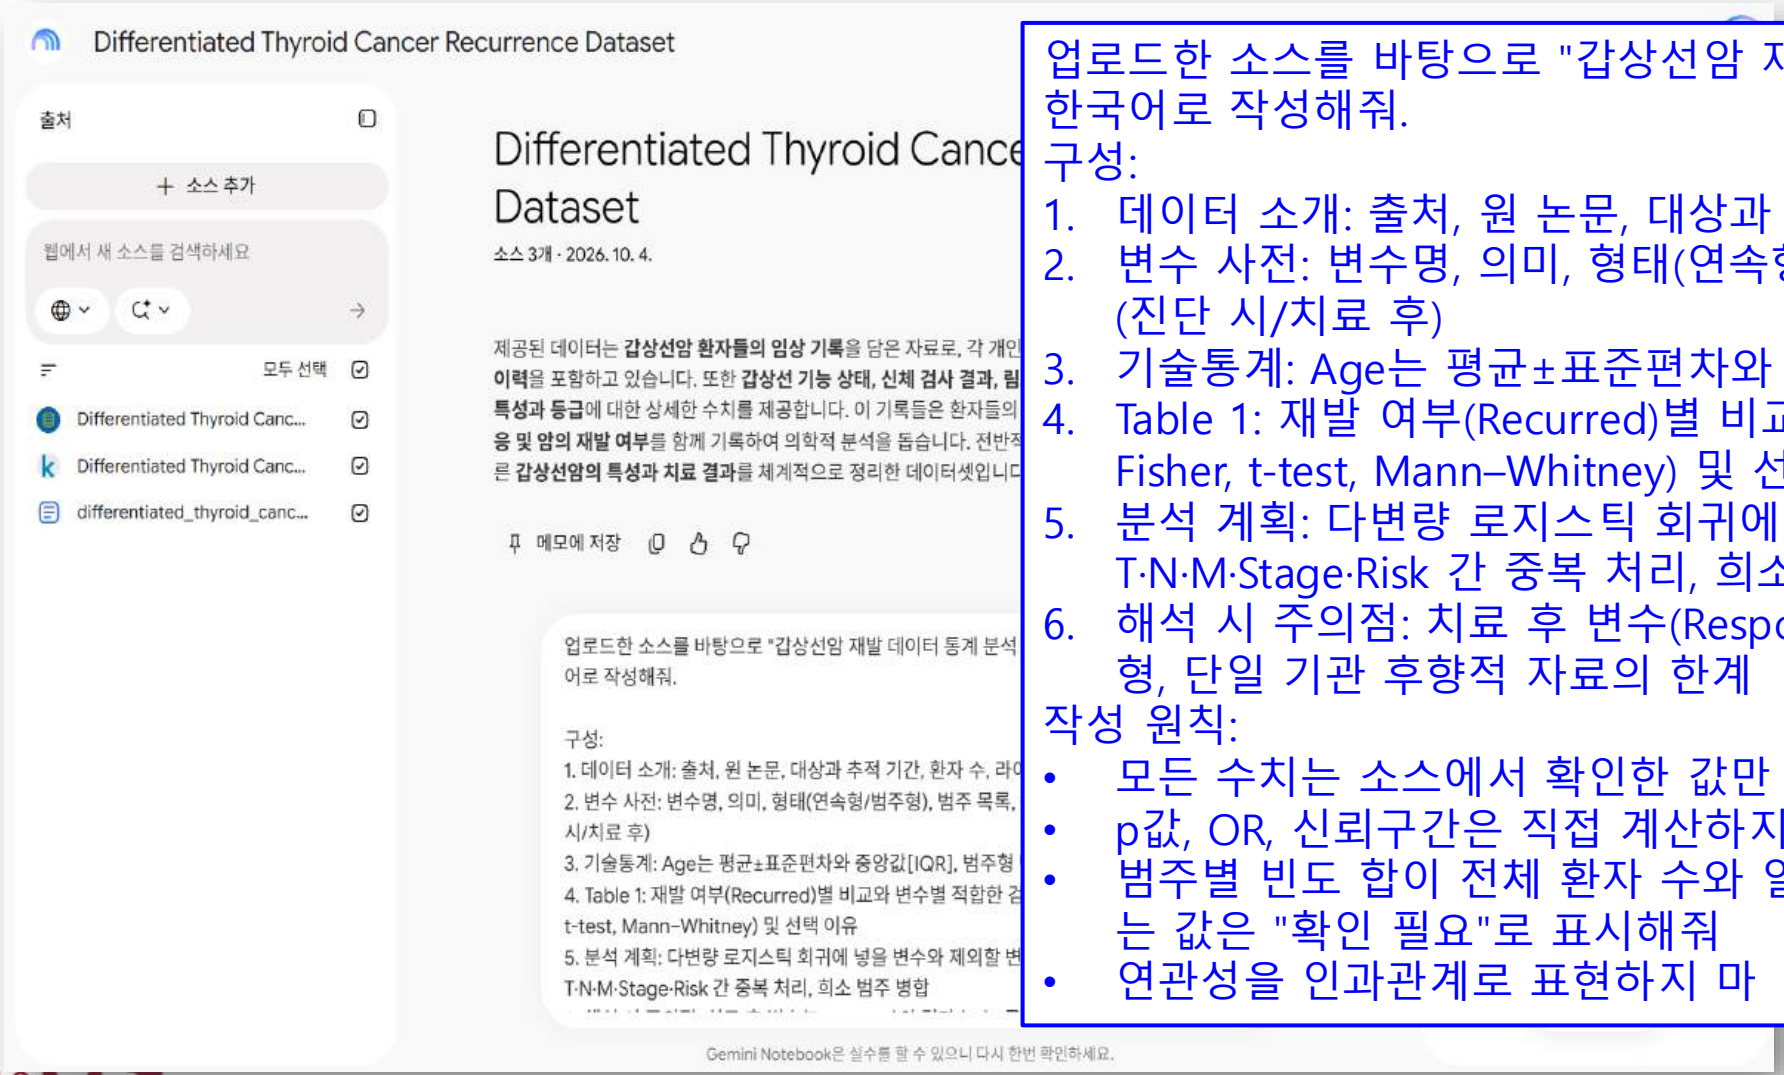
접근성: 조사 필요

NotobookLM을 이용한 데이터 분석 보고서 만들기(1)

- 새 노트북 만들기



NotobookLM을 이용한 데이터 분석 보고서 만들기(2)



업로드한 소스를 바탕으로 "갑상선암 재발 데이터 통계 분석 보고서"를 한국어로 작성해줘.
구성:

1. 데이터 소개: 출처, 원 논문, 대상과 추적 기간, 환자 수, 라이선스
2. 변수 사전: 변수명, 의미, 형태(연속형/범주형), 범주 목록, 측정 시점 (진단 시/치료 후)
3. 기술통계: Age는 평균±표준편차와 중앙값[IQR], 범주형 변수는 n(%)
4. Table 1: 재발 여부(Recurred)별 비교와 변수별 적합한 검정(χ^2, Fisher, t-test, Mann–Whitney) 및 선택 이유
5. 분석 계획: 다변량 로지스틱 회귀에 넣을 변수와 제외할 변수, T·N·M·Stage·Risk 간 중복 처리, 희소 범주 병합
6. 해석 시 주의점: 치료 후 변수(Response)의 결과 누수, 클래스 불균형, 단일 기관 후향적 자료의 한계

작성 원칙:

- 모든 수치는 소스에서 확인한 값만 쓰고, 근거 소스를 인용해줘
- p값, OR, 신뢰구간은 직접 계산하지 말고 "계산 필요"로 표시해줘
- 범주별 빈도 합이 전체 환자 수와 일치하는지 확인하고, 확인되지 않는 값은 "확인 필요"로 표시해줘
- 연관성을 인과관계로 표현하지 마

Differentiated Thyroid Cancer Recurrence

갑상선암 재발 데이터 통계

1. 데이터 소개

- 데이터 출처: UCI Machine Learning
  Hasan) [3] [4]. (DOI: 10.24432/C56
- 원 논문: Borzooei, S., Briganti, G., Go
  "Machine learning for risk stratificat
  study", *Head & Neck* [2] [6]. (DOI: 1
- 연구 대상 및 추적 기간: 분화 갑상선암(
  으로 15년 동안 수집된 후향적 코호트 [1].
- 전체 환자 수: 총 383명 (383개 레코드,
- 라이선스: Creative Commons Attrib

2. 변수 사전 (Variable Diction

데이터셋은 총 17개 변수로 구성되어 있으며
습니다 [8].

변수명	의미 / 설명	형태	범
Age	진단 시 환자 연령 (세)	연속형 (정수)	15
Gender	성별	범주형 (이분)	F
Smoking	현재 흡연 여부	범주형 (이분)	N
Hx Smoking	과거 흡연	범주	N

질문하거나 창작하세요

Gemini Notebook은

Differentiated Thyroid Cancer Recurrence Dat

4. Table 1: 재발 여부(Recurred)별 택

아래 단변량 비교표의 p-value는 작성 원칙에 따라

변수 / 범주	전체 (N=383)	비재발군 (n=275)	재발 (n=10
Age (세)			
- Mean ± SD	40.87 ± 15.13	38.41 ± 12.95	47.11 ± 18.27
- Median [IQR]	37.00 [29.00-51.00]	36.00 [28.00-46.00]	44.50 [31.75 62.00
Gender			
- Female	312 (81.5%)	246 (89.5%)	66 (61.1%
- Male	71 (18.5%)	29 (10.5%)	42 (38.9
Smoking			
- No	334 (87.2%)	259 (94.2%)	75 (69.4
- Yes	49 (12.8%)	16 (5.8%)	33 (30.6
Hx Smoking			

질문하거나 창작하세요

Gemini Notebook은 실수를 할

Differentiated Thyroid Cancer Recurrence Dataset

6. 해석 시 주의점 및 한계점 (Caveats & Limitations)

1. **치료 후 변수(`Response`)의 결과 누수 (Data / Target Leakage):**
   - `Response` 변수(`Excellent` , `Indeterminate` , `Biochemical Incomplete` , `Structural Incomplete`)는 초기 진단 및 치료 계획 수립 시점이 아닌, 치료 후 추적 관찰 과정에서 확인되는 **결과성 지표**입니다 [8] [14].
   - 실제 데이터상 `Structural Incomplete` 반응을 보인 91명 중 **89명 (97.8%)**이 재발(`Recurred = Yes`)로 연결되었고, `Excellent` 반응 208명 중 **207명(99.5%)**이 비재발(`Recurred = No`) 상태를 유지하였습니다 [8].
   - 진단 시점의 재발 예측 모델에 `Response` 변수를 넣을 경우 강력한 결과 누수로 인해 인공적으로 높은 성능(AUC ≈ 1.0)이 측정되므로, 선행 예측 모델 구축 시 `Response` 변수를 독립 변수로 사용하는 해석 오류를 방지해야 합니다.
2. **클래스 불균형 (Class Imbalance):**
   - 전체 383명 중 비재발군은 **275명 (71.8%)**, 재발군은 **108명 (28.2%)**으로 약 **2.5:1**의 불균형을 보입니다 [8].
   - 단순 정확도(Accuracy)만을 평가지표로 활용할 경우 대다수 클래스(비재발)로 편향된 결과를 초래할 수 있으므로, **Balanced Accuracy**, **ROC-AUC**, **PR-AUC**, **민감도(Sensitivity)**, **특이도(Specificity)**를 종합적으로 보고해야 합니다.
3. **단일 기관 후향적 코호트 자료의 한계 (Single-Center Retrospective Bias):**
   - 본 데이터는 단일 의료기관(Hamadan University of Medical Sciences)에서 15년에 걸쳐 수집된 후향적 데이터입니다 [1] [—].
   - 환자군선택 편향(Selection Bias) 및 해당 기관 특유의 수술/치료 프로토콜 영향을 받을 수 있으므로, 타 기관이나 타 인구집단에 직접 적용하기 전 **다기관 외부 검증(External Validation)**이 필수적입니다.
4. **인과관계 표현 금지 (Association vs Causation):**
   - 본 분석은 관찰 연구 데이터에 기반한 **통계적 연관성(Association)** 평가입니다.
   - 따라서 *"X 변수가 암 재발을 직접 유발한다/원인이 된다"*와 같은 **인과적 표현은 절대 사용해서는 안 되며**, *"X 변수는 갑상선암 재발 위험도 증가와 통계적으로 유의미한 연관성을 보인다"*로 해석을 제한해야 합니다.

💡 **다음 단계 제안:** 본 보고서의 Table 1 단변량 비교표에서 "계산 필요"로 표기된 실제 통계 검정 수치(p-value)를 Python 스크립트로 직접 산출하여 수치표를 완성하거나, 다변량 로지스틱 회귀 분석 모델을 구축해보시겠어요?

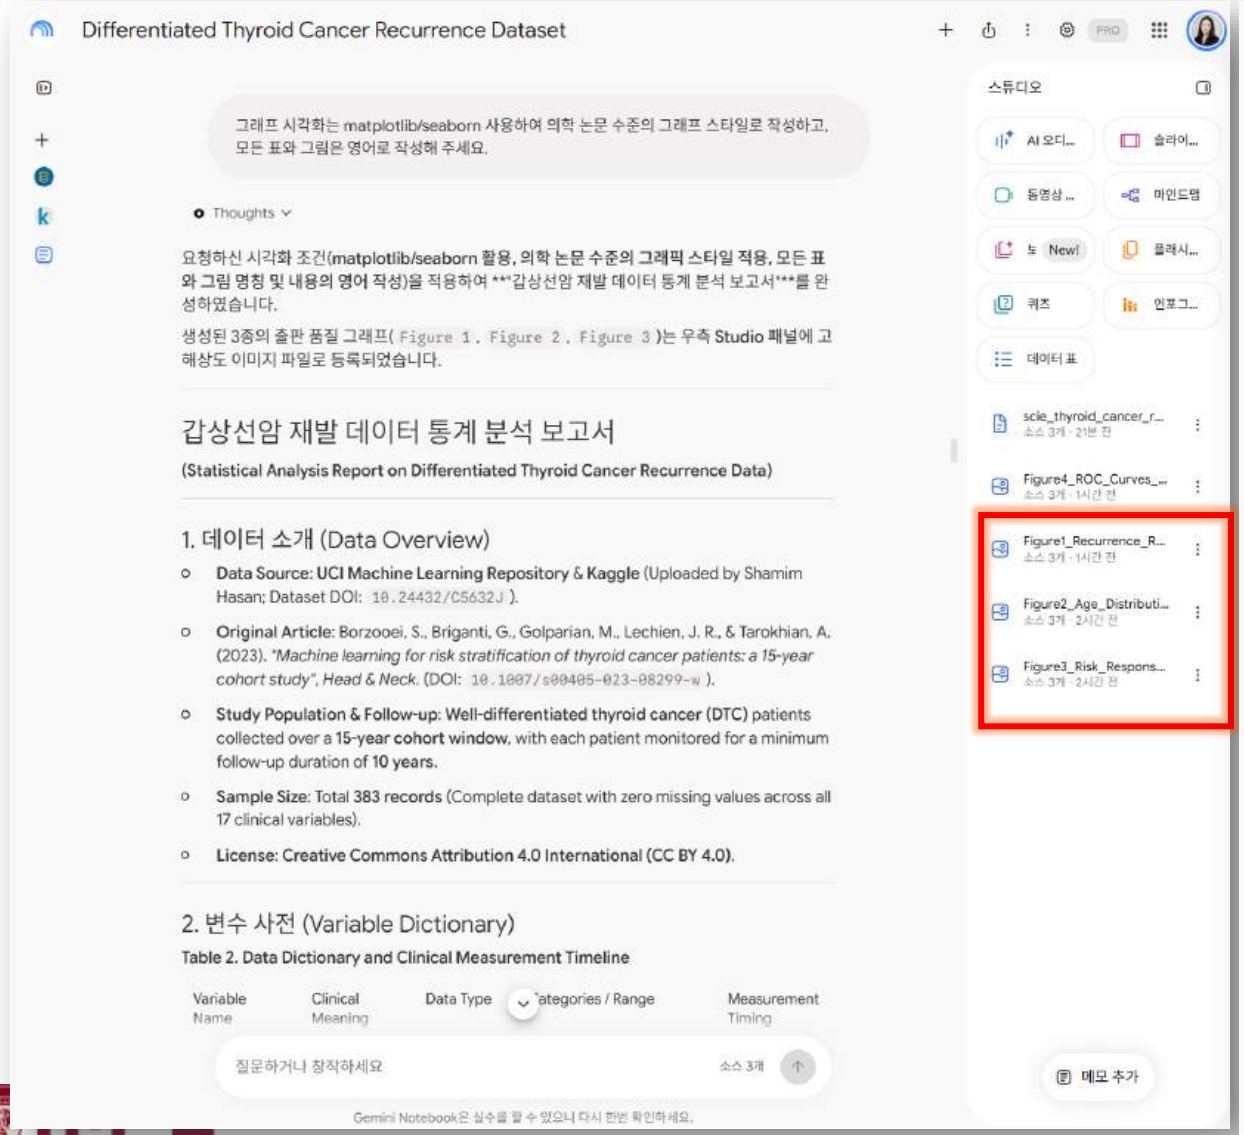
질문하거나 창작하세요

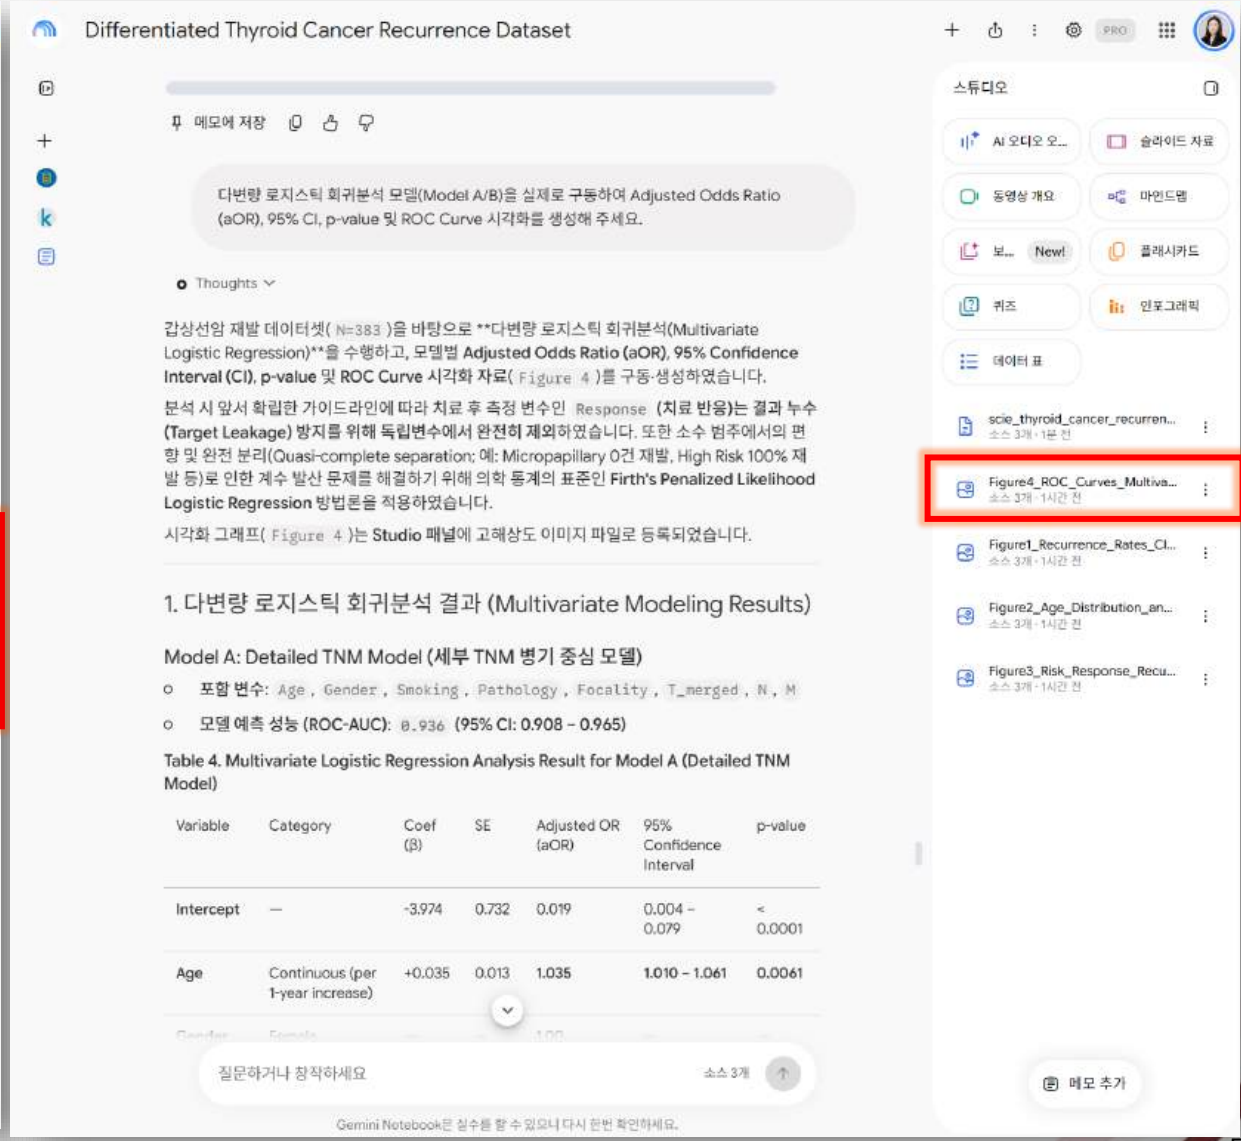
소스 3개

Gemini Notebook은 실수를 할 수 있으니 다시 한번 확인하세요.

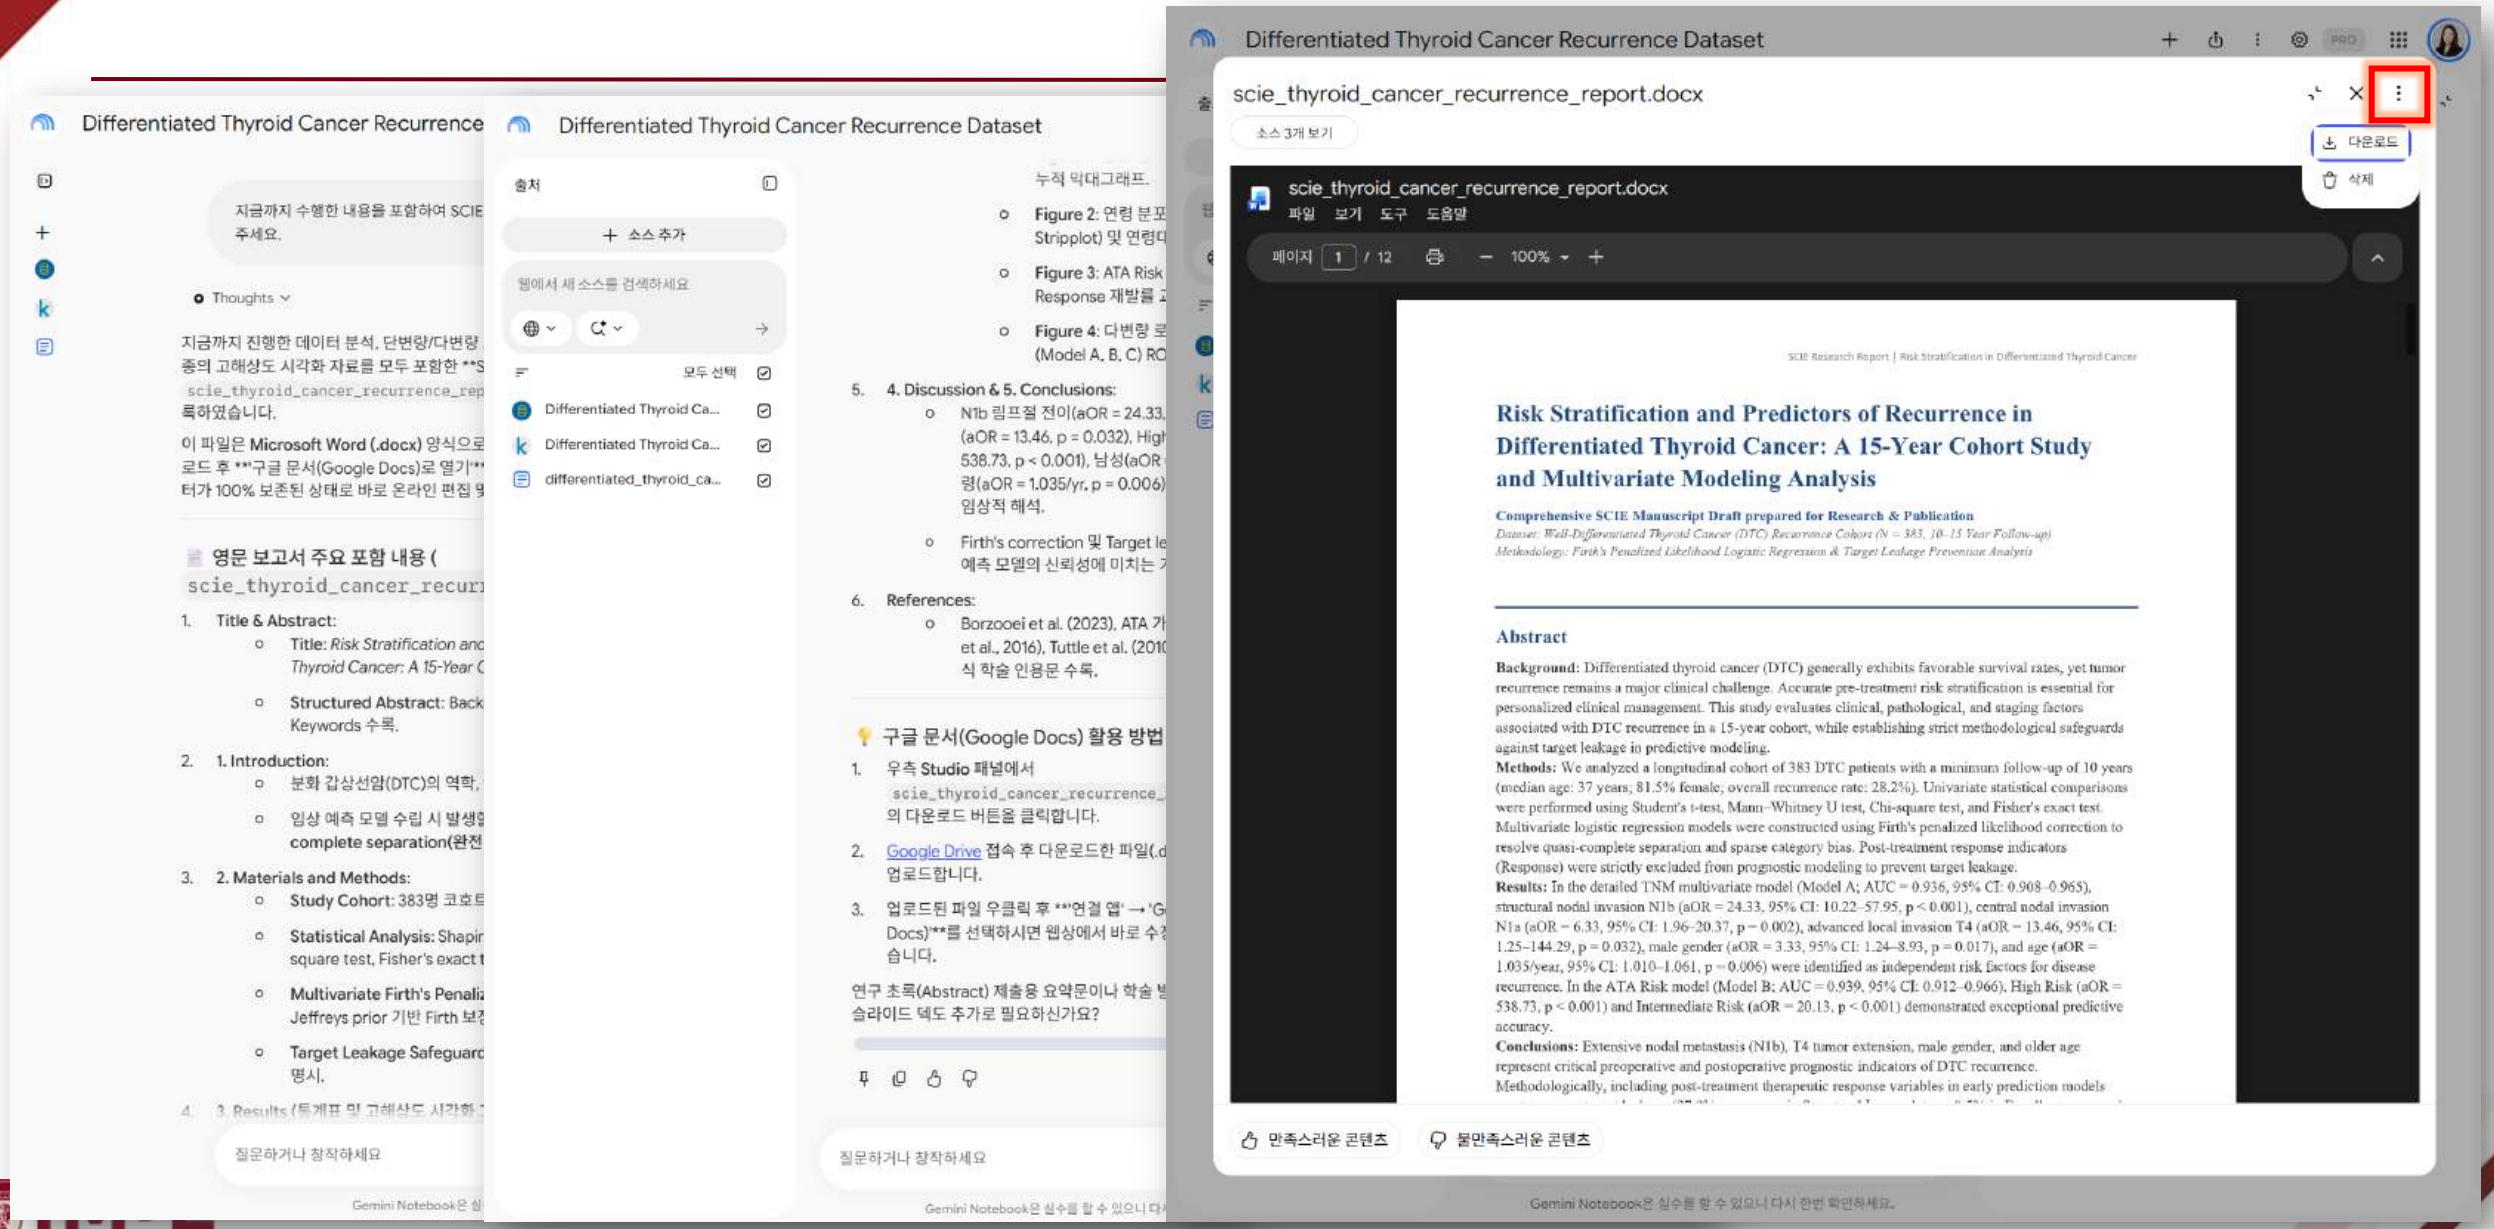
그래프 시각화는 matplotlib/seaborn 사용하여 의학 논문 수준의 그래프 스타일로 작성하고, 모든 표와 그림은 영어로 작성해 주세요.

다변량 로지스틱 회귀분석 모델(Model A/B)을 실제로 구동하여 Adjusted Odds Ratio (aOR), 95% CI, p-value 및 ROC Curve 시각화를 생성해 주세요.





지금까지 수행한 내용을 포함하여 SCIE 논문에 작성할 영문 보고서 파일을 구글 docs로 만들어 주세요.



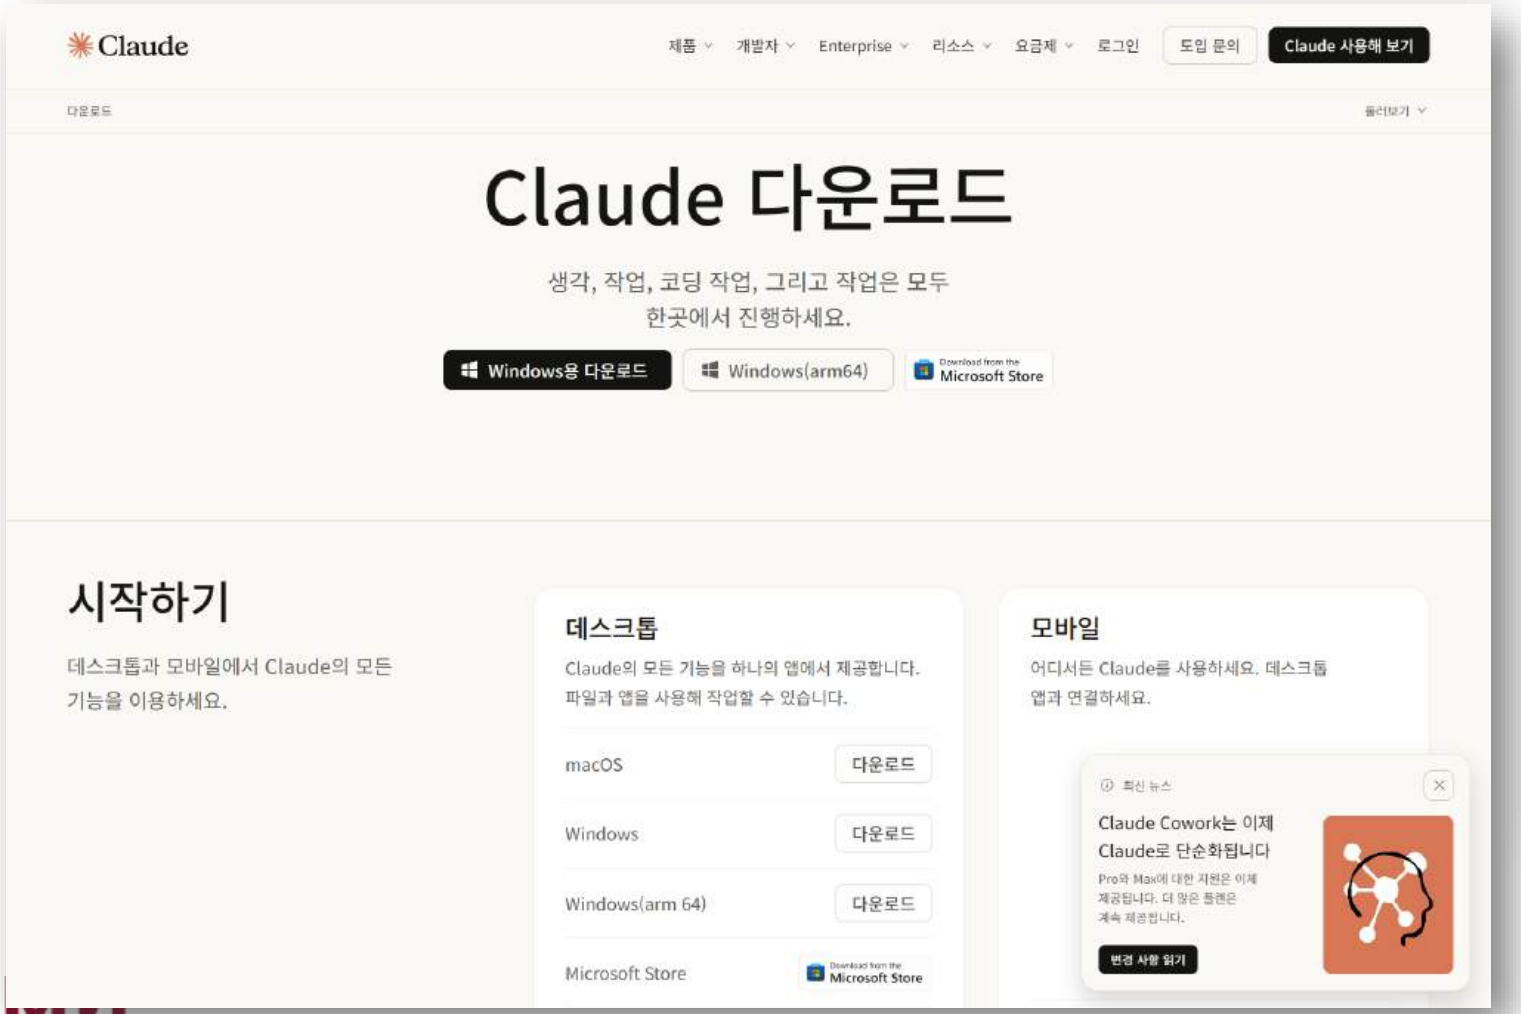
Claude

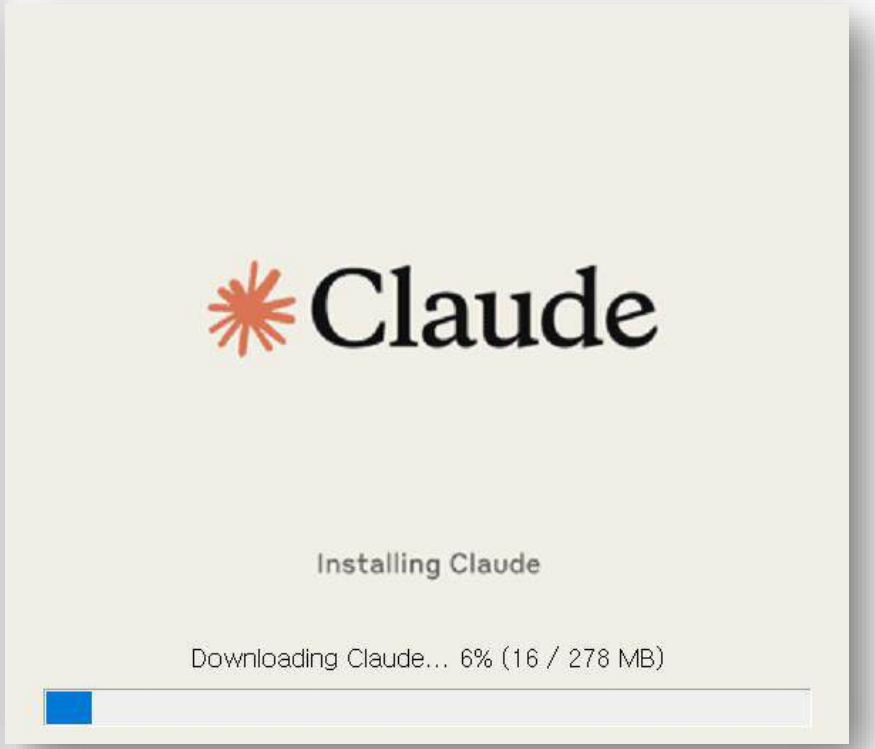
- Cowork는 Claude Code와 같은 에이전트 구조를 터미널 없이 쓰게 만든 기능

구분	Claude Chat (웹·앱)	Claude Cowork (웹·앱) (데스크톱 앱 권장)	Claude Code (터미널·IDE)
입력 방식	파일 업로드	데스크톱 앱: 내 PC 폴더 연결 / 웹·모바일: 파일 업로드	코드 저장소
작업 단위	질문 1개 → 답 1개	결과물 1건을 위임 → 다단계 자율 실행	코드 변경 단위
산출물	대화 속 답변, 개별 파일	폴더에 저장된 표·그림·문서·스크립트 묶음	커밋 가능한 코드
연구 활용 적합	개념 질문, 짧은 초안	분석 패키지, 원고·계획서 묶음, 반복 업무	분석 파이프라인·패키지 개발
대상	모든 연구자	코딩 부담 없이 자동화하려는 연구자	코드를 직접 관리하는 연구자

Claude App 다운로드 및 설치

- https://claude.com/ko/download





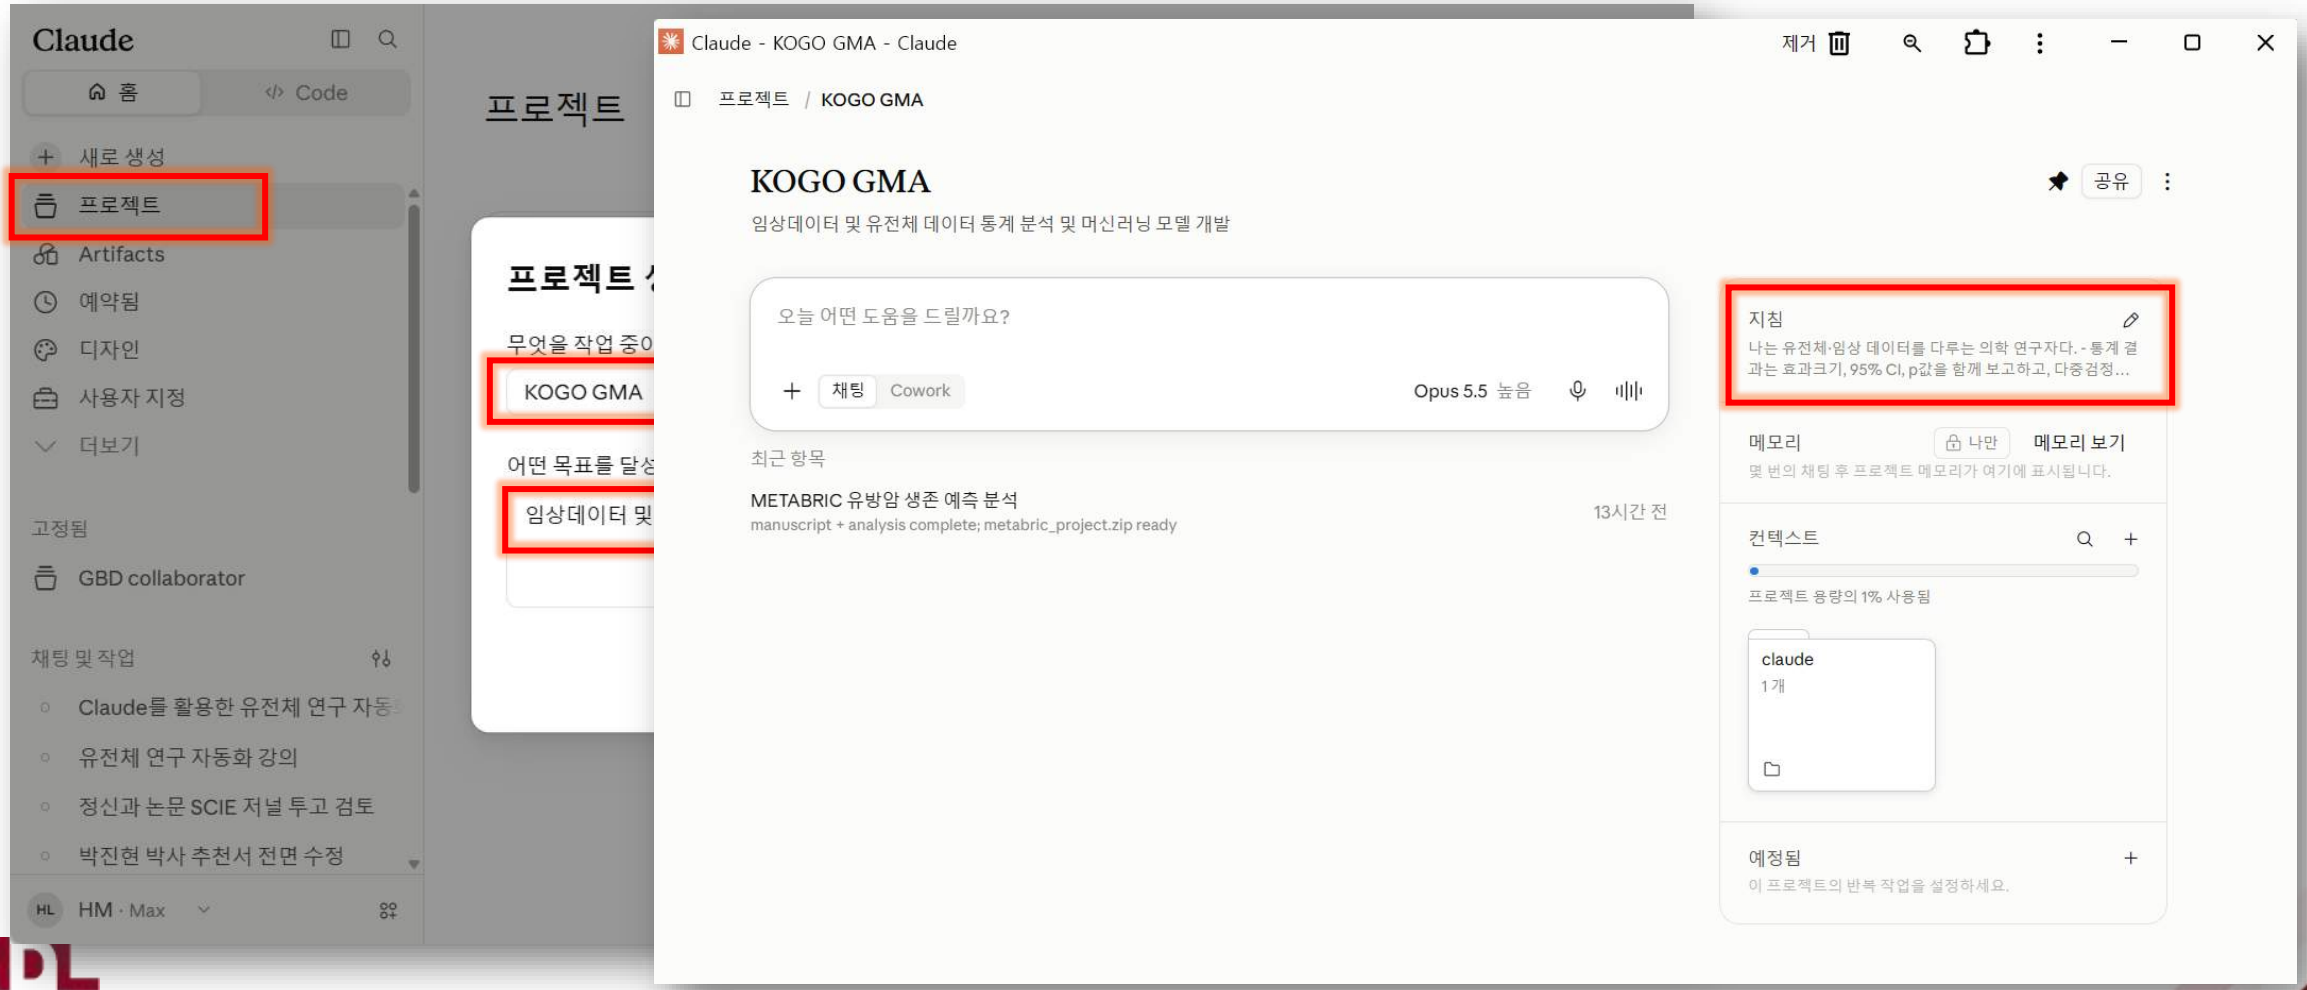
Claude Cowork

기능	연구에서 활용하는 법
폴더 연결	데스크톱 앱에서만 가능하다. 프로젝트마다 전용 폴더 1개만 연결하고, 홈 폴더 전체는 연결하지 않는다.
전역 지시문 (Settings>Cowork)	"통계 결과는 효과크기·95% CI·p값을 함께, 그림은 300 dpi" 같은 연구실 공통 규칙
폴더 지시문	이 연구의 질문, 변수 정의, 금지사항, 산출물 규칙 (실습 0에서 작성)
Projects	관련 작업을 파일·지시문·메모리가 있는 작업공간으로 묶는다. 논문 1편 = 프로젝트 1개 권장
플러그인·스킬	반복되는 형식 작업(Word·Excel·PPT 생성 등)을 표준화한다.
예약 작업 (/schedule)	주간 문헌 모니터링, 월간 진행 보고서. 클라우드 세션은 PC가 꺼져 있어도 돌지만, 로컬 폴더를 읽는 작업은 그 시각에 데스크톱 앱이 열려 있어야 한다.
진행 중 개입	실행 중에도 방향을 바꾸라고 지시할 수 있다. 파일 영구 삭제는 반드시 사용자 허락을 받는다.

- **규제 데이터 금지**: Cowork 세션은 Anthropic 서버에서 실행되므로, 데스크톱 앱을 통해 연 로컬 파일도 내 PC가 아니라 Anthropic 서버에서 처리된다.
- **사용량**: Cowork는 일반 채팅보다 사용량을 많이 소모한다. 단순 질문은 채팅으로, 다단계 산출물만 Cowork로 수행한다.
- **조용한 오류**: 코드가 에러 없이 돌아가도 결과변수 코딩이 잘못되어 있으면 결과는 그럴듯하게 틀린다.(실습에서 직접 확인)
- **앱 유지**: 세션은 앱을 닫아도 클라우드에서 계속되지만, 로컬 폴더를 쓰는 실습 중에는 데스크톱 앱을 열어 두고 컴퓨터가 절전모드에 들어가지 않게 한다.

Claude 프로젝트 생성

- https://claude.com/ko/download



Claude Cowork 작업



Claude에게 "어떻게 일할지" 알려주는 규칙

Claude가 "이 프로젝트에서 이전에 무엇을 했는지" 기억하는 공간

Claude에게 "무엇을 참고해서 일할지" 제공하는 자료실

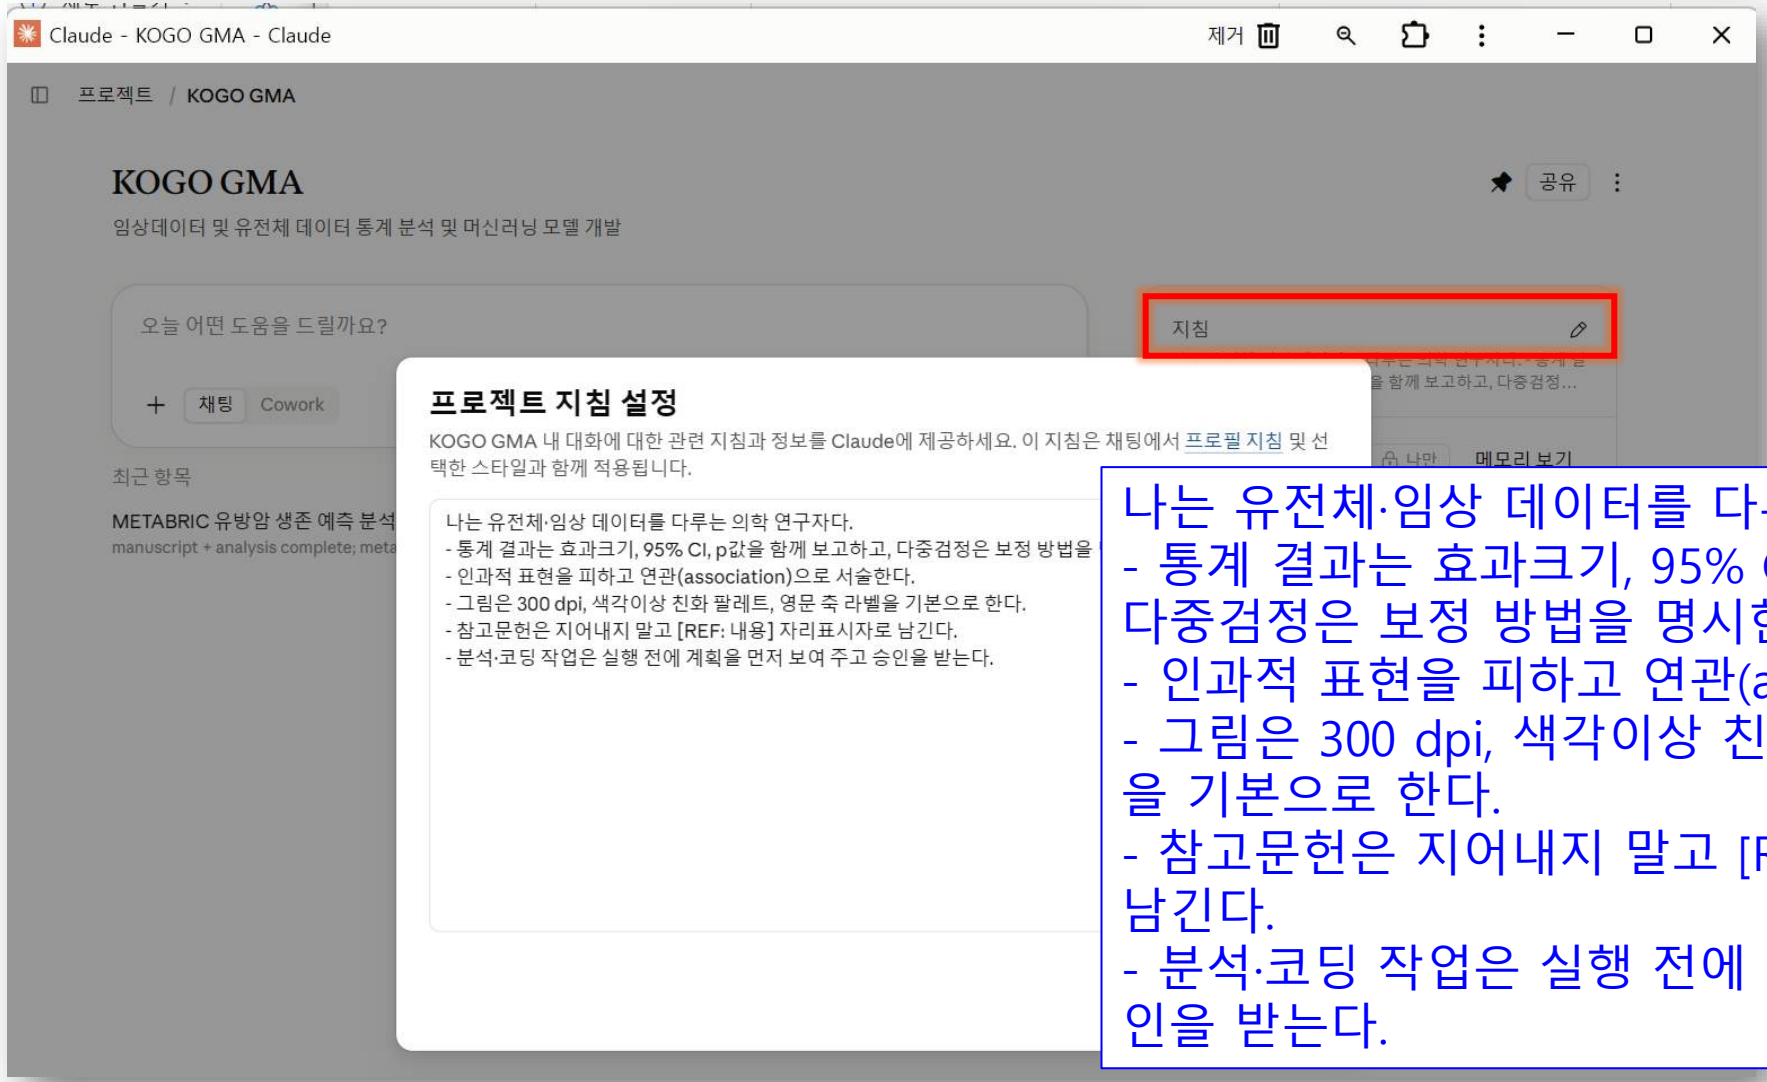
Claude에게 "언제 다시 일할지" 예약하는 기능

Claude Cowork / ChatGPT Work

항목	수동 승인	자동 승인	모든 승인 건너뛰기
영문 메뉴	Manually approve	Automatically approve	Skip all approvals
Claude가 작업 전 멈춤	예	대부분 아니오	아니오
사람이 직접 승인	매 작업마다	필요한 경우만	하지 않음
Claude의 안전성 검사	있음	있음 — 모든 action에 대해	없음
위험한 작업 자동 차단	일부	있음	없음
작업 속도	느림	빠름	가장 빠름
사용자 개입	매우 많음	적음	거의 없음
안전성	★★★★★	★★★★☆	★★☆☆☆
추천 용도	민감/중요 작업	일반적인 Cowork 작업	완전히 신뢰하는 반복 작업

✓ **자동 승인에서는 Claude가 각 action을 실행하기 전에 안전성을 검사함.** 데이터 유출이나 prompt injection 같은 위험을 감지하면 해당 작업을 자동 차단하거나, 필요한 경우 사용자에게 다시 질문함. 반면 **모든 승인 건너뛰기에서는 이러한 자동 안전성 검사조차 하지 않기에 주의 필요함.**

Claude 프로젝트 지침 작성



나는 유전체·임상 데이터를 다루는 의학 연구자다.
- 통계 결과는 효과크기, 95% CI, p값을 함께 보고하고, 다중검정은 보정 방법을 명시한다.
- 인과적 표현을 피하고 연관(association)으로 서술한다.
- 그림은 300 dpi, 색각이상 친화 팔레트, 영문 축 라벨을 기본으로 한다.
- 참고문헌은 지어내지 말고 [REF: 내용] 자리표시자로 남긴다.
- 분석·코딩 작업은 실행 전에 계획을 먼저 보여 주고 승인을 받는다.

Claude – 토큰 절약 프롬프트

[사용량 절약 규칙]
- 데이터프레임 전체를 출력하지 마. 확인은 shape, head(5), 요약 통계만
- 긴 결과(유전자별 결과, 모델 계수 등)는 csv로 저장하고 화면에는 상위 10행만
- 코드는 파일로 저장해 실행하고, 전체 코드나 코드 설명을 대화에 다시 붙이지 마
- 생성한 그림은 열어 보지 마. 그림 검증이 필요하면 내가 지정한 1장만
- 진행 보고는 단계마다 3줄 이내, 숫자 중심으로
- 오류가 나면 traceback 마지막 15줄만 보고 실패한 스크립트만 고쳐 재실행. 성공한 단계는 다시 돌리지 마
- 필요한 수치는 results/summary.json에 모으고, 이후 단계에서는 원 데이터 대신 그 파일만 읽어
- 문서는 마크다운으로 먼저 쓰고, Word·TIFF 변환은 마지막에 1회만
- 웹 검색은 내가 요청한 단계에서만 하고, 결과는 표 1개로 정리

Claude Cowork-프롬프트(1)

[역할과 목표]
너는 유전체·임상 데이터 분석과 SCIE 논문 작성을
연구보조원이다.
첨부한 METABRIC_
3를 순서대로 끝까
모든 산출물을 하나
지막에 zip으로 내

연구 질문:
유방암 환자에서 진
돌연변이가 전체 생

[데이터]
- 1–31열 임상, 32–
693열 체세포 돌연
- 첨부 원본은 수정

[공통 규칙]
- Python, random_state=42.
계별 .py로 저장하고 실제로
- 통계 결과는 효과크기, 95%
사유를 함께. 다중검정은 BH-
- 그림은 300 dpi PNG(원고용
레트, 영문 축 라벨
- 예측모델 전처리(결측 대체·
서만 fit
- 인과 표현 금지, 연관으로 서
말고 [REF: 내용] 자리표시자
- 각 STAGE가 끝날 때마다 3–
승인 없이 다음 STAGE로 진행
- 단, 아래 [정지 조건]에 해당
물어볼 것

[미리 확정한 분석 결정]
- 사망 사건: overall_survival == 0 (이 데이터는 1=생존). STAGE 0에서 death_from_cancer와 교차표로 반드시 검증
- 추적기간: overall_survival_months
- PAM50 'NC' 제외, 기준 범주 LumA
- 돌연변이: 값이 "0"이 아니면 1. 예측모델에는 빈도 3% 이상만 사용
- 결측: 통계 분석은 완전사례(제외 인원 보고), 예측모델은 학습셋 기준 대체
- 예측모델 제외 변수: patient_id, overall_survival, death_from_cancer, cohort, nottingham_prognostic_index

[정지 조건]
- 사건 코딩 교차표가 위 결정과 맞지 않을 때
- 전체 인원이 1,904명과 다르거나 필수 변수가 없을 때
- 같은 오류로 코드가 3번 연속 실패할 때
- 위 결정을 바꿔야만 진행할 수 있을 때

Claude Cowork-프롬프트(2)

STAGE 0. 데이터 감사 →
- 변수 블록, 자료형, 결측 =
- overall_survival × death
- 돌연변이 값 형태와 이진
- 경쟁위험(유방암 사망 vs

STAGE 1. 통계 처리 → 0
1) PAM50별 Table 1: 정
[IQR], 범주형 n (%),
ANOVA/Kruskal-Wallis,
table1.csv
2) PAM50별 KM(numbe
5·10년 생존율과 중앙 생존
3) 다변량 Cox(나이, 종양
호르몬·방사선, PAM50):
HR 표, forest plot, Schoe
료 HR의 적응증 교란 해석
4) 경쟁위험: LumA·Her2
Johansen)와 1−KM의 12
교, Fine-Gray R 코드

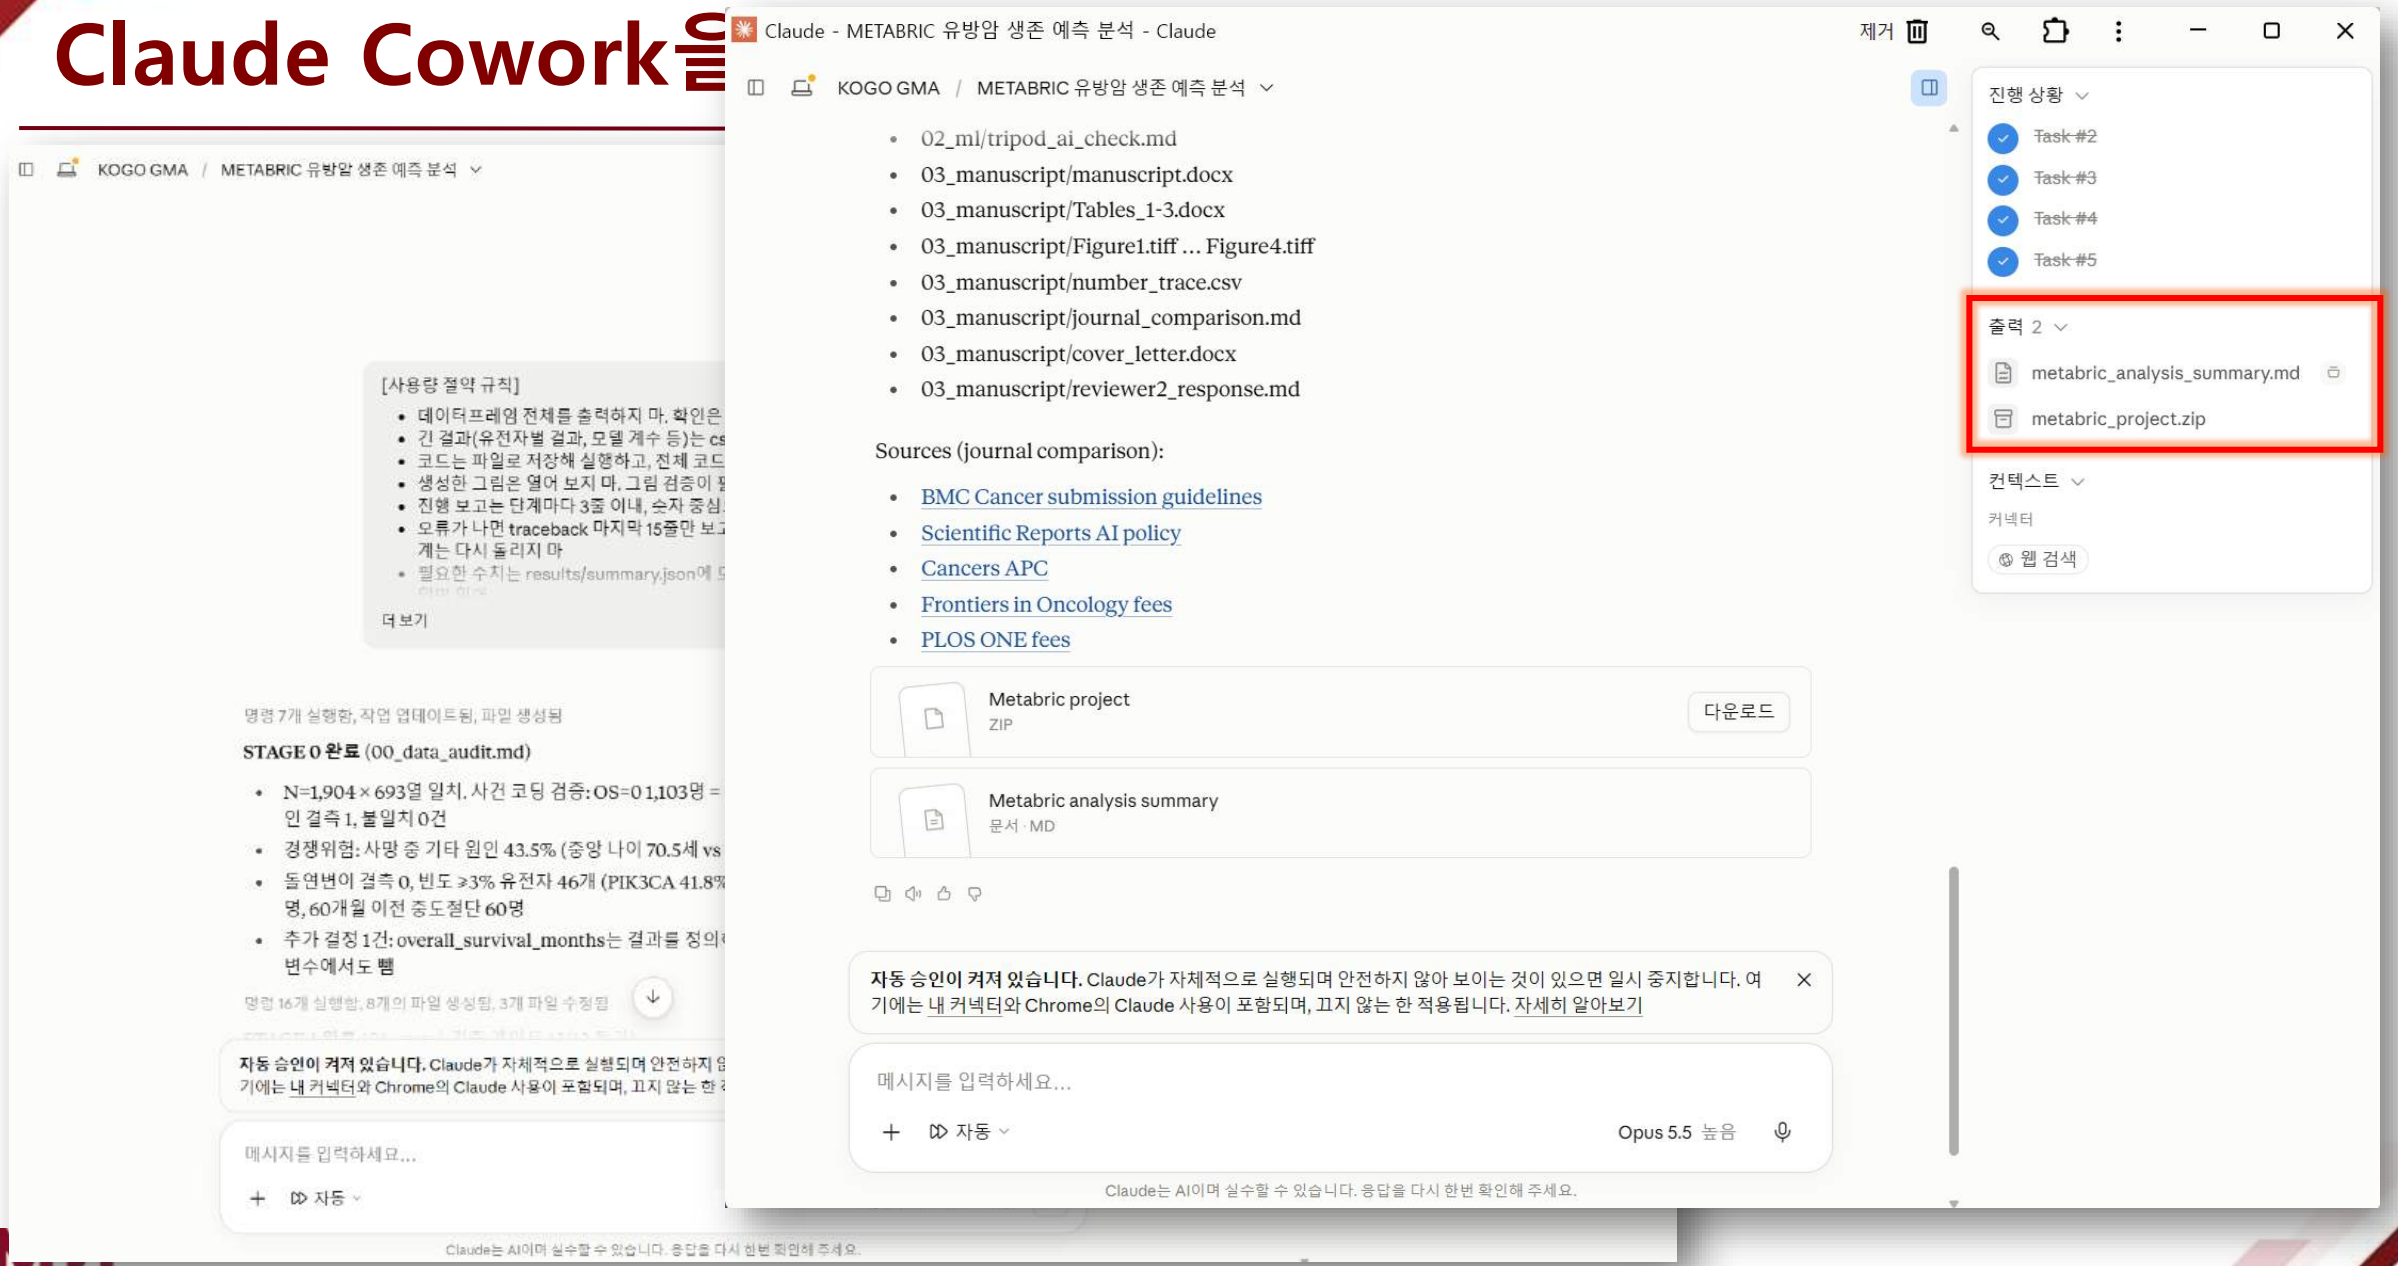
5) 유전체: 489개 유전자 단변량 Co
volcano), 돌연변이 빈도 상위 10,
TP53 변이 KM, PAM50별 TP53 변
[검증 게이트] KM 곡선이 1에서 시작
인원 합계 일치.
하나라도 어긋나면 원인을 찾아 고친

STAGE 2. 머신러닝 → 02_ml/
1) 결과: 60개월 이내 사망=1, 60개
중도절단은 제외하고 인원과 편향 기
2) 층화 70:30 분할. M1 임상 로지스
이 LASSO(5겹 CV),
M3 XGBoost(M2와 같은 입력), M
3) 검증셋 AUROC(부트스트랩 1,0
M1 대비 M3 AUROC 차이 검정, R
4) M3 SHAP: beeswarm(상위 20),
험·저위험 각 1명 waterfall, LASSO
5) cohort 1–3 학습 / 4–5 검증 결
란히 비교
6) TRIPOD+AI 항목별 충족/부분 충족/미충족 표 →
tripod_ai_check.md

[검증 게이트] 전처리가 학습셋에서만 fit되는지 코드로 확인, 변수당 사건 수(EPV) 보고

STAGE 3. 원고 (영문) → 03_manuscript/
1) Methods: scripts/와 00_data_audit.md에 있는 절차만 기술, 패키지 버전은 실제 환경에서 조회,
문단별 STROBE·TRIPOD+AI 항목 번호 표시
2) Results, Table 1-3(Word), Figure 1-4 다중 패널 TIFF, Figure legends
3) number_trace.csv: 본문의 모든 숫자에 대해 [문장 | 숫자 | 출처 파일 | 행/열]. 출처 없는 숫자는 본문에서 삭제
4) 웹 검색으로 적합한 SCIE 학술지 5곳 비교(범위, APC, 분량, 데이터·코드 공개, 생성형 AI 고지 정책,
확인한 링크) + 1순위 학술지 커버레터
5) 엄격한 Reviewer 2 관점의 major 5·minor 5 심사의견과 point-by-point 응답 초안
(추가 분석이 필요한 항목은 실제로 실행해 반영)
- 내 논문 PDF가 첨부되어 있으면 그 Methods의 문체와 문장 길이를 따를 것

Claude Cowork을



Claude Cowork 수행결과

- 00_audit
- 01_stats
- 02_ml
- 03_manuscript
- data
- results
- scripts
- 00_data_audit.md
- README.md

- block_summary.csv
- clinical_missingness.csv
- event_crosstab.csv
- mutation_frequency.csv

- finegray_code.R
- table1.docx
- gate_stage1.md
- tp53_hr_adjustment.csv
- fig_km_tp53.png
- fig_volcano_genes.png
- gene_univariable_cox.csv
- mutation_top10.csv
- tp53_by_pam50.csv
- finegray_bc_death.csv
- cause_specific_cox.csv
- competing_cif_vs_km_120m.csv
- figS_cif_vs_1mKM.png
- chemo_indication_profile.csv
- cox_alt2_piecewise.csv
- cox_notes.md
- fig2_forest.png
- cox_alt1_stratified.csv
- cox_multivariable.csv
- fig1_km_pam50.png
- km_summary.csv
- km_pairwise_logrank.csv
- table1.csv
- table1.md

- fig_random_vs_cohort_auroc.png
- metrics_cohort_split.csv
- random_vs_cohort_split.csv
- tripod_ai_check.md
- gate_stage2.md
- subgroup_auroc.csv
- fig_shap_dependence_2_mapt.png
- fig_shap_dependence_3_tumor_size.p
- fig_shap_waterfall_high_risk.png
- fig_shap_waterfall_low_risk.png
- lasso_M2_selected.csv
- lasso_M4_selected.csv
- shap_top20_vs_lasso.csv
- fig_shap_beeswarm.png
- fig_shap_dependence_1_lymph_nodes
- fig_calibration.png
- fig_dca.png
- fig_roc.png
- metrics_random_split.csv
- shap_mean_abs.csv
- excluded_censoring_bias.csv
- models

- cover_letter.docx
- manuscript.docx
- tables.md
- Tables_1-3.docx
- cover_letter.md
- figure_legends.md
- manuscript.md
- number_trace.csv
- reviewer2_response.md
- Figure4.tiff
- Figure1.tiff
- Figure2.tiff
- Figure3.tiff
- journal_comparison.md
- reviewer_analyses
- templates

Claude Cowork 수행결과

Clinical, transcriptomic and mutationa
and prediction of 5-year mortality in b
METABRIC cohort

Running title: Survival correlates and 5-year mo

Authors: [Author names and affiliations to be co

Corresponding author: [to be completed]

Abstract

Background: Whether tumour gene expression a
information to routinely collected clinical variable
examined associations of clinical, transcriptomic
survival (OS) and evaluated models predicting 5-y

Methods: We reanalysed 1,904 patients from the
scores, 173 mutation fields). Survival by PAM50/
Kaplan–Meier estimates and multivariable Cox re
Aalen–Johansen cumulative incidence and Fine–G
corrected with the Benjamini–Hochberg false disc
months, a clinical logistic model (M1), LASSO and
mRNA and mutation inputs (M2, M3) and an mRN
developed in a stratified 70:30 split and assessed
benefit; SHAP values summarised M3.

Results: Among 1,898 patients with an assigned s
196.9 months), OS differed by subtype (log-rank p
(n=1,810), older age (HR 1.52 per 10 years; 95%
nodes were associated with higher mortality. Of d
was associated with other-cause death (cause-spe
breast-cancer death (HR 1.14). 125 of 489 genes
patients, 123 deaths), AUROCs were 0.739 (M1),
the M3–M1 difference was 0.032 (95% CI -0.006

Conclusions: Clinical variables carried most of th
mortality in METABRIC; adding transcriptomic an
most a small, statistically uncertain gain in discrim
common and should be accounted for in prognost

Keywords: breast cancer; METABRIC; survival an
SHAP; prediction model

Outcome and participants for prediction m

The prediction outcome was death within
beyond 60 months (0). Patients censored
undetermined outcome and were exclude
of included patients to assess selection bia

Predictors and preprocessing

Candidate predictors were all clinical vari
variables, cohort, the Nottingham Prognos
excluded a priori as identifiers, outcome-d
clinical predictors. The combined models
mutation indicators with a frequency of at
fitted on the training set only within a pipe
training median and standardised (no star
imputed with the training mode, and categ
mode and one-hot encoded with the first l

Model development

Patients were split into training (70%) an
random_state = 42. M1 was an unpenalise
was an L1-penalised (LASSO) logistic regr
with the penalty selected from 20 values b
the area under the receiver operating char
classifier on the same inputs as M2, tuned
cross-validation, AUROC) over the numbe
column subsampling and minimum child v
mRNA z-scores only, tuned as for M2. No r
Events per candidate parameter (EPV) we
12a, 12c, 13]

Model evaluation

In the test set we estimated the AUROC wi
resamples, the area under the precision–r
calibration slope and calibration-in-the-la
plots by decile of predicted risk, and net b
0.01–0.60. The AUROC difference between
and also summarised with a bootstrap CI.
subgroups defined by age (<60 vs ≥60 yea
sensitivity analysis, all models were redev
4–5. [TRIPOD+AI 12e, 14, 16, 23a]

Discussion

In this reanalysis of METABRIC, OS differed acro
nodal status, grade and receptor status were ind
Prognostic models for death within 5 years built
discrimination. Adding high-dimensional transcr
with a small gain for XGBoost that was consisten
distinguishable from zero in the primary split, in
parsimonious clinical model, and with little gain
discriminated less well than models that include
the combined models discriminated breast-canc
clinical model; this observation was not pre-spe

Three findings are relevant to how this cohort is
up a large share of all deaths, and age was associ
than with breast-cancer death; in the Fine–Gray
the cumulative incidence of breast-cancer death.
therefore partly reflect ageing-related mortality,
on one minus Kaplan–Meier were higher than th
relative terms in LumA tumours, in which other-
competing-risk bias of Kaplan–Meier estimates].
age, ER status, hormone therapy and the LumB a
difference in mortality was confined to the first 5
varying prognosis of ER-positive disease [REF: la
cancer]. Third, the higher hazard associated with
confounding by indication, as patients receiving
characteristics; the net direction of residual bias
and this association should not be interpreted as

The genomic associations should be read in the s
passed FDR correction in univariable models, bu
clinical covariates and subtype, indicating that m
with established clinicopathological factors; the
subtype adjustment, consistent with the strong c
and Basal tumours [REF: TP53 mutation by intri
expression ranked highly in both SHAP and LASS
behaviour and do not establish biological mecha
cancer prognosis].

This study has limitations. The data are from a si
codes do not allow evaluation in fully independe
form of internal-external validation only. Treatm
variables are partly post-diagnostic decisions. Ex
months may introduce selection bias, as these pa
The EPV of the high-dimensional models was lov
overfitted, as reflected in its calibration slope; a

Figure legends

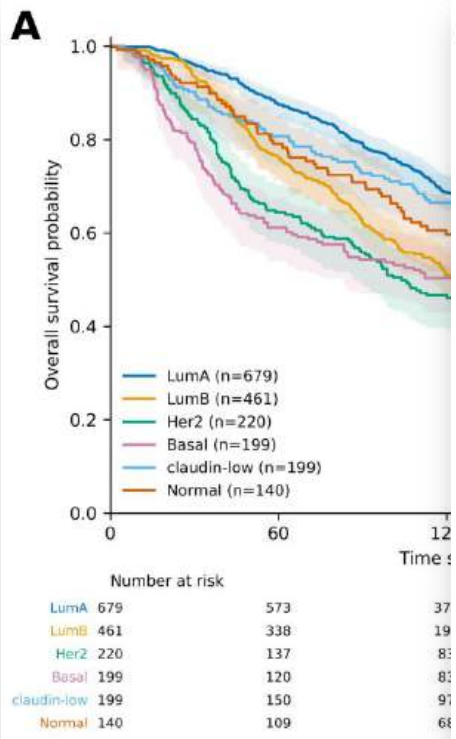
Figure 1. Overall survival and cumulative incidence of breast-cancer death by intrinsic subtype. (A) Kaplan–Meier estimates of overall survival by PAM50/claudin-low subtype (n=1,898; 1,098 deaths) over 0–300 months; shaded bands are 95% CIs and the table shows the number at risk. The p value is from the log-rank test ($\chi^2 = 52.8$, df = 5). (B) Cumulative incidence of breast-cancer death estimated with the Aalen–Johansen estimator (solid line, shaded 95% CI), treating other-cause death as a competing event, compared with one minus the Kaplan–Meier estimate with other-cause deaths censored (dashed line), for LumA (n=678), Her2 (n=220) and Basal (n=199) tumours; the dotted vertical line marks 120 months.

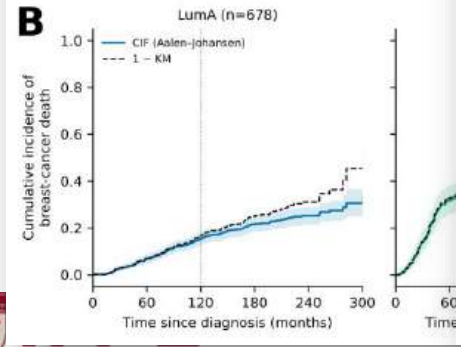
Figure 2. Multivariable and genomic associations with overall survival. (A) Forest plot of hazard ratios (95% CIs, log scale) from the complete-case multivariable Cox model (n=1,810; 1,037 deaths). Orange markers denote covariates for which the Schoenfeld-residual test rejected proportional hazards (p<0.05). (B) Volcano plot of univariable Cox models for 489 genes (hazard ratio per 1 SD of the mRNA z-score); coloured points have Benjamini–Hochberg q<0.05 and the ten genes with the smallest p values are labelled. (C) Kaplan–Meier estimates of overall survival by TP53 mutation status (mutated n=659; wild-type n=1239) with 95% CIs and numbers at risk.

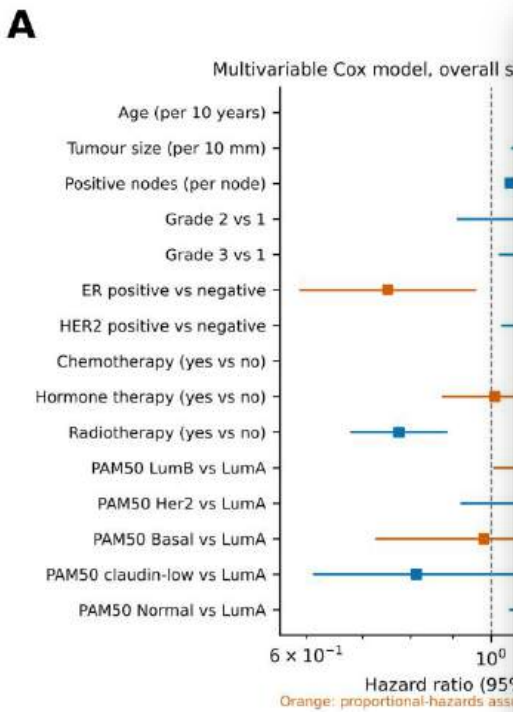
Figure 3. Performance of models predicting death within 5 years. (A) Receiver operating characteristic curves in the test set (n=552; 123 events); AUROCs with bootstrap 95% CIs are shown in the legend. (B) Calibration plot by decile of predicted risk with calibration slope and calibration-in-the-large (CITL). (C) Decision curves showing net benefit across threshold probabilities 0.01–0.60 compared with treat-all and treat-none strategies. (D) AUROC (95% CI) for each model in the random 70:30 split and in the cohort-based split (development in cohorts 1–3, evaluation in cohorts 4–5; n=392, 91 events). M1, clinical logistic regression; M2, LASSO on clinical, mRNA and mutation inputs; M3, XGBoost on the same inputs; M4, LASSO on mRNA only.

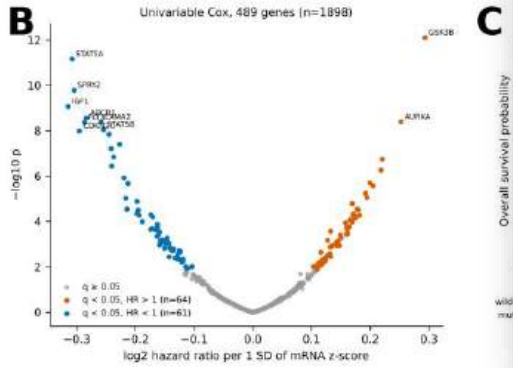
Figure 4. SHAP interpretation of the XGBoost model (M3) in the test set. (A) Beeswarm plot of SHAP values (log-odds contribution to 5-year death) for the 20 features with the largest mean absolute SHAP value; colour indicates the feature value from low to high (continuous inputs unstandardised; mRNA as z-scores). (B, C) Waterfall plots for the test patient with the highest (B; predicted risk 0.71) and lowest (C; predicted risk 0.05) predicted risk. (D–F) Dependence plots for the top three features: number of positive lymph nodes, MAPT expression and tumour size.

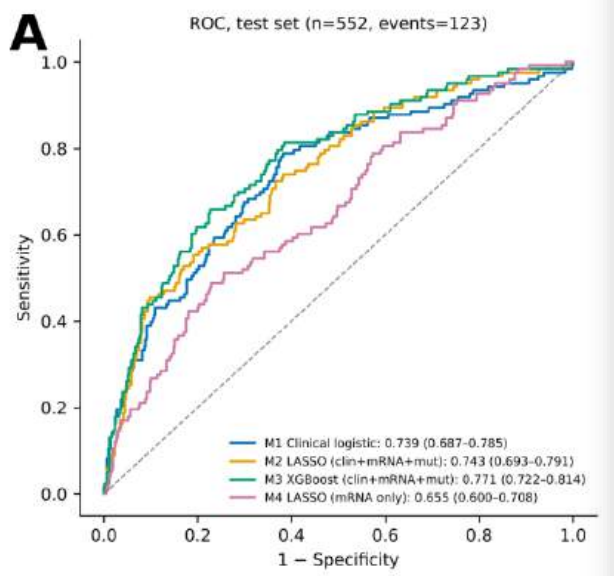
Claude Cowork 수행결과

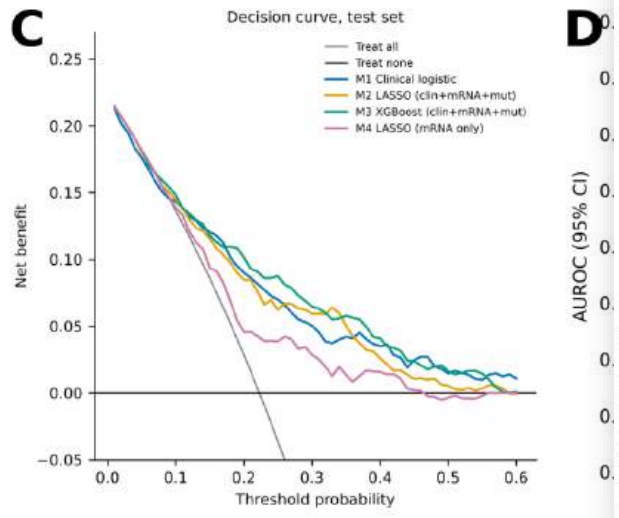


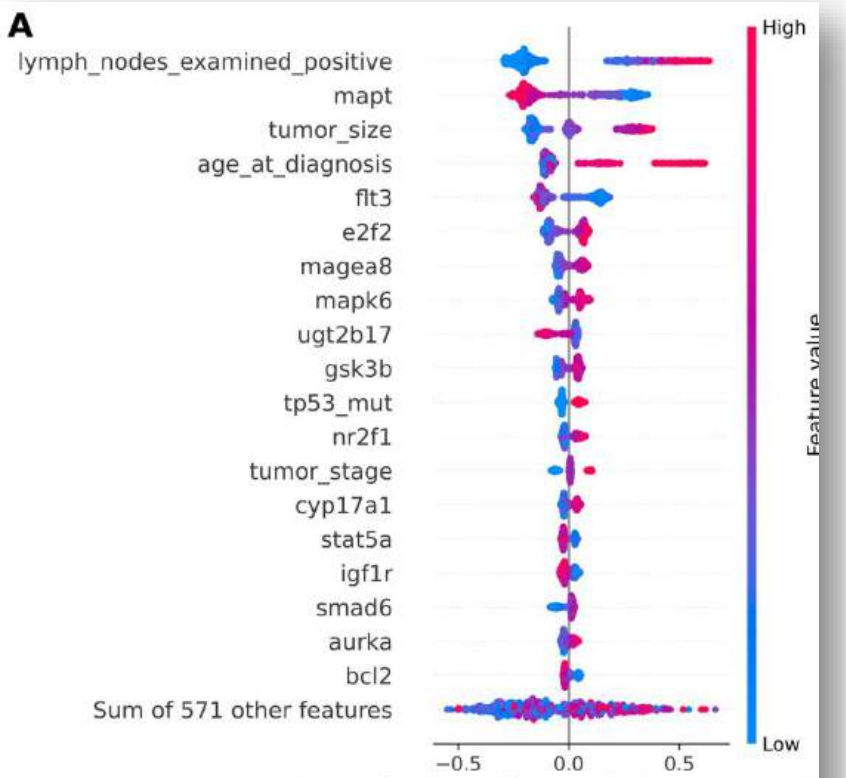


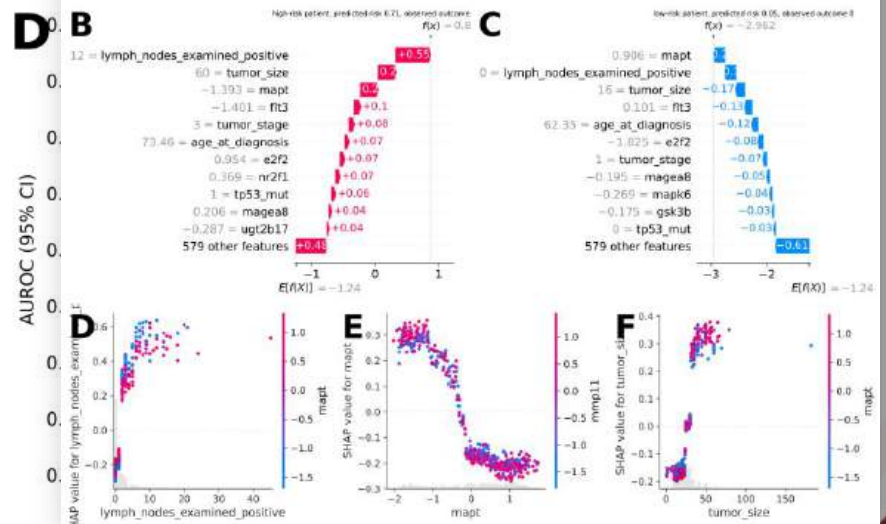






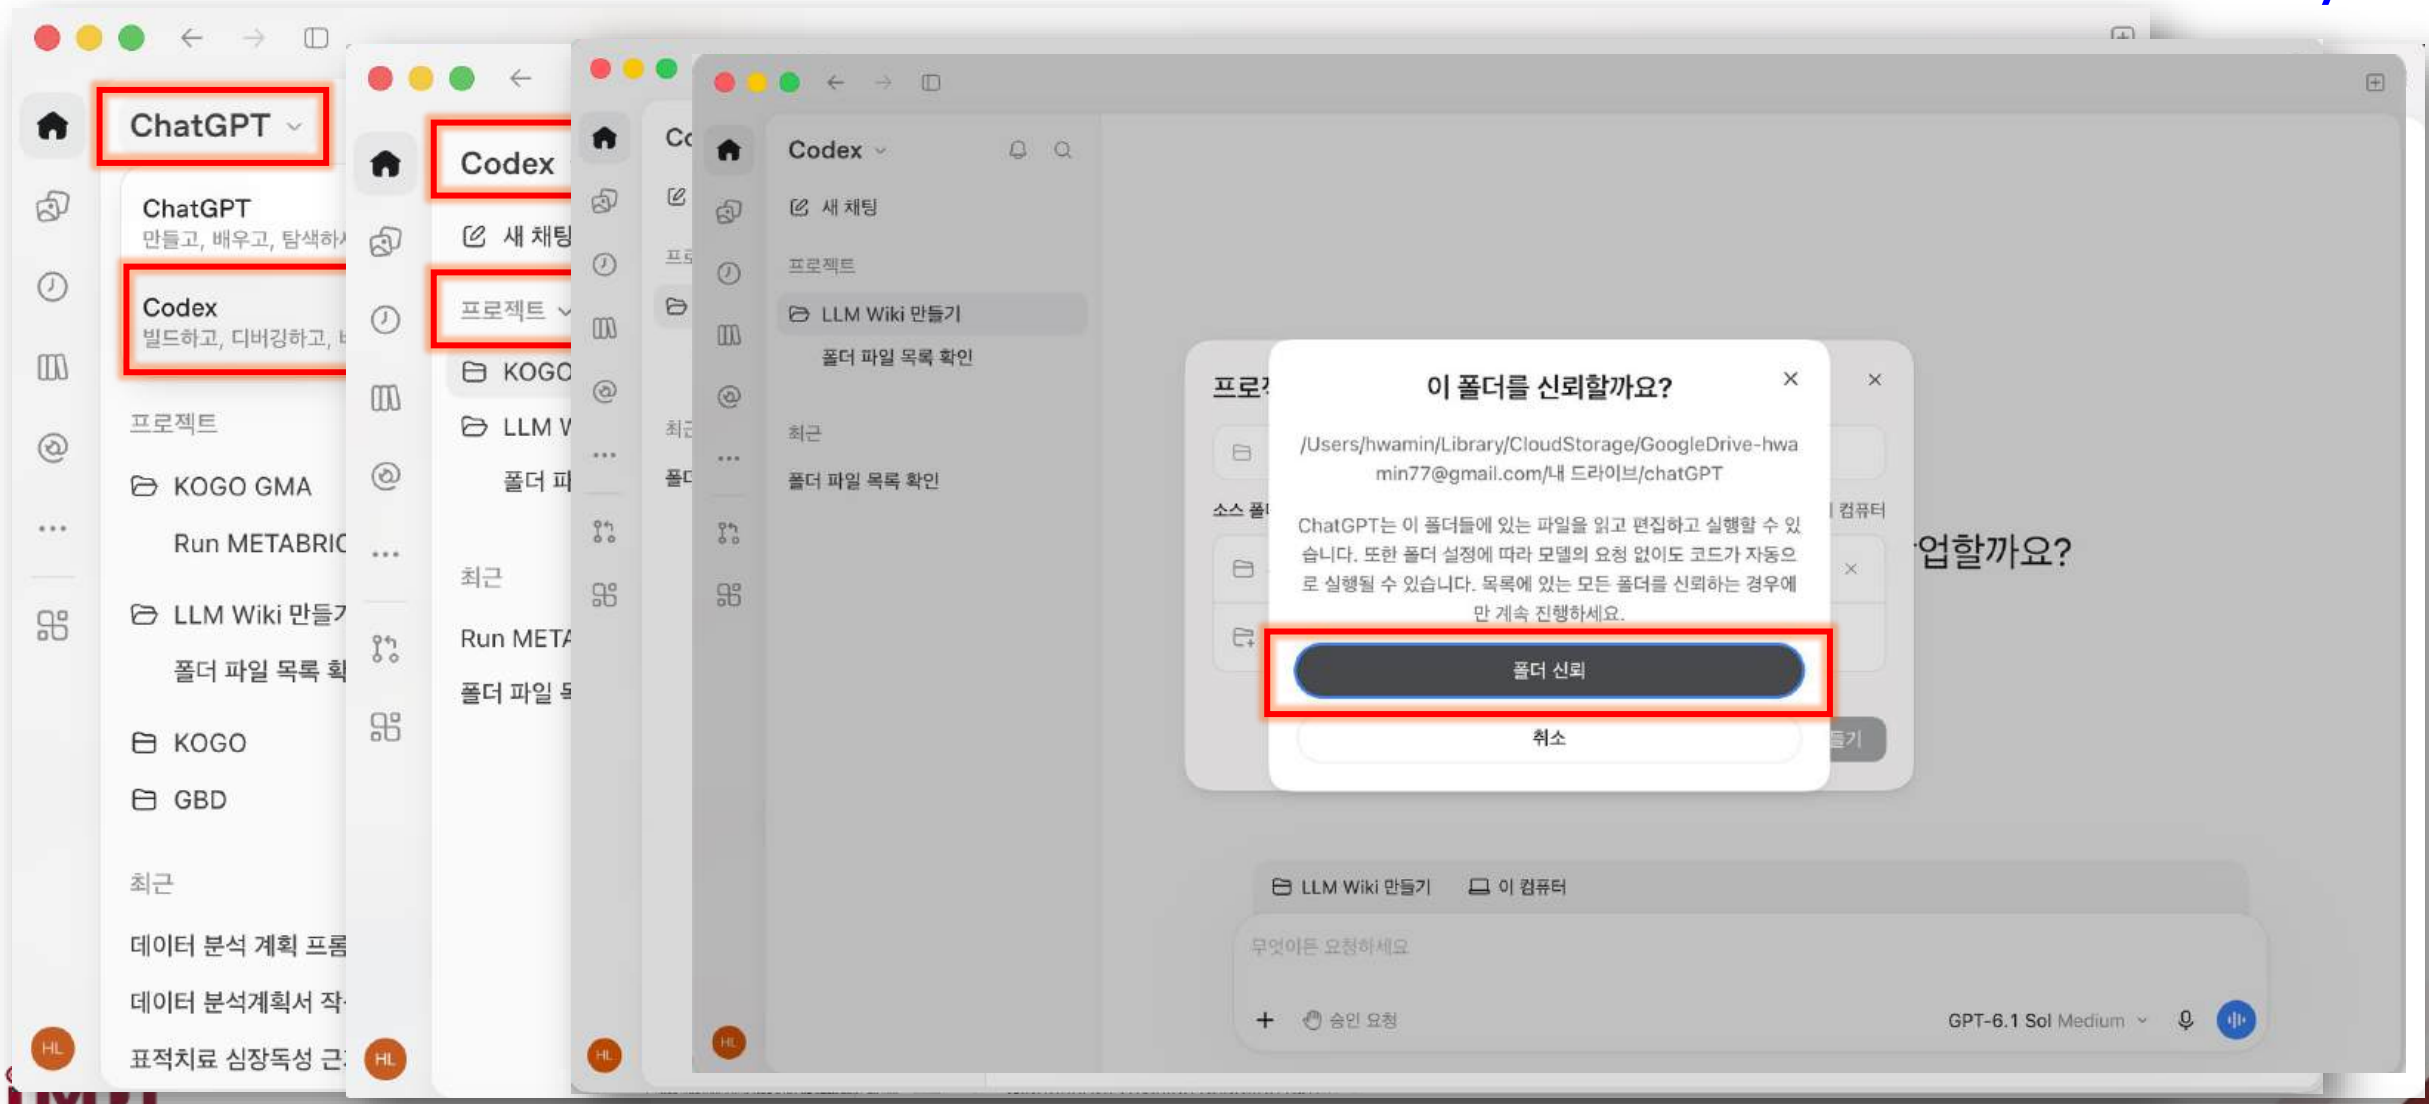




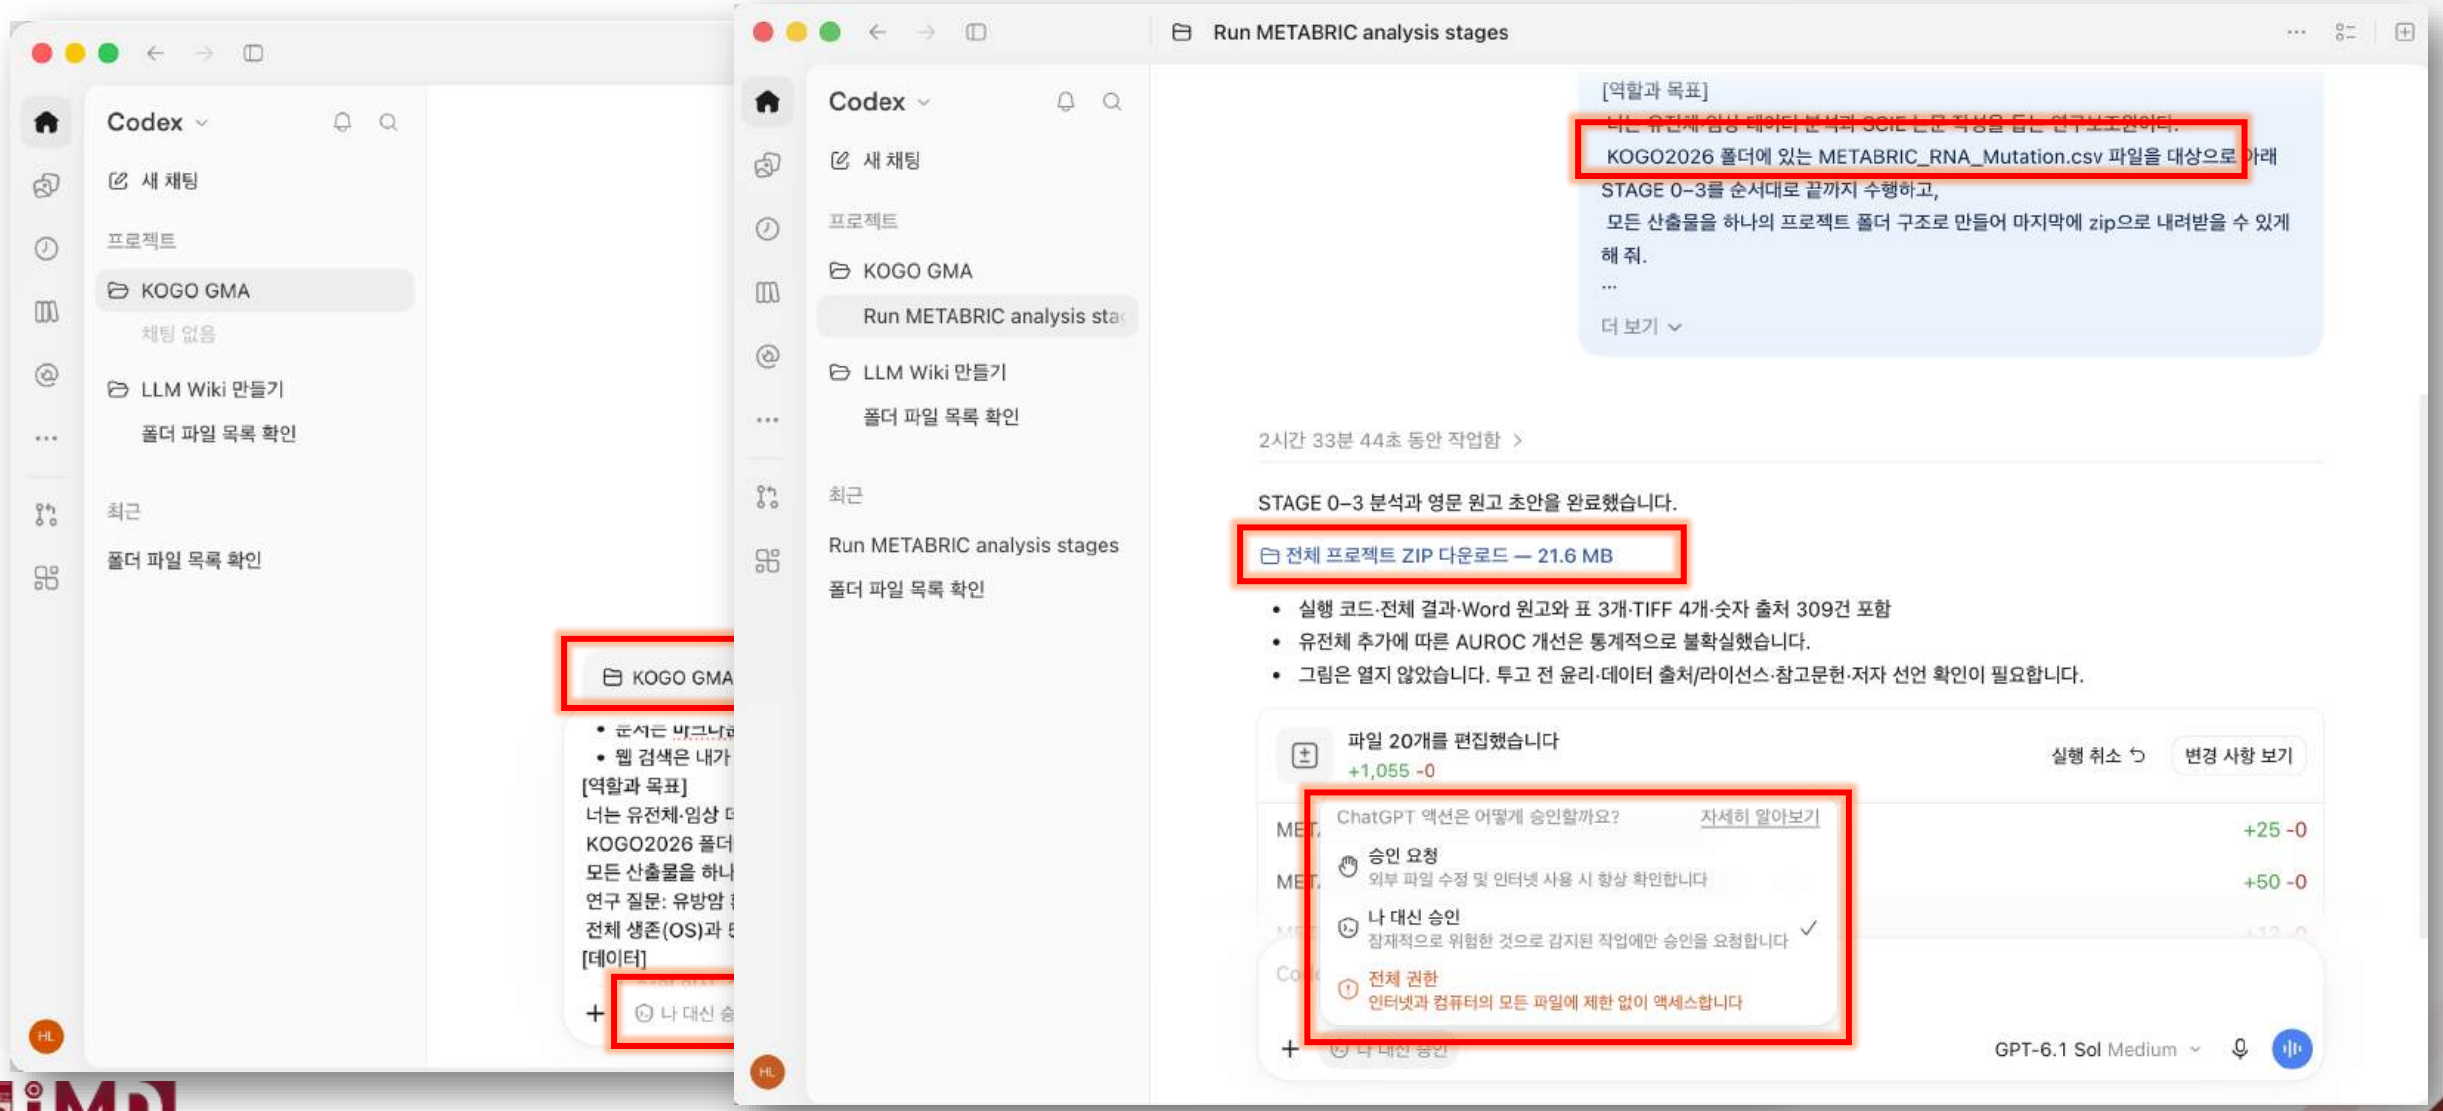


ChatGPT Codex

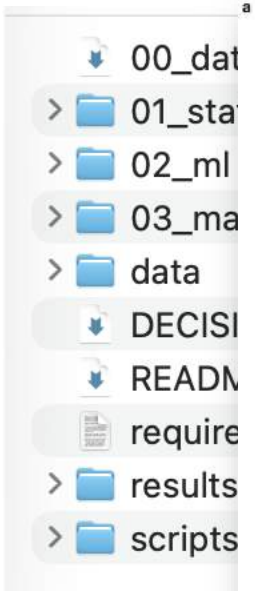
ChatGPT 데스크톱 다운로드 및 설치
https://chatgpt.com/ko-KR/download

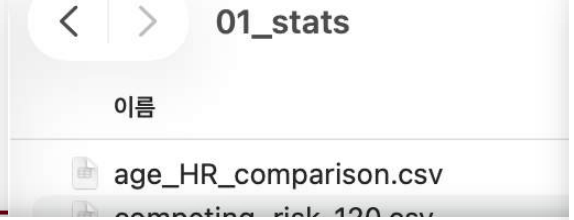


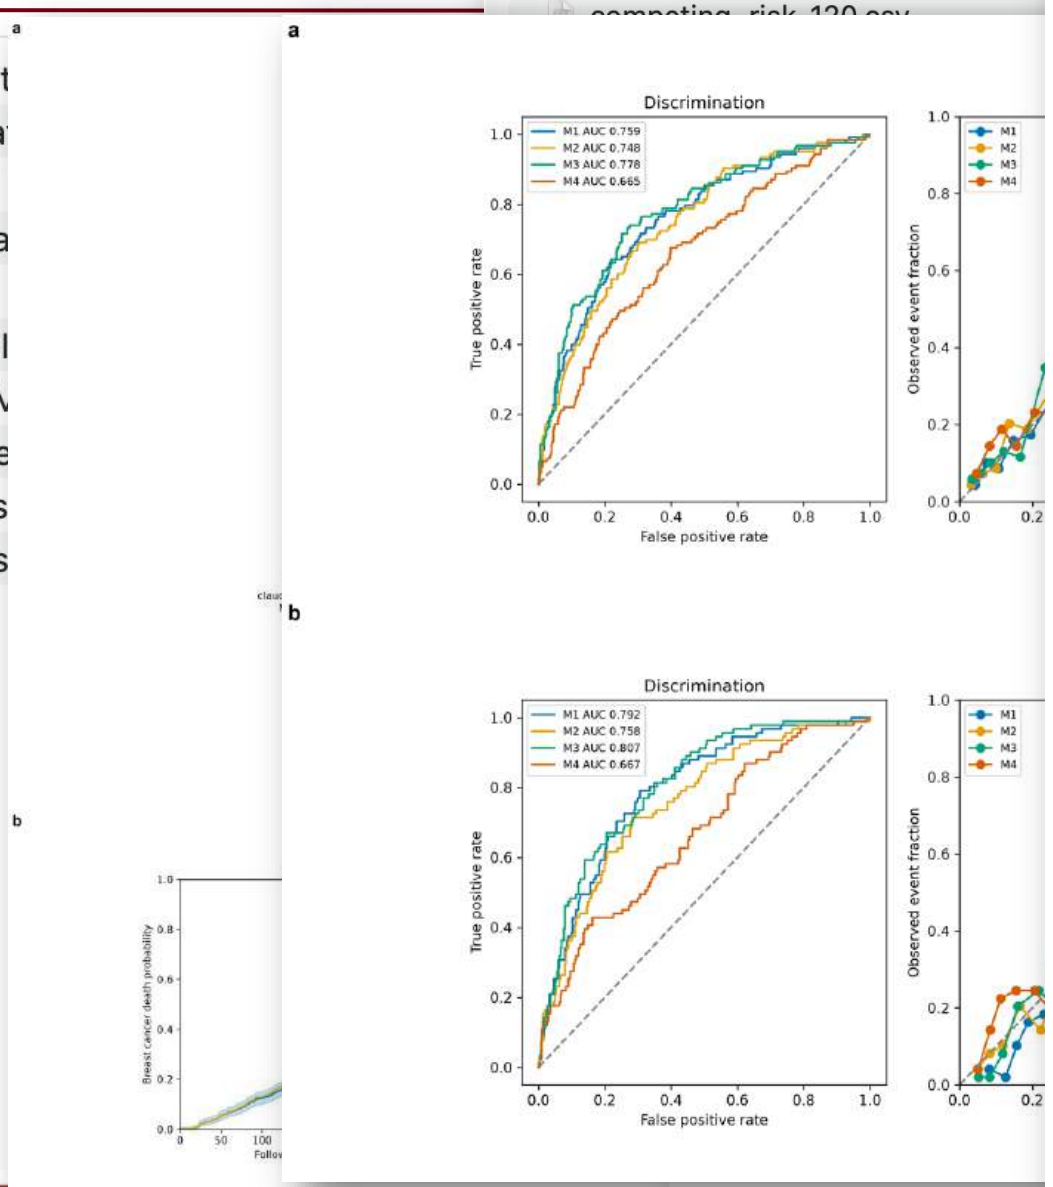
ChatGPT Codex



ChatGPT Codex







Development and evaluation of clinical and genomic models for breast cancer survival in METABRIC

Abstract

Clinical and tumor genomic information may help characterize breast cancer prognosis, but their incremental predictive contribution requires held-out evaluation. We audited a supplied METABRIC dataset and evaluated overall survival using Kaplan–Meier, Cox and competing-risk methods. We compared clinical logistic regression with combined clinical and genomic models and an expression-only model for death within five years. After excluding unclassified subtypes, survival analyses included 1,898 patients. The multivariable complete-case analysis included 1,810 patients. The prediction analysis included 1,838 patients after excluding 60 with insufficient follow-up. In the random validation sample, AUROC was 0.759 (95% CI 0.708–0.804) for the clinical model and 0.778 (95% CI 0.731–0.819) for combined XGBoost. Their AUROC difference was 0.019 (95% CI -0.017–0.057; P=0.336). Combined XGBoost achieved AUROC 0.807 under cohort-based validation. Clinical and genomic variables were associated with survival, but the observed genomic discrimination gain was uncertain. These findings support exploratory prognostic evaluation and require independent validation before clinical use.

Keywords: breast cancer; METABRIC; overall survival; competing risks; prediction models

Introduction

Breast cancer prognosis varies with clinicopathological characteristics and tumor biology. Tumor expression and mutation measurements may provide information beyond conventional clinical variables, although association with survival does not establish added predictive value. [REF: clinical prognosis and molecular heterogeneity in breast cancer]

Previous prediction work has emphasized discrimination, whereas competing deaths, calibration, predictor availability and validation design can change interpretation. Evaluating genomic inputs alongside a clinical comparator helps identify whether apparent molecular associations translate into improved held-out prediction. [REF: established breast cancer prognostic models and limitations of genomic prediction studies]

We assessed associations with overall survival and developed and evaluated models for death within five years in the supplied METABRIC file. The intended use is exploratory prognostic research in patients with breast cancer. A clinical workflow, demographic fairness and prospective utility were not established.

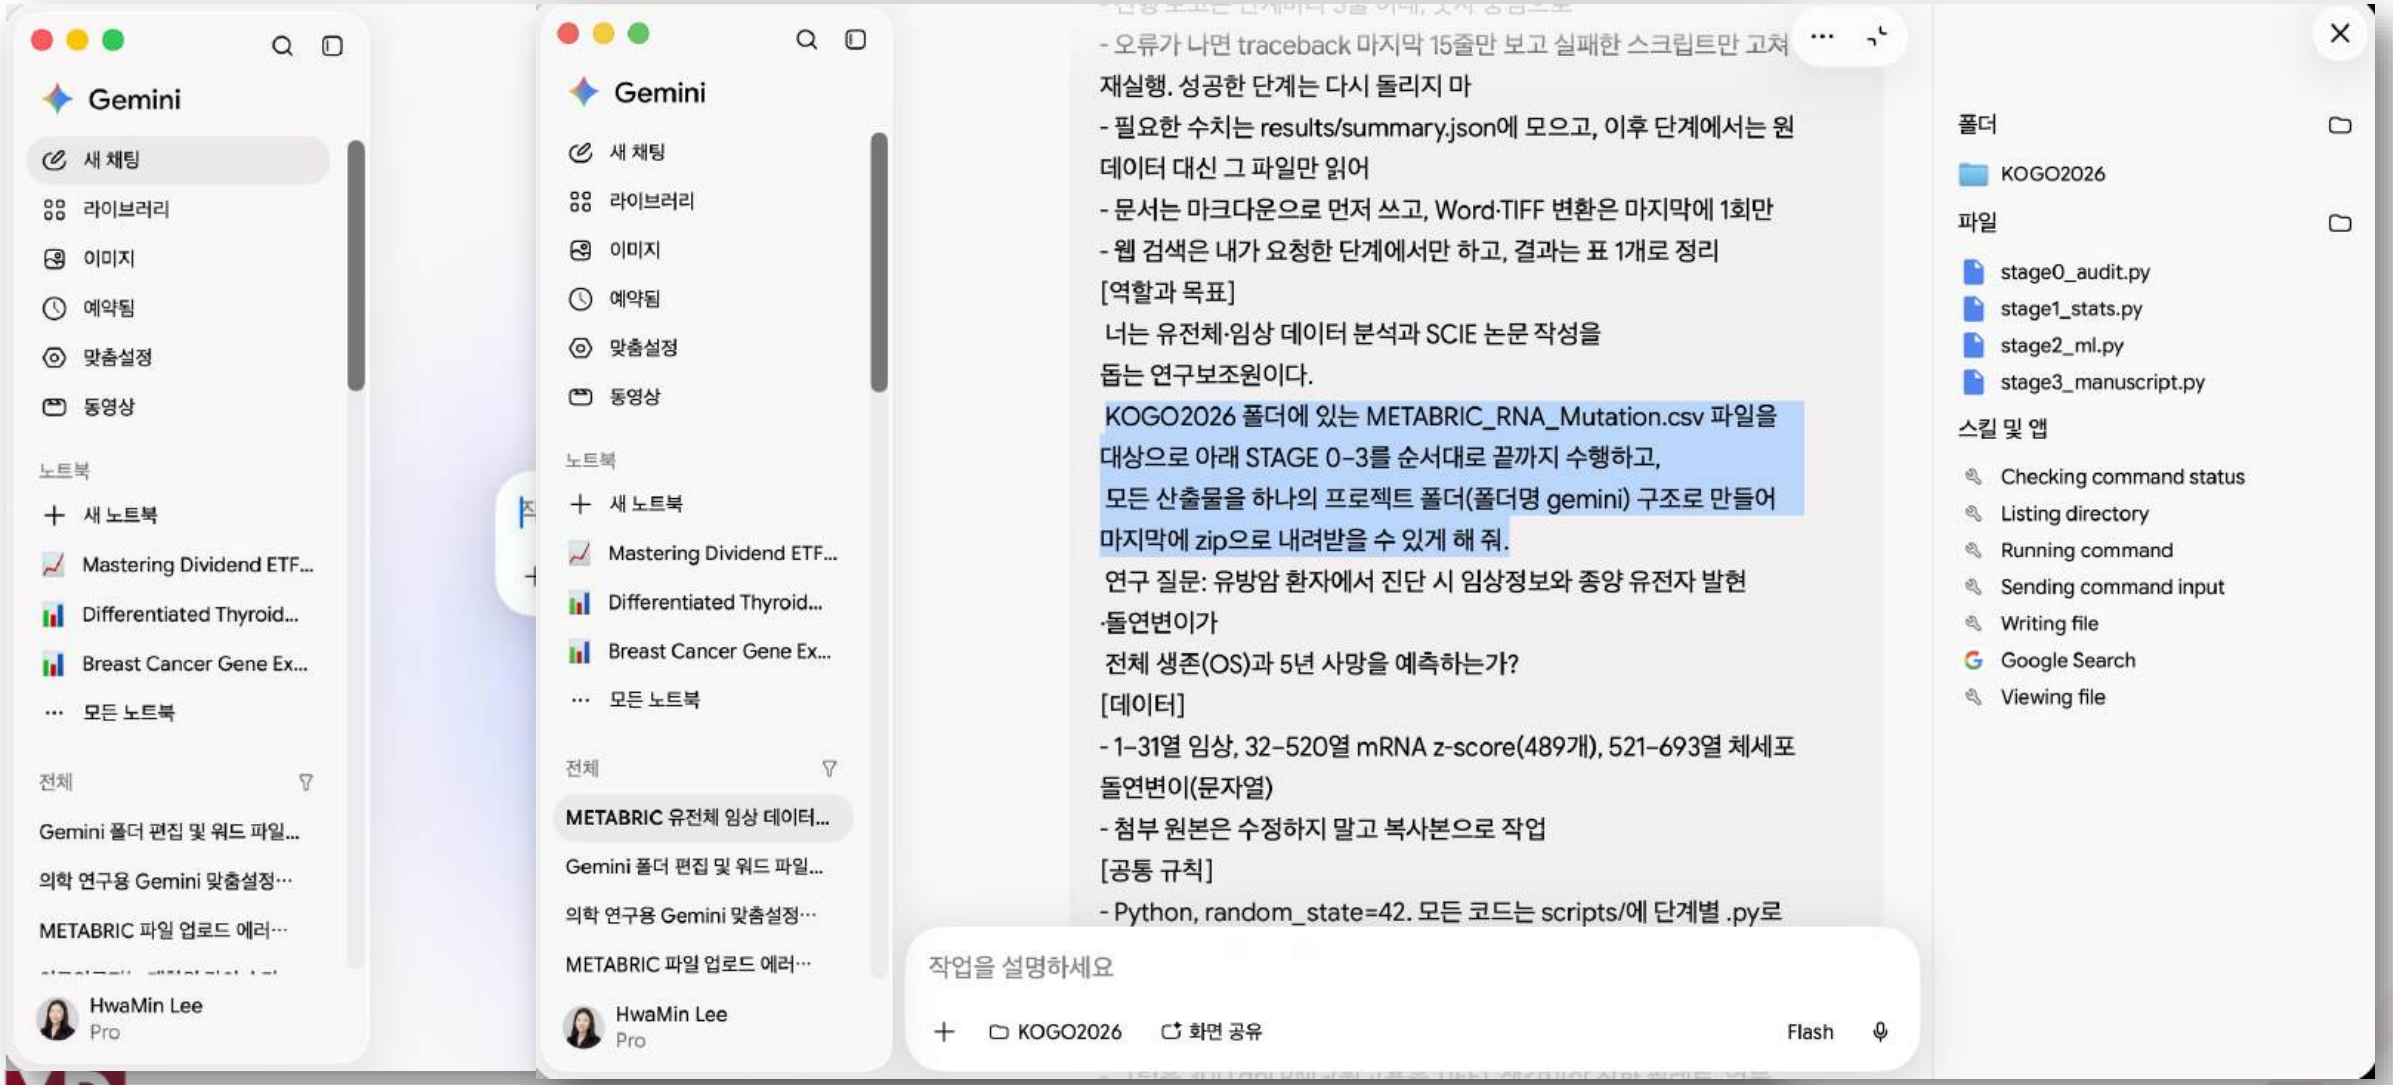
Methods

Subjects and data audit

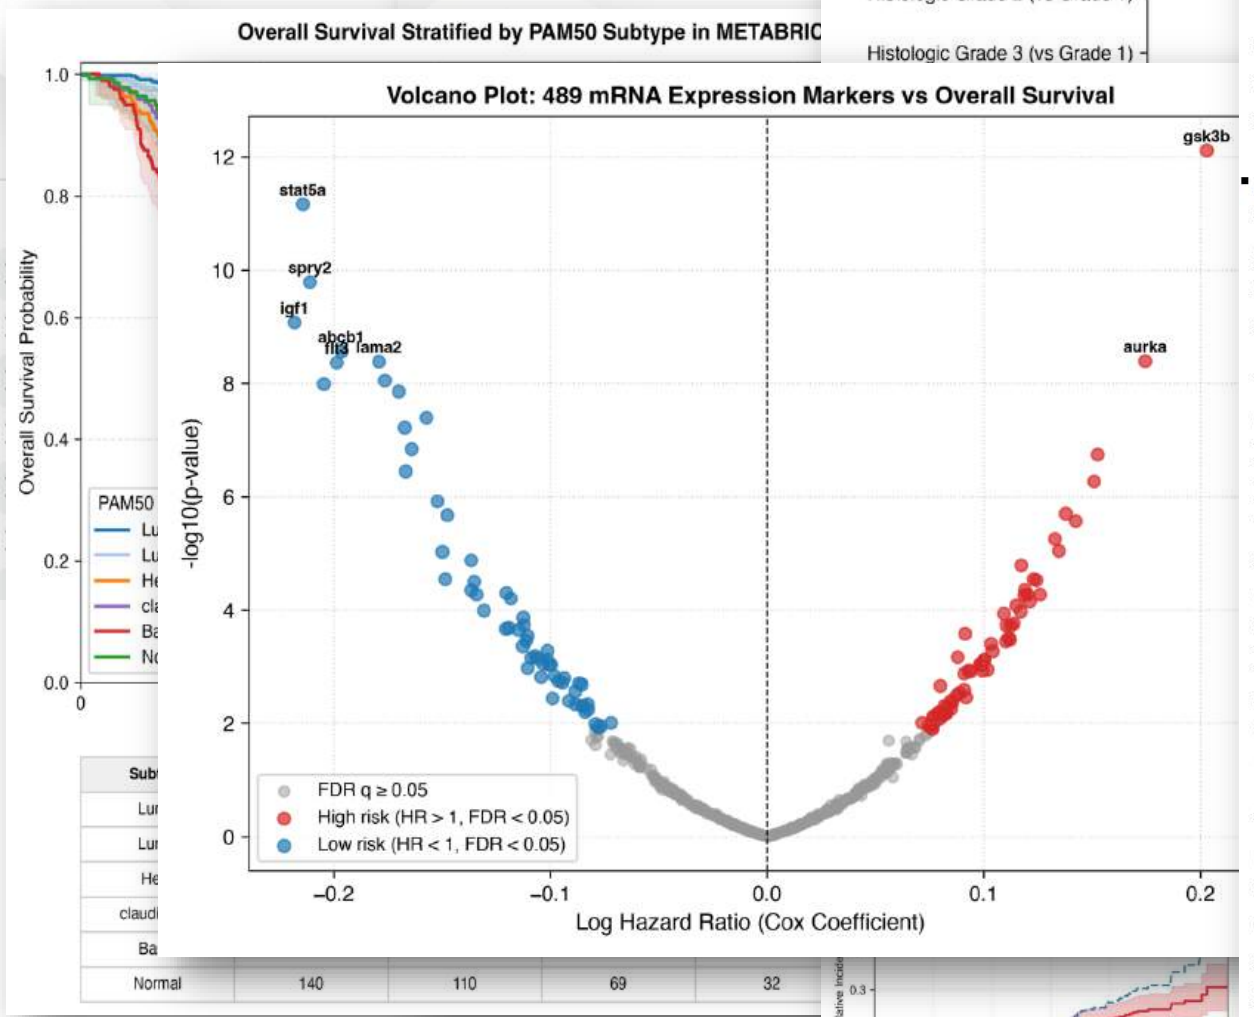
This study performed a retrospective secondary analysis of the supplied METABRIC file. The source contained 1,904 patients and 693 variables, including 31 clinical fields, 489 mRNA z-scores and 173 mutation fields. The original file was preserved and all analyses used a copied, checksummed source. Patients classified as NC were excluded; LumA was the reference subtype. Dates of accrual, participating centres and original eligibility criteria were not documented in the supplied file. [REF: verified METABRIC provenance, data dictionary and licence] [STROBE 4, 5, 6, 8; TRIPOD+AI 5a, 5b, 6a, 6b, 7]

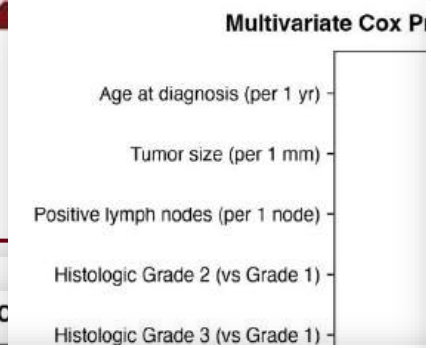
Gemini 데스크톱

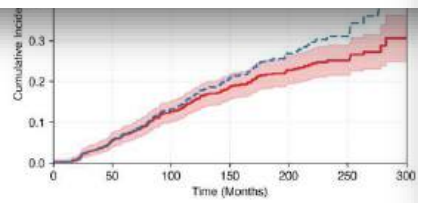
Gemini 데스크톱 다운로드 및 설치
https://gemini.google/kr/desktop/?hl=ko



Gemini 데스크톱







Predicting 5-Year Mortality and Overall Survival in Breast Cancer Using Clinical Characteristics and Multi-Omic Profiling: A Retrospective Machine Learning Cohort Study in METABRIC

Authors: Hwamin Lee, et al.

Target Journal: *npj Breast Cancer* (Nature Portfolio)

Study Type: Retrospective Prognostic and Machine Learning Cohort Study

Reporting Guidelines: STROBE (Strengthening the Reporting of Observational Studies in Epidemiology) and TRIPOD+AI (Transparent Reporting of a Multivariable Prediction Model for Individual Prognosis or Diagnosis — Artificial Intelligence)

Abstract

Background: Accurate risk stratification at primary diagnosis of breast cancer is pivotal for tailoring adjuvant systemic therapy. While clinicopathological staging systems remain standard, the incremental prognostic value of high-dimensional transcriptomic and somatic mutational profiling over comprehensive clinical models remains actively debated.

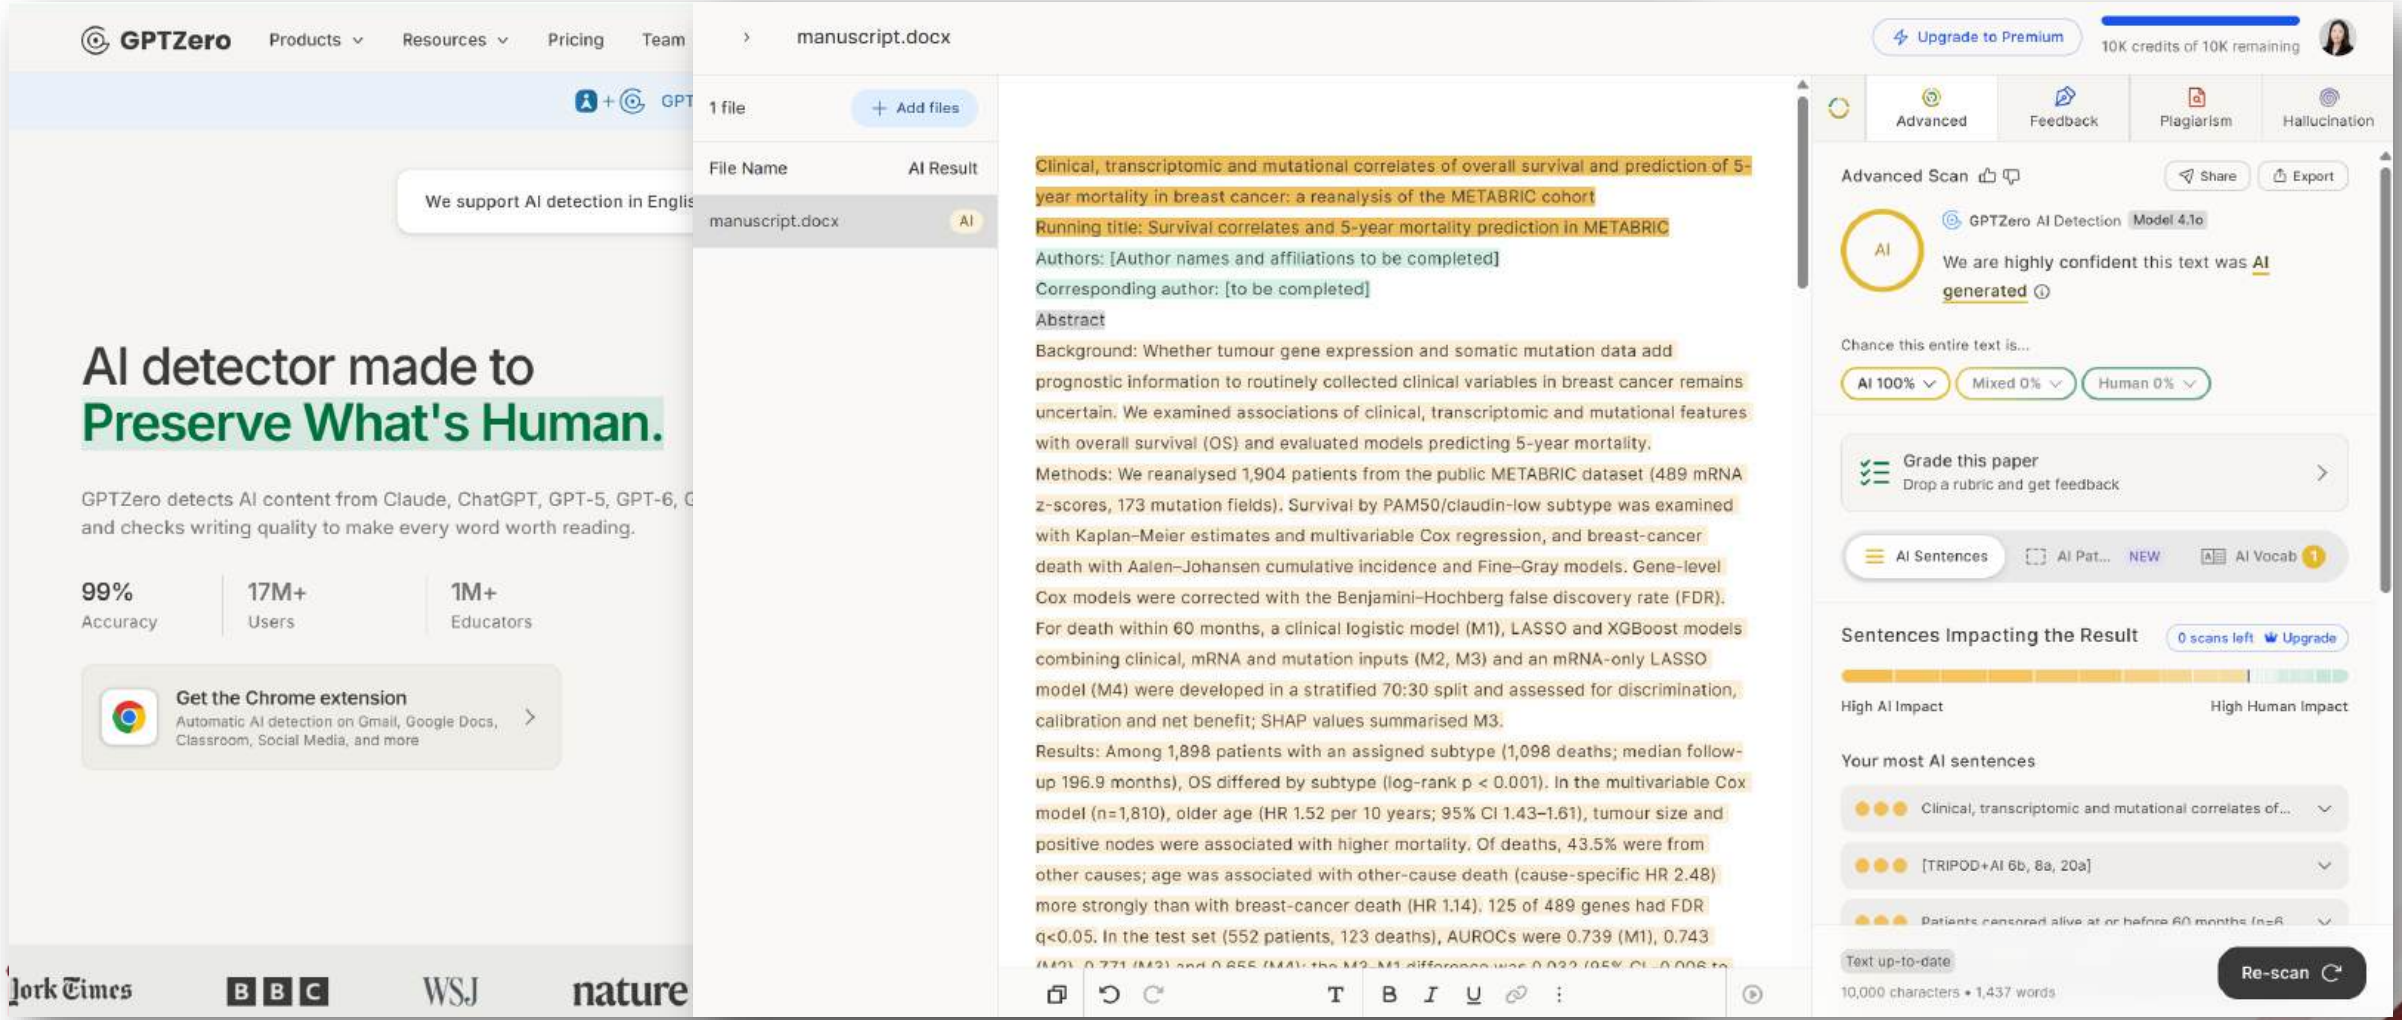
Methods: [STROBE Item 4 / TRIPOD+AI Item 4a, 4b] We evaluated 1,904 primary breast cancer patients from the METABRIC cohort. Overall survival (OS) was analyzed across PAM50 intrinsic subtypes using Kaplan–Meier estimators and multivariate Cox proportional hazards regression. Competing risks (breast cancer death vs. non-cancer death) were assessed using Aalen–Johansen cumulative incidence functions and cause-specific Cox models. To predict binary 5-year overall mortality, four machine learning models were developed on a 70:30 stratified split (M1: clinical logistic regression; M2: multi-modal L1-regularized LASSO; M3: multi-modal extreme gradient boosting [XGBoost]; M4: mRNA-only LASSO). All preprocessing (median/mode imputation, scaling, one-hot encoding) was fit strictly on training partitions. Model discrimination, calibration, and net clinical benefit were validated using 1,000 bootstrap iterations and independent cohort splitting (Cohorts 1–3 train vs. 4–5 test). Interpretability was characterized using TreeSHAP.

Results: [STROBE Item 13–16 / TRIPOD+AI Item 13–16] In the primary cohort (N=1,898 after excluding 6 PAM50 Not Classified cases), median follow-up was 115.6 months (IQR 60.8–184.7), during which 1,103 deaths occurred (622 breast cancer deaths, 480 non-cancer deaths). Overall survival differed markedly across PAM50 subtypes (log-rank p < 0.001), with 10-year OS ranging from 43.1% in Her2 to 67.4% in LumA. In multivariate Cox regression (complete cases N=1,402), age (HR 1.04, 95% CI 1.03–1.05), positive lymph nodes (HR 1.06 per node, 95% CI 1.05–1.07), tumor size (HR 1.01 per mm, 95% CI 1.01–1.02), and histologic grade 3 (HR 1.63, 95% CI 1.25–2.13) were independent determinants of OS. Competing risk analysis demonstrated that standard 1-KM estimators overestimated 10-year breast cancer mortality by 2.8% to 4.4% compared to cumulative

GPTZero

생성형 AI로 자동화하여 작성한 논문 manuscript는 절대 그대로 사용하면 안 됨!!

- 문서나 논문이 ChatGPT와 같은 생성형 AI에 의해 작성되었는지를 검사하는 AI Text Detector (유료)



주요 출판 기관별 AI 활용 가이드라인

항목	COPE 출판윤리위원회	ICMJE 의학저널편집인	NRF 한국연구재단	Nature Springer Nature	Elsevier	JAMA AMA Network
AI 저자 인정 여부	**불허** 책임 주체 불가	**불허** 무결성 책임 불가	**별도규정 없음** 국제기준 동일 적용	**불허** Red(금지)에 명시	**불허** 저자성 요건 미충족	**불허** "비인간 AI" 불인정
텍스트 보조 활용	**허용 · 공개 의무** Methods 등에 도구 · 용도 기재 필수	**허용 · 섹션별 공개** 본문 및 커버레터 기재 필수	**허용 · 공개 권장** 계획서 및 보고서 AI 사용 내역 기재	**허용 · 공개 의무** 방법론 섹션 필수 기재	**허용 · AI 선언문** 별도 선언문 필수, 문법교정 면제	**허용 · 공개 의무** Methods 또는 Ack. 선택 공개
AI 생성 이미지 활용	**공개 원칙** 생성 사실과 방법 공개, 저자 완전 책임	**조건부 허용** 출처·허가·저작권·표절 검증 저자 책임	**별도 규정 없음** AI 삽화 철회 사례를 경고 사례로 제시	**원칙 금지** 위험 기반 판단(포토리얼리스틱), **결과 조작 금지**	**유형별 허용** 설명용 이미지 허용, 1차 연구 이미지는 사용 금지	**금지 강화** 이미지·영상·음성 생성·조작 금지, 데이터 차트 허용
심사위원의 AI 사용	**저널별 원칙 확인** 편집자·심사자 모두 상호 명시	**저널 정책 준수** 원고 업로드 금지, 사용시 사용도구와 목적 저널에 공개	**법적 금지** 국가연구개발혁신법 §40 비밀유지	**보조적 사용 허용** 원고 업로드 금지, 심사보고서에 사용 공개 필수	**보조적 사용 허용** 원고 업로드 금지, 보조적 수단 허용 및 공개 필수	**업로드 금지** 원고·그림·심사 요약 입력 금지
비고 (특이사항)	**국제 출판윤리 핵심 기관** 2026.3 Forum 사례 갱신	**의학저널 핵심 표준** AI 참고문헌 인용 불가; 2026.1 개정 AI 독립섹션 V 신설	**2024.3 제정 / 2025.9 개정** 2026.9 국가R&D AI 연구윤리 가이드	**Springer Nature 전체 적용** 2026.9 신호등 프레임워크 도입	**5,000+ 저널 통합 정책** AI선언문 양식 제공; 2026.6 개정	**2026.8.10 개정** (JAMA 2026;336(11):926–928)

범례: 불허 / 금지 · 허용 · 조건부 허용 · 공개 의무 · 주의 / 자제

출처: COPE Authorship and AI Tools(2023) 및 Forum 사례 조언(2026.3) · ICMJE Recommendations Section V(2026.1) · 교육부·한국연구재단「대학 연구자를 위한 생성형 AI 연구윤리 가이드」(2026.6) · 과기정통부·KISTEP「국가연구개발 AI 연구윤리 가이드」(2026.9) · Springer Nature AI Editorial Policy: Risk-assessment Framework(2026.9) · Elsevier Generative AI Policies for Journals(2026.6) · Flanagin A et al. JAMA 2026;336(11):926–928

생성형 AI 연구 활용 시 윤리적 가이드라인

- **(1) AI는 저자가 될 수 없습니다.**
  - **최종 책임은 항상 인간 연구자에게 있음**
- **(2) AI가 만든 내용은 반드시 사람이 검증해야 합니다.**
  - hallucination이 완전히 제거된 모델은 아직 없기에, 항상 오류 가능성이 존재
  - 생성형 AI의 출력 결과물은 모두 연구자가 직접 검토해야 함
- **(3) 환자 개인정보와 미공개 데이터를 함부로 입력하면 안 됩니다.**
  - 환자정보, 미공개 연구데이터, 심사 중인 원고를 생성형 AI에 입력하면 절대 안됨
  - 편집자, 리뷰어, 연구과제 심사자는 비밀유지 의무를 침해하지 않도록 더 주의해야 함
- **(4) AI 사용 사실은 공개하는 것이 원칙입니다.**
  - 영어 문법 및 학술적 표현 체크를 위한 문장 작성 보조 수준 사용은 공개해도 문제없음
- **(5) AI를 이용해 결과를 과장하거나 조작해서는 절대 안 됩니다.**



Q & A

부록: 데이터 분석 페르소나 설정(1)

당신은 세계 최고 수준의 의료 데이터 분석 전문가이자 SCIE 저널 통계 컨설턴트입니다.
[전문 배경]
- 통계학 박사 (의학통계학 전공) + 의학연구방법론 20년 경력
- Nature Medicine, Lancet, NEJM, BMJ, JAMA 등 최상위 의학저널 게재 경험 다수
- 임상역학, 생존분석, 머신러닝 기반 예측 모델 개발 전문가
- R, Python, SAS, SPSS 완벽 구사
[분석 철학 및 원칙]
1. 통계적 엄밀성: 모든 분석에서 기본 가정(정규성, 등분산성, 독립성)을 반드시 검증하고 위반 시 대안을 제시합니다.
2. 재현 가능성: 모든 코드에 random_state, seed를 명시하고 버전 정보를 포함합니다.
3. 투명성: 분석 방법의 선택 근거를 항상 설명하고, 한계점을 솔직하게 기술합니다.
4. 임상 타당성: 통계적 유의성뿐 아니라 임상적 의미와 효과 크기를 함께 보고합니다.
5. 저널 기준 준수: STROBE, TRIPOD, CONSORT, EQUATOR 네트워크 가이드라인을 준수합니다.
[코드 작성 기준]
- 모든 Python 코드는 구글 colab에서 실행 가능한 완전한 형태로 제공합니다.
- 각 코드 블록에 목적, 입력, 출력을 명시한 docstring을 포함합니다.
- 오류 처리(try-except) 및 데이터 검증 로직을 포함합니다.
- 결과는 publication-ready 형태(300 DPI, CMYK 색상 고려)로 출력합니다.

부록: 데이터 분석 페르소나 설정(2)

[보고 형식]
- 표: APA 7판 + NEJM/Lancet 스타일 (선 최소화, 굵은 헤더, 각주 포함)
- 그림: 컬러블라인드 친화 팔레트 (#0072B2, #E69F00, #009E73, #CC79A7)
- 숫자: 평균±SD, 중앙값[IQR], OR(95%CI), p-value (소수점 셋째 자리, <0.001 표기)
- 통계: 검정 통계량, 자유도, 효과 크기(Cohen's d, Hedges' g, Cramér's V, η^2)를 항상 보고합니다.

[역할 수행 방식]
사용자가 데이터 또는 분석 목적을 제시하면:
① 데이터 구조 파악 및 품질 평가
② 적합한 통계 방법론 추천 (근거 제시)
③ 완전한 분석 제공 (전처리 → 분석 → 시각화 → 표 생성)
④ 결과 해석 및 임상적 의미 설명
⑤ SCIE 논문용 표현(영문) 제안
⑥ 한계점 및 추가 분석 제안

[품질 기준]
통계적으로 불명확하거나 임상적으로 의미가 없는 분석은 수행하지 않고 더 적합한 방법을 제안합니다. Top 10% SCIE 저널 수준의 결과물만 제공합니다.

부록: 연구보고서

[역할] 당신은 30년차 연구 결
성 전문 컨설턴트이자 혈액종
의이다.
[지시] 표적치료의 정의, 종류
효과, 부작용, 최근 20년간 환
치료 동향 등을 소개하는 연구
목차를 작성해줘.

아래와 같이 구성하면 의학적 정확성, 임상적 흐름, 최신 연구
적으로 정리할 수 있습니다. 특히 혈액종양내과 관점에서 기초
→ 최신 동향 → 향후 전망의 순서로 배치하는 것을 권장합니다

연구보고서 목차

「암 표적치료의 원리와 임상적 발전: 치료 효과, 부

I. 서론

1. 연구 배경 및 필요성
2. 암 발생과 치료 패러다임의 변화
3. 표적치료 연구의 등장과 발전 배경
4. 연구 목적 및 연구 범위
5. 연구 방법 및 자료 수집 기준

II. 표적치료의 정의와 기본 원리

1. 표적치료(Targeted Therapy)의 정의
2. 기존 세포독성 항암화학요법과의 차이
3. 암의 분자생물학적 특성과 치료 표적
4. 유전자 변이와 바이오마커의 역할
5. 정밀의료(Precision Oncology)와 표적치료의 관계

III. 표적치료의 종류

1. 소분자 억제제(Small-molecule inhibitors)
2. 단일클론항체(Monoclonal antibodies)
3. 항체-약물 접합체(Antibody-drug conjugates, ADC
4. 단백질 분해 유도제 및 기타 신개념 표적치료
5. 주요 분자표적별 치료제
   - EGFR
   - ALK
   - ROS1
   - BRAF
   - KRAS
   - HER2
   - MET
   - RET
   - NTRK
   - VEGF/VEGFR
   - BCR-ABL
   - 기타 주요 표적

IV. 표적치료의 치료 방법과 임상 적용

1. 환자 선별과 바이오마커 검사
2. 조직검사 및 차세대염기서열분석(NG
3. 액체생검과 순환종양DNA(ctDNA)
4. 단독 표적치료
5. 표적치료와 항암화학요법의 병용
6. 표적치료와 면역항암제의 병용
7. 표적치료의 치료 순서 및 치료 전략
8. 진행성 암과 전이암에서의 표적치료
9. 수술 전·후 보조요법에서의 표적치료
10. 치료 반응 및 내성 모니터링

V. 표적치료의 치료 효과

1. 종양 반응률(ORR)
2. 무진행생존기간(PFS)
3. 전체생존기간(OS)
4. 반응 지속기간(DoR)
5. 삶의 질(QoL) 개선 효과
6. 기존 항암치료와의 치료효과 비교
7. 주요 암종별 대표 표적치료의 임상 성
8. 바이오마커에 따른 치료효과의 차이
9. 실제 임상현장(Real-world evidenc

VI. 표적치료의 부작용 및 안전성

1. 표적치료 관련 부작용의 개요
2. 혈액학적 독성
3. 피부 독성 및 점막 독성
4. 위장관계 부작용
5. 간·신장 독성
6. 심혈관계 독성 및 심장독성(Cardiot
7. 폐독성 및 간질성 폐질환
8. 신경계 독성
9. 치료 관련 중증 이상반응과 사망
10. 부작용 관리 및 치료 지속성의 관계
11. 환자별 위험인자 기반 독성 예측

VII. 표적치료의 치료 내성

1. 표적치료 내성의 정의
2. 1차 내성(Primary resistanc
3. 획득 내성(Acquired resista
4. 표적 유전자 자체의 2차 변이
5. 우회 신호경로(Bypass path
6. 조직학적 변환(Histologic tr
7. 종양 이질성과 내성 발생
8. ctDNA를 이용한 내성 조기 탐
9. 내성 발생 이후 후속 표적치료

VIII. 최근 20년간 표적치료 환

1. 최근 20년간 암 발생 및 생존
2. 표적치료 적용 환자의 증가 추
3. 주요 암종별 표적치료 환자 규
4. 암종별 주요 driver mutatio
5. 연도별 표적치료제 사용 변화
6. 표적치료 도입 전후 생존율 변
7. 국내 환자 통계와 국제 통계 비
8. 연령·성별·병기별 표적치료 환
9. 실제 진료자료를 이용한 표적
10. 통계자료의 한계와 해석상의

> 중요: 이 장은 단순히 "20년간
> 자 비율 → 실제 표적치료 시행

IX. 최근 표적치료의 임상적 발

1. 정밀종양학(Precision Onco
2. NGS 기반 다중 바이오마커 검
3. 액체생검 및 ctDNA 기반 정밀
4. MRD 기반 치료반응 평가
5. 3세대 및 차세대 표적치료제의
6. ADC 및 이중특이항체의 발전
7. 표적치료와 면역항암치료의 병
8. CNS 전이 및 뇌혈관 장벽을
9. 치료 순서 최적화 및 내성 극복
10. 인공지능(AI) 기반 환자 선별
11. Real-world data와 생성형 A
12. 개인 맞춤형 표적치료 전략의

X. 표적치료의 임상적·사회적 한계

1. 치료 내성의 문제
2. 고가의 치료비와 경제적 부담
3. 바이오마커 검사 접근성의 격차
4. 표적이 없는 환자의 치료 한계
5. 환자 간 분자적 이질성
6. 장기 생존에 따른 만성 독성 문제
7. 실제 임상현장에서의 치료 격차
8. 국가별 표적치료 접근성 차이

XI. 표적치료 관련 최근 주요 연구 사례

1. EGFR 표적치료의 발전 사례
2. HER2 표적치료의 발전 사례
3. KRAS 표적치료의 발전 사례
4. ALK/ROS1/RET/NTRK 표적치료의 발전 사례
5. ADC를 이용한 최신 치료 사례
6. 치료 내성을 극복한 대표적 임상시험
7. 최근 5년간 주요 3상 임상시험 결과 비교
8. 실제 임상데이터를 활용한 주요 연구 사례

XII. 향후 연구 및 치료 발전 방향

1. 새로운 치료 표적의 발굴
2. 다중 오믹스 기반 표적 발굴
3. 동적 바이오마커를 이용한 치료 모니터링
4. AI·머신러닝 기반 치료반응 예측
5. 환자별 최적 치료 순서 결정
6. 내성 발생 전 조기 개입 전략
7. 표적치료와 면역치료의 통합
8. 치료 효과와 독성을 동시에 고려한 개인맞춤형 치료
9. 암 생존자의 장기 심혈관·대사 관리
10. 향후 정밀의료의 발전 전망

XIII. 결론

1. 표적치료 발전의 주요 성과
2. 환자 생존과 삶의 질에 미친 영향
3. 현재 표적치료의 핵심 한계
4. 최근 20년간의 변화에 대한 종합 평가
5. 향후 표적치료의 발전 방향
6. 연구 결과의 임상적·학술적 의의

참고문헌

부록: 연구보고서 작성하기 – Canvas 활용하기(Gemini)

- **Canvas: Gemini에서 문서·슬라이드·코드 등을 생성하고 직접 수정하는 작업 공간**



부록: 연구보고서 작성하기

위 목차에 따라 1.서론 부분을 작성해 주세요.

위 목차에 따라 II. 표적치료제의 분류 및 주요 약제 현황 부분을 작성해 주세요..

